

数理经济学 (26 春)

课堂笔记

© Editors

云边港



第一章 线性代数回顾

1

1.1	总览	1
1.2	线性空间与线性映射	1
1.2.1	欧氏空间与基本运算	1
1.2.2	线性映射的定义与刻画	2
1.3	内积、范数与几何结构	3
1.3.1	内积与范数	3
1.3.2	Cauchy–Schwarz 不等式	4
1.3.3	三角不等式	5
1.4	矩阵与线性映射的矩阵表示	5
1.4.1	矩阵表示	5
1.4.2	矩阵乘法与复合映射	6
1.5	单位矩阵、可逆矩阵与线性方程组	6
1.5.1	单位矩阵	6
1.5.2	可逆矩阵	6
1.5.3	可逆性与线性方程组	7
1.6	行列式	8
1.6.1	2×2 情形	8
1.6.2	一般定义	9
1.6.3	行列式的基本性质	9
1.6.4	行列式与可逆性	10
1.7	行列式的进一步性质	10
1.7.1	转置矩阵	10
1.7.2	对称矩阵	11
1.7.3	上三角矩阵、下三角矩阵与块三角矩阵	11
1.7.4	正交矩阵	13
1.8	伴随矩阵与克莱姆法则	14
1.8.1	代数余子式与伴随矩阵	14
1.8.2	克莱姆法则	15
1.9	对称矩阵的正定性	18
1.9.1	半正定、正定、负定	18
1.9.2	利用正交对角化理解正定性	19

1.10 主子式与 Sylvester 判别法	20
1.10.1 主子式与顺序主子式	20
1.10.2 正定矩阵的必要条件	21
1.10.3 Sylvester 判别法	21
1.10.4 二维与三维情形的快速判别	23
1.11 与优化理论的联系	23
1.12 特征值、特征向量与对角化	24
1.12.1 定义	24
1.12.2 特征值的求法	24
1.12.3 对角化	25

第二章 $\mathbb{R}^N$ 的拓扑基础 27

2.1 总览	27
2.2 度量空间与收敛	27
2.2.1 度量的定义	27
2.2.2 序列收敛	28
2.2.3 有界序列与 Cauchy 序列	28
2.2.4 例: Cauchy 序列在 $\mathbb{Q}$ 中未必收敛	29
2.3 实数列与 $\mathbb{R}^N$ 中序列的若干基本性质	31
2.3.1 实数列极限的代数性质	31
2.3.2 收敛序列必有界	33
2.3.3 子列与子列极限	34
2.3.4 上极限与下极限	35
2.4 开集、闭集与邻域	37
2.4.1 开球与闭球	37
2.4.2 开集与闭集	37
2.5 内点、闭包与边界	38
2.6 紧集与 Heine-Borel 定理	39
2.6.1 紧性的序列定义	39
2.6.2 紧集的基本性质	39
2.6.3 Heine-Borel 定理	40
2.7 聚点与函数极限	41
2.7.1 聚点	41
2.7.2 聚点处的函数极限	41
2.7.3 极限的基本性质	43
2.8 连续函数	44
2.8.1 连续性的定义	44
2.8.2 序列刻画	45
2.8.3 紧集上的连续函数	47

2.9 半连续函数、Lipschitz 连续与不动点定理	48
2.9.1 半连续函数	48
2.9.2 半连续函数在紧集上取极值	49
2.9.3 Lipschitz 连续	50
2.9.4 压缩映射与不动点	51
2.9.5 介值定理	54

第三章 多元微积分回顾 56

3.1 总览与核心思想	56
3.2 Differentiation: 可微与导数的定义	56
3.2.1 一般定义: Differentiability in $\mathbb{R}^n$	56
3.2.2 导数的唯一性 (Uniqueness of the Derivative)	57
3.2.3 可微必连续 (Differentiable $\Rightarrow$ Continuous)	58
3.3 从二维线性逼近到偏导数 (Partial Derivatives)	58
3.3.1 二维情形的线性逼近	58
3.3.2 偏导数的定义	58
3.3.3 一个偏导计算的例子	59
3.4 光滑性的层次 (Levels of Smoothness)	59
3.5 二维可微的正式定义	60
3.6 Vector notation and gradient: 向量记号与梯度	62
3.6.1 向量形式的可微	62
3.6.2 梯度 (Gradient)	62
3.6.3 一阶最优条件 (First-Order Condition)	62
3.6.4 方向导数 (Directional Derivative) 与最速上升方向	63
3.6.5 例子: 距离函数	64
3.7 Mean Value Theorem and Taylor's Theorem	65
3.7.1 多元中值定理 (Mean Value Theorem)	65
3.7.2 Hessian 矩阵与二阶 Taylor 公式	66
3.8 Vector-Valued Functions 与 Jacobian Matrix	67
3.8.1 向量值函数 (Vector-Valued Functions)	67
3.8.2 向量值函数的可微性	67
3.8.3 Jacobian 矩阵	68
3.9 Chain Rule: 链式法则	68
3.9.1 一般形式	68
3.9.2 PPT 中的一维参数例子	69
3.10 Implicit Function Theorem: 隐函数定理	70
3.10.1 动机: 无差异曲线 (Indifference Curves)	70
3.10.2 一维内生变量的隐函数求导	71
3.10.3 多维版本的矩阵形式	71
3.10.4 隐函数定理 (Implicit Function Theorem)	72
3.10.5 例子: 圆	72
3.10.6 经济学应用: Consumer Demand and Comparative Statics	73

3.11 Inverse Function Theorem: 逆函数定理	74
--	----

第四章 多元无约束优化	76
--------------------	-----------

4.1 总览	76
4.2 单变量优化例子	76
4.2.1 垄断者利润最大化问题 (Monopoly Equilibrium Problem)	76
4.3 多元无约束优化的一般问题 (General Unconstrained Optimization Problem)	77
4.4 一阶条件 (First-Order Conditions)	78
4.4.1 必要性但非充分性	78
4.4.2 几个基本定义	78
4.5 经济学例子: 市场间产量配置 (Monopolist Output Allocation Across Markets)	79
4.6 经济学例子: 边际收益与需求弹性 (Demand Elasticity)	79
4.6.1 Lerner Index	80
4.6.2 经济学含义	80
4.7 Cournot 竞争例子	80
4.7.1 最佳反应函数 (Best Response)	81
4.7.2 一般化到 n 个相同企业	81
4.8 关于一阶条件的进一步说明	82
4.9 局部极值与鞍点的图形理解	82
4.9.1 在两个方向上都是局部极小或局部极大	82
4.9.2 一个方向最小、另一个方向最大: 鞍点 (Saddle Point)	83
4.10 二阶充分条件 (Sufficient Condition for Optimality: Second-Order Condition)	83
4.10.1 推导	83
4.10.2 二维情形的 Hessian	84
4.11 二阶条件的例子	85
4.11.1 一维例子	85
4.11.2 二维例子: 正定 Hessian	85
4.11.3 鞍点例子	86
4.12 凸优化 (Convex Optimization)	86
4.12.1 凸函数的定义 (Definition: Convex Function)	86
4.12.2 凸函数与 Hessian 的关系	87
4.12.3 解释	87
4.13 凸函数的另一种刻画	87
4.13.1 证明	88
4.13.2 图形解释	88
4.14 凸函数上的最优性刻画	88
4.14.1 证明思路 (Hint: Taylor's Theorem)	89
4.15 二次函数 (Quadratic Functions)	89
4.15.1 形式与记号 (Form and Notation)	89
4.15.2 梯度与 Hessian	90
4.15.3 凸性与凹性	90
4.15.4 最优解公式	90

4.16 数值计算 (Numerical Computation)	91
4.17 一维非线性求根：二分法 (Bisection Method)	91
4.17.1 问题背景	91
4.17.2 基本原理	91
4.17.3 算法过程 (Process)	91
4.17.4 Matlab 代码	92
4.17.5 收敛速度 (Convergence Rate and Order)	92
4.18 割线法与假位法	93
4.18.1 基本思想	93
4.18.2 割线法 (Secant Method)	93
4.18.3 假位法 (False Position Method)	94
4.18.4 Secant Method 的 Matlab 代码	95
4.18.5 两种方法的比较	95
4.18.6 长迭代例子 (Example of Long Iterations)	95
4.19 牛顿法 (Newton's Method / Newton-Raphson Method)	95
4.19.1 基本思想	95
4.19.2 数学推导	96
4.19.3 收敛性质	97
4.19.4 一维 Newton Method 的 Matlab 代码	98
4.19.5 优点与局限 (Advantages and Limitations)	98
4.19.6 失败例子 (Failure Examples)	99
4.20 多维牛顿法 (Newton Method in Multiple Dimensions)	99
4.20.1 求解非线性方程组	99
4.20.2 MATLAB 实现思路	99
4.21 牛顿法用于数值优化 (Newton Method for Numerical Optimization)	100
4.21.1 从 Taylor 近似推导	100
4.21.2 与方程求解的关系	101
4.21.3 正式算法 (Formal Algorithm)	101
4.22 Newton Method 在经济学中的应用	101
4.22.1 优化问题	101
4.22.2 均衡计算 (Equilibrium Computation)	102
4.23 梯度法 (Gradient Method / Steepest Descent Method)	102
4.23.1 几何解释	102
4.23.2 基本思想	102
4.23.3 算法步骤	103
4.23.4 图形理解 (Graphic Illustration)	103
4.23.5 例子 (Gradient Method)	104
4.24 本讲总结	104

第五章 多元等式约束优化

106

5.1 导入	106
--------	-----

5.2	例子: 消费者效用最大化	106
5.2.1	问题	106
5.2.2	解答: 直接代入法	107
5.2.3	Why study the general theory?	108
5.3	二元函数的约束优化	108
5.3.1	从无约束到有约束	108
5.3.2	几何解释	109
5.4	约束优化的代数解	109
5.4.1	切线条件 (Tangency condition)	109
5.4.2	可行性条件	110
5.5	约束优化的替换方法	110
5.5.1	把约束写成隐函数	110
5.5.2	化为无约束问题	111
5.6	受限最优解的拉格朗日特征 (Lagrangian Characterization of Constrained Optima)	111
5.6.1	双变量、单约束情况	111
5.6.2	为什么它与相切条件一致?	112
5.7	多变量和多约束的拉格朗日方法	112
5.7.1	Generalized problem	113
5.7.2	Jacobian matrix of constraints	113
5.7.3	First-Order Conditions	113
5.7.4	Equivalent characterization	114
5.8	非退化约束限定 (Nondegenerate Constraint Qualification, NDCQ)	114
5.8.1	Definition	114
5.8.2	为什么需要 NDCQ?	114
5.9	示例: 约束优化问题	114
5.9.1	Example 1	114
5.9.2	Example 2	115
5.10	拉格朗日方法的重要注意事项	116
5.10.1	Without NDCQ	116
5.10.2	With NDCQ	116
5.11	应用: Cobb-Douglas 效用函数	116
5.11.1	Primal Problem (Utility Maximization)	117
5.11.2	Dual Problem (Expenditure Minimization)	117
5.12	Setup: Two-Variable, One-Constraint Problem	117
5.13	Hessian Matrix of the Lagrange Function	117
5.13.1	Bordered Hessian	118
5.14	拉格朗日优化的二阶条件: 双变量情形	118
5.14.1	为什么这里符号与无约束 Hessian 判别不同?	118
5.15	Why Does the Bordered Hessian Look Like This?	119
5.15.1	Feasible directions	119
5.15.2	Curvature along the constraint	119

5.16 Second-Order Conditions: n -variable case	120
5.16.1 For Minimum	121
5.16.2 For Maximum	121
5.16.3 补充说明	121
5.17 示例: 预算约束下的 Cobb-Douglas 效用	122
5.17.1 Step 1: Construct the Lagrangian	122
5.17.2 Step 2: First-order conditions	122
5.17.3 Step 3: Why is the tangency point a true local maximum?	123
5.18 本讲总结	124

第六章 比较静态与包络定理 126

6.1 总览	126
6.2 比较静态的基本思想 (Comparative Statics Analysis)	126
6.2.1 动机一: 线性市场模型	126
6.2.2 动机二: 垄断者产出税	127
6.3 单方程比较静态: 隐函数方法 (Implicit Function Approach)	128
6.3.1 一般形式	128
6.3.2 市场均衡例子	129
6.4 多变量比较静态 (Comparative Statics with Multiple Variables)	130
6.4.1 两个内生变量、两个外生变量	130
6.4.2 利用 Cramer's rule 求显式公式	130
6.4.3 Cramer's rule 回顾	131
6.5 无约束优化问题的比较静态 (Comparative Statics for Unconstrained Optimization)	131
6.5.1 一般问题	131
6.5.2 Implicit Function Theorem 与 Hessian	132
6.5.3 比较静态公式	132
6.5.4 例子: 竞争性厂商的要素需求	132
6.6 等式约束优化问题的比较静态 (Comparative Statics for Equality Constrained Optimization)	133
6.6.1 一般形式	133
6.6.2 Jacobian 与 bordered Hessian	134
6.6.3 二维、单约束情形的矩阵推导	134
6.6.4 显式比较静态公式	134
6.7 应用: Slutsky 方程 (Slutsky Equation)	135
6.7.1 效用最大化问题	135
6.7.2 关于价格的比较静态	135
6.7.3 Slutsky 方程	136
6.7.4 正常品、劣等品与 Giffen goods	137
6.7.5 Cobb-Douglas 例子	137

6.8	包络定理 (Envelope Theorem)	138
6.8.1	无约束优化情形	138
6.8.2	等式约束优化情形	138
6.8.3	推导	139
6.8.4	一般形式	139
6.8.5	拉格朗日乘子的经济学含义	140
6.9	包络定理的经济学应用	140
6.9.1	长短期成本曲线	140
6.9.2	数值例子	141
6.9.3	应用: shadow wage rate	142
6.9.4	间接效用函数与 Roy's Identity	143
6.9.5	支出函数与 Shephard's Lemma	143
6.9.6	经验需求分析中的一个应用: AIDS	144
6.10	本讲总结	144

第七章 多元不等式约束优化 145

7.1	总览	145
7.2	单个线性不等式约束	145
7.2.1	问题设定	145
7.2.2	内部解与边界解	145
7.2.3	可行方向与必要条件	146
7.2.4	正式结论	146
7.3	多个线性不等式约束	148
7.3.1	可行方向	148
7.3.2	KKT 条件的线性约束版本	148
7.3.3	拉格朗日解释	149
7.4	同时含等式与不等式约束	149
7.4.1	把等式约束改写成两条不等式	149
7.4.2	乘子符号为什么不同	150
7.4.3	一般形式	150
7.5	非线性不等式约束与约束资格 (Constraint Qualification)	151
7.5.1	为什么线性情形不能直接照搬	151
7.5.2	一般 KKT 定理	151
7.5.3	一个说明 CQ 必要性的例子	151
7.5.4	活跃约束集与 NDCQ	152
7.5.5	Slater 条件	152
7.5.6	线性无关的例子	153
7.5.7	几何解释: box constraints	153
7.5.8	非线性 LICQ 成立与失败的例子	153

7.6	凸优化中的 KKT 条件	154
7.6.1	定理陈述	154
7.6.2	充分性的证明	154
7.6.3	怎样实际使用这一定理	155
7.7	例子与应用	155
7.7.1	例子: 最小化 $1/x_1 + 1/x_2$	155
7.7.2	最大化问题的等价改写	156
7.7.3	Cobb-Douglas 效用最大化	157
7.8	本讲总结	157

第八章 应用一般均衡理论

158

8.1	总览	158
8.2	Arrow-Debreu 模型	158
8.2.1	什么是一般均衡?	158
8.2.2	商品的广义含义	158
8.2.3	基本记号	159
8.2.4	消费束与效用函数	159
8.2.5	常见效用函数	160
8.2.6	Arrow-Debreu 经济的定义	160
8.2.7	市场、价格与预算约束	161
8.2.8	货币中性与价格标准化	162
8.2.9	主体目标与竞争均衡	162
8.2.10	例子: Edgeworth box 经济	163
8.2.11	例子: 利率作为跨期相对价格	164
8.3	Walras 法则	165
8.3.1	三种单调性概念	165
8.3.2	局部不饱和意味着花光收入	166
8.3.3	Walras Law	166
8.3.4	均衡中超额供给商品必须免费	167
8.3.5	强单调性下可以忽略一个市场	168
8.3.6	求解一般均衡的基本算法	169
8.3.7	Cobb-Douglas Edgeworth box 的一般形式	170
8.3.8	一般 Cobb-Douglas 经济	170
8.4	准线性模型	171
8.4.1	为什么引入准线性模型?	171
8.4.2	准线性效用	172
8.4.3	准线性效用下的需求	172
8.4.4	可加分离的非线性部分	173
8.4.5	准线性模型的局限	173
8.4.6	均衡配置最大化效用和	174
8.4.7	最大化效用和也能生成均衡	175
8.4.8	福利含义	176

8.4.9 例子：一维准线性经济	176
8.5 本讲总结	177
第九章 凸集与凸函数	179
9.1 总览	179
9.2 凸集	179
9.2.1 凸集的定义	179
9.2.2 凸包	180
9.2.3 凸组合与凸包的存在	180
9.3 超平面与半空间	182
9.3.1 从直线和平面到超平面	182
9.3.2 半空间	182
9.4 凸集的分离	183
9.4.1 分离超平面	183
9.4.2 可分离性的等价写法	183
9.4.3 分离超平面定理	184
9.4.4 投影引理	184
9.4.5 点与凸集的分离	186
9.4.6 分离超平面定理的证明	187
9.5 凸函数与拟凸函数	188
9.5.1 凸函数与凹函数	188
9.5.2 一阶刻画	189
9.5.3 Hessian 刻画	189
9.5.4 上图集、下图集与凸性	190
9.5.5 拟凸函数	191
9.5.6 单调变换下的关系	191
9.5.7 拟凸函数的一阶刻画	191
9.5.8 偏好理论中的拟凹性	192
9.5.9 间接效用与支出函数	192
9.5.10 支出函数关于价格凹	193
9.5.11 间接效用关于价格和收入拟凸	193
9.5.12 拟凸问题中 KKT 的充分性	193
9.6 应用：均衡的福利性质	194
9.6.1 均衡是否“理想”？	194
9.6.2 一致同意原则	195
9.6.3 Pareto 有效性	195
9.6.4 蛋糕例子	196
9.6.5 福利最大化推出 Pareto 有效	196
9.6.6 Pareto 权重的构造	197
9.7 本讲总结	199

第十章 动态优化与 Ramsey 模型 200

10.1 总览	200
10.1.1 跨期权衡	200
10.1.2 离散时间与连续时间	200
10.1.3 差分方程与微分方程	201
10.2 离散时间 Ramsey 模型	202
10.2.1 规划者问题	202
10.2.2 基本假设	202
10.2.3 内点性与终端条件	203
10.2.4 拉格朗日法与 Euler 方程	204
10.2.5 凹性与充分性	205
10.2.6 例：对数效用与线性技术	206
10.2.7 例：十期数值问题	206
10.3 无限期与横截条件	207
10.3.1 无限期 Ramsey 问题	207
10.3.2 Euler 方程与横截条件	208
10.3.3 例：对数效用与 Cobb-Douglas 生产	209
10.4 稳态与转移动态	210
10.4.1 稳态	210
10.4.2 稳态比较静态	211
10.4.3 例：Cobb-Douglas 生产	211
10.4.4 转移动态	212
10.5 本讲总结	213

第十一章 动态规划与连续时间优化 214

11.1 总览	214
11.2 动态规划与 Bellman 方程	214
11.2.1 动态规划的基本思想	214
11.2.2 Bellman 方程	215
11.2.3 Ramsey 模型的递归表示	216
11.2.4 政策函数	216
11.2.5 一阶条件与包络条件	217
11.2.6 序列方法与递归方法的比较	217
11.3 猜测验证法与价值函数迭代	218
11.3.1 猜测验证法	218
11.3.2 求解政策函数	219
11.3.3 匹配系数	219
11.3.4 经济学解释	220

11.4 价值函数迭代	220
11.4.1 基本思想	220
11.4.2 Bellman 算子	221
11.4.3 为什么价值函数迭代有效	222
11.4.4 log-Cobb-Douglas 模型中的 VFI	223
11.4.5 数值图示	224
11.5 本讲总结	224



Sec 1.1 总览

第一章按照课件顺序回顾后续数理经济学中最常用的线性代数工具。主线可以概括为：

1. **Linearity (线性性)**：理解线性空间、线性函数与线性映射；
2. **Inner product and norm (内积与范数)**：建立长度、角度与距离的几何语言；
3. **Matrix (矩阵)**：把抽象线性映射写成可计算的矩阵形式；
4. **Identity matrix, inverse, determinant (单位矩阵、逆矩阵、行列式)**：刻画线性方程组何时可逆、何时有一解；
5. **Transpose, symmetric matrices, orthogonal matrices (转置、对称矩阵、正交矩阵)**：为二次型与二阶条件做准备；
6. **Eigenvalues, eigenvectors, diagonalization (特征值、特征向量、对角化)**：把复杂线性变换化为最容易分析的对角形式。

这些内容在后面几章会反复出现：拓扑里要用范数与距离，微积分里要用 Jacobian 与 Hessian，优化理论里要用正定性、特征值和对角化来判断极值性质。

Sec 1.2 线性空间与线性映射

1.2.1 欧氏空间与基本运算

设

$$\mathbb{R}^N = \{x = (x_1, \dots, x_N) : x_i \in \mathbb{R}\}.$$

在 $\mathbb{R}^N$ 上定义向量加法与数乘：

$$x + y := (x_1 + y_1, \dots, x_N + y_N), \quad \alpha x := (\alpha x_1, \dots, \alpha x_N).$$

它们满足交换律、结合律、分配律，并存在零向量

$$0 := (0, \dots, 0)$$

以及加法逆元 $-x$ 。因此 $\mathbb{R}^N$ 是一个实线性空间。

1.2.2 线性映射的定义与刻画

Definition 1.2.1.

设 X, Y 为实线性空间。映射 $T: X \rightarrow Y$ 称为**线性映射**，若对任意 $x, y \in X$ 及任意标量 $\alpha, \beta \in \mathbb{R}$ ，都有

$$T(\alpha x + \beta y) = \alpha T(x) + \beta T(y).$$

特别地，当 $Y = \mathbb{R}$ 时， T 称为线性泛函。

Proposition 1.2.1.

任意线性映射 $T: \mathbb{R}^N \rightarrow \mathbb{R}$ 都可写成

$$T(x) = a_1 x_1 + \cdots + a_N x_N$$

的形式，其中 $a_1, \dots, a_N \in \mathbb{R}$ 唯一确定。

Proof. 记标准基为

$$e_1 = (1, 0, \dots, 0), \quad e_2 = (0, 1, \dots, 0), \quad \dots, \quad e_N = (0, \dots, 0, 1).$$

任意 $x = (x_1, \dots, x_N)$ 可分解为

$$x = x_1 e_1 + \cdots + x_N e_N.$$

由线性性，

$$T(x) = T\left(\sum_{i=1}^N x_i e_i\right) = \sum_{i=1}^N x_i T(e_i).$$

令

$$a_i := T(e_i),$$

则

$$T(x) = \sum_{i=1}^N a_i x_i.$$

唯一性显然：若

$$\sum_{i=1}^N a_i x_i = \sum_{i=1}^N b_i x_i \quad \forall x \in \mathbb{R}^N,$$

取 $x = e_j$ 即得 $a_j = b_j$ 。

Sec 1.3 内积、范数与几何结构

1.3.1 内积与范数

在 $\mathbb{R}^N$ 上定义欧氏内积

$$\langle x, y \rangle := x_1 y_1 + \cdots + x_N y_N = \sum_{i=1}^N x_i y_i.$$

对应的欧氏范数定义为

$$\|x\| := \sqrt{\langle x, x \rangle} = \sqrt{x_1^2 + \cdots + x_N^2}.$$

Proposition 1.3.2.

内积关于每个变量都是线性的，即

$$\langle x, y + z \rangle = \langle x, y \rangle + \langle x, z \rangle, \quad \langle x, \alpha y \rangle = \alpha \langle x, y \rangle,$$

并且

$$\langle x, y \rangle = \langle y, x \rangle.$$

Proposition 1.3.3.

在 $\mathbb{R}^2$ 中，若 θ 是非零向量 x, y 之间的夹角，则

$$\langle x, y \rangle = \|x\| \|y\| \cos \theta.$$

Proof. 对向量差应用余弦定理：

$$\|x - y\|^2 = \|x\|^2 + \|y\|^2 - 2\|x\| \|y\| \cos \theta.$$

另一方面，

$$\|x - y\|^2 = \langle x - y, x - y \rangle = \|x\|^2 + \|y\|^2 - 2\langle x, y \rangle.$$

比较两式即得

$$\langle x, y \rangle = \|x\| \|y\| \cos \theta.$$

因此内积不仅是一个代数量，而且有清晰的几何含义：

- 若 $\langle x, y \rangle = 0$ ，则 x, y **orthogonal** (正交)；
- 若 $\langle x, y \rangle > 0$ ，则两向量形成 **acute angle** (锐角)；
- 若 $\langle x, y \rangle < 0$ ，则两向量形成 **obtuse angle** (钝角)。

Proposition 1.3.4.

欧氏范数满足以下三个基本性质:

1. *Non-negativity* (非负性):

$$\|x\| \geq 0, \quad \|x\| = 0 \iff x = 0;$$

2. *Homogeneity* (齐次性):

$$\|\alpha x\| = |\alpha| \|x\|;$$

3. *Triangle inequality* (三角不等式):

$$\|x + y\| \leq \|x\| + \|y\|.$$

Proof. 前两条可直接由定义推出。首先

$$\|x\| = \sqrt{x_1^2 + \cdots + x_N^2} \geq 0.$$

若 $\|x\| = 0$, 则平方后得

$$x_1^2 + \cdots + x_N^2 = 0.$$

由于每一项都非负, 只能逐项为零, 即 $x = 0$; 反之 $x = 0$ 时显然 $\|x\| = 0$ 。

其次,

$$\|\alpha x\| = \sqrt{(\alpha x_1)^2 + \cdots + (\alpha x_N)^2} = \sqrt{\alpha^2(x_1^2 + \cdots + x_N^2)} = |\alpha| \|x\|.$$

第三条三角不等式将在下一小节由 Cauchy-Schwarz 不等式推出。 ■

1.3.2 Cauchy-Schwarz 不等式

Theorem 1.3.1.

Cauchy-Schwarz 不等式 对任意 $x, y \in \mathbb{R}^N$,

$$|\langle x, y \rangle| \leq \|x\| \|y\|.$$

当且仅当 x, y 线性相关时取等号。

Proof. 若 $y = 0$, 结论显然。以下设 $y \neq 0$ 。

考虑关于实数 t 的函数

$$\phi(t) := \|x - ty\|^2 = \langle x - ty, x - ty \rangle.$$

由于范数平方非负,

$$\phi(t) \geq 0 \quad \forall t \in \mathbb{R}.$$

展开得

$$\phi(t) = \|x\|^2 - 2t\langle x, y \rangle + t^2\|y\|^2.$$

这是一个二次多项式, 且对任意 t 非负, 因此其判别式不大于零:

$$\Delta = 4\langle x, y \rangle^2 - 4\|x\|^2\|y\|^2 \leq 0.$$

于是

$$\langle x, y \rangle^2 \leq \|x\|^2\|y\|^2,$$

即

$$|\langle x, y \rangle| \leq \|x\|\|y\|.$$

若取等号, 则判别式为零, 此时存在某个 t_0 使

$$x - t_0 y = 0,$$

故 x, y 线性相关。反之, 若 $x = \lambda y$, 则

$$|\langle x, y \rangle| = |\lambda|\|y\|^2 = \|x\|\|y\|.$$

1.3.3 三角不等式

Proposition 1.3.5.

对任意 $x, y \in \mathbb{R}^N$,

$$\|x + y\| \leq \|x\| + \|y\|.$$

Proof. 计算:

$$\|x + y\|^2 = \langle x + y, x + y \rangle = \|x\|^2 + 2\langle x, y \rangle + \|y\|^2.$$

由 Cauchy-Schwarz 不等式,

$$2\langle x, y \rangle \leq 2|\langle x, y \rangle| \leq 2\|x\|\|y\|.$$

故

$$\|x + y\|^2 \leq \|x\|^2 + 2\|x\|\|y\| + \|y\|^2 = (\|x\| + \|y\|)^2.$$

两边取平方根即得结论。

Sec 1.4 矩阵与线性映射的矩阵表示

1.4.1 矩阵表示

设 $T: \mathbb{R}^N \rightarrow \mathbb{R}^M$ 为线性映射。令

$$T(e_j) = \begin{pmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{Mj} \end{pmatrix}, \quad j = 1, \dots, N.$$

1.5. 单位矩阵、可逆矩阵与线性方程组

则 T 可由矩阵

$$A = (a_{ij})_{M \times N}$$

表示, 且对任意 $x = (x_1, \dots, x_N)^\top$,

$$T(x) = Ax.$$

具体地,

$$Ax = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1N} \\ a_{21} & a_{22} & \cdots & a_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ a_{M1} & a_{M2} & \cdots & a_{MN} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix} = \begin{pmatrix} \sum_{j=1}^N a_{1j}x_j \\ \sum_{j=1}^N a_{2j}x_j \\ \vdots \\ \sum_{j=1}^N a_{Mj}x_j \end{pmatrix}.$$

1.4.2 矩阵乘法与复合映射

若

$$T: \mathbb{R}^N \rightarrow \mathbb{R}^M, \quad S: \mathbb{R}^M \rightarrow \mathbb{R}^L$$

分别由矩阵 A 与 B 表示, 则复合映射 $S \circ T: \mathbb{R}^N \rightarrow \mathbb{R}^L$ 由矩阵 BA 表示:

$$(S \circ T)(x) = S(T(x)) = B(Ax) = (BA)x.$$

因此矩阵乘法本质上是线性映射复合的坐标表示。

Sec 1.5 单位矩阵、可逆矩阵与线性方程组

1.5.1 单位矩阵

n 阶单位矩阵记为 I_n , 其定义为

$$(I_n)_{ij} = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

它对应恒等映射 $\text{id}(x) = x$, 满足

$$AI_n = A, \quad I_n A = A.$$

对映射 $T: \mathbb{R}^n \rightarrow \mathbb{R}^n$, 还需要区分三种基本性质:

- **injective (单射, one-to-one)**: 若 $T(x) = T(y)$ 必推出 $x = y$;
- **surjective (满射, onto)**: 对任意 $z \in \mathbb{R}^n$, 存在 x 使 $T(x) = z$;
- **bijective (双射)**: 同时既单射又满射。

若 T 是双射, 则对每个 z 都存在唯一的 x 使 $T(x) = z$, 从而可以定义逆映射

$$T^{-1}(z) = x.$$

矩阵可逆性正是这一概念在线性映射坐标表示下的版本。

1.5.2 可逆矩阵

Definition 1.5.2.

若存在 $n \times n$ 矩阵 B 使得

$$AB = BA = I_n,$$

则称 A 可逆, 并称 B 为 A 的逆矩阵, 记作 A^{-1} .

Proposition 1.5.6.

若逆矩阵存在, 则它唯一。

Proof. 设 B, C 都是 A 的逆矩阵, 则

$$AB = BA = I, \quad AC = CA = I.$$

于是

$$B = BI = B(AC) = (BA)C = IC = C.$$

故逆矩阵唯一。 ■

1.5.3 可逆性与线性方程组

设 A 为 $n \times n$ 矩阵, 则下列命题等价:

1. A 可逆;
2. 对任意 $b \in \mathbb{R}^n$, 线性方程组

$$Ax = b$$

有唯一解;

3. 齐次方程组

$$Ax = 0$$

只有零解;

4. A 的列向量线性无关;
5. A 的行向量线性无关。

Proof (等价性的说明).

$$A \text{ 可逆} \implies x = A^{-1}b$$

给出任意线性方程组的唯一解, 因此 (1) $\Rightarrow$ (2)。

(2) $\Rightarrow$ (3) 显然: 取 $b = 0$ 。

(3) $\Rightarrow$ (4): 设 $A = [v_1, \dots, v_n]$ 。若列向量线性相关, 则存在不全为零的 $\lambda_1, \dots, \lambda_n$ 使

$$\lambda_1 v_1 + \dots + \lambda_n v_n = 0.$$

令

$$x = (\lambda_1, \dots, \lambda_n)^\top \neq 0,$$

则

$$Ax = 0,$$

与齐次方程只有零解矛盾。

(4) $\Rightarrow$ (2) 可由维数理论或消元法推出: 列向量线性无关意味着线性映射 $x \mapsto Ax$ 单射, 而定义域与值域维数同为 n , 因此也是满射, 于是对任意 b 都有唯一解。

最后 (2) $\Rightarrow$ (1): 定义映射

$$T: \mathbb{R}^n \rightarrow \mathbb{R}^n, \quad T(x) = Ax.$$

由唯一可解知 T 为双射, 故存在逆映射 T^{-1} 。进一步可证 T^{-1} 线性, 因此存在矩阵 B 使 $T^{-1}(y) = By$ 。于是

$$BA = AB = I.$$

故 A 可逆。

Sec 1.6 行列式

1.6.1 2×2 情形

对矩阵

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix},$$

定义其行列式为

$$\det A = ad - bc.$$

几何上, $|\det A|$ 等于矩阵列向量张成平行四边形的面积。




图 1.1: 2×2 行列式的几何意义: 列向量张成平行四边形的面积

1.6.2 一般定义

对 $n \times n$ 矩阵 $A = (a_{ij})$, 行列式可递归定义为按第 i 行展开:

$$\det A = \sum_{j=1}^n (-1)^{i+j} a_{ij} M_{ij},$$

其中 M_{ij} 是删去第 i 行第 j 列后所得 $(n-1) \times (n-1)$ 子式的行列式。

Theorem 1.6.2.

Leibniz 公式 (Leibniz Formula) 对任意 $n \times n$ 矩阵 $A = (a_{ij})$,

$$\det A = \sum_{\sigma \in S_n} \operatorname{sgn}(\sigma) \prod_{i=1}^n a_{i, \sigma(i)},$$

其中 S_n 是 n 个元素的排列群, $\operatorname{sgn}(\sigma) \in \{1, -1\}$ 表示排列 σ 的符号。

这个公式说明: 行列式是“每一行恰好取一个元素、每一列也恰好取一个元素”的所有乘积之和, 并按照排列奇偶性赋予正负号。递归定义与 Leibniz 公式是等价的; 前者便于计算, 后者便于证明性质。

1.6.3 行列式的基本性质

Proposition 1.6.7.

行列式满足:

1. $\det I_n = 1$;
2. 交换两行 (或两列), 行列式变号;
3. 某一行乘以常数 λ , 则行列式也乘以 λ ;
4. 某一行加上另一行的倍数, 行列式不变;
5. 若两行相同或成比例, 则 $\det A = 0$;
6. 若 A, B 都是 $n \times n$ 矩阵, 则

$$\det(AB) = \det A \cdot \det B.$$

Proof (关于乘法公式 $\det(AB) = \det A \det B$ 的说明). 前五条性质反映了行列式对行 (或列) 变换的响应。下面说明第六条乘法公式。

固定矩阵 B , 定义关于矩阵 A 的函数

$$\Phi_B(A) := \det(AB).$$

把 A 的列向量记为

$$A = [a_1 \ a_2 \ \cdots \ a_n].$$

1.7. 行列式的进一步性质

则

$$AB = [Ba_1 \ Ba_2 \ \cdots \ Ba_n].$$

由于行列式对列向量是多重线性的 (multilinear) 且交替的 (alternating), 所以 $\Phi_B(A)$ 也是 A 的列向量的交替多线性函数。

再看单位矩阵:

$$\Phi_B(I) = \det(B).$$

因此, Φ_B 与行列式 $\det A$ 具有同样的交替多线性结构, 只是归一化常数从 1 变成了 $\det(B)$ 。由行列式的唯一刻画可知

$$\Phi_B(A) = \det(B) \det(A).$$

也就是

$$\det(AB) = \det A \cdot \det B.$$

1.6.4 行列式与可逆性

Theorem 1.6.3.

矩阵 A 可逆当且仅当

$$\det A \neq 0.$$

Proof. 先证必要性。若 A 可逆, 则存在 A^{-1} 使

$$AA^{-1} = I.$$

取行列式:

$$\det(AA^{-1}) = \det I = 1.$$

由乘法公式,

$$\det A \cdot \det A^{-1} = 1,$$

故 $\det A \neq 0$ 。

再证充分性。若 $\det A \neq 0$, 则 A 的列向量不可能线性相关; 否则列向量线性相关意味着它们张成的有向体积为零, 即 $\det A = 0$, 矛盾。故列向量线性无关, 从而 A 可逆。 ■

Sec 1.7 行列式的进一步性质

1.7.1 转置矩阵

对矩阵 $A = (a_{ij})$, 其转置定义为

$$A^T = (a_{ji}).$$

显然有

$$(A^T)^T = A, \quad (A+B)^T = A^T + B^T, \quad (AB)^T = B^T A^T.$$

1.7.2 对称矩阵

Definition 1.7.3.

若

$$A^T = A,$$

则称 A 为对称矩阵。

对称矩阵在经济学中的二阶条件中极其重要, 因为 Hessian 矩阵在足够光滑时就是对称矩阵。

1.7.3 上三角矩阵、下三角矩阵与块三角矩阵

Definition 1.7.4.

设 $A = (a_{ij}) \in \mathbb{R}^{n \times n}$ 。

1. 若当 $i > j$ 时恒有 $a_{ij} = 0$, 则称 A 为上三角矩阵;
2. 若当 $i < j$ 时恒有 $a_{ij} = 0$, 则称 A 为下三角矩阵;
3. 若 A 可以写成分块形式

$$A = \begin{pmatrix} B & C \\ 0 & D \end{pmatrix} \quad \text{或} \quad A = \begin{pmatrix} B & 0 \\ C & D \end{pmatrix},$$

其中 B, D 都是方阵, 则称 A 为块上三角矩阵或块下三角矩阵, 统称块三角矩阵。

Proposition 1.7.8.

若 A 是三角矩阵, 则

$$\det A = \prod_{i=1}^n a_{ii}.$$

Proof. 先证上三角情形。按行列式的 Leibniz 展开式,

$$\det A = \sum_{\sigma \in S_n} \operatorname{sgn}(\sigma) \prod_{i=1}^n a_{i, \sigma(i)}.$$

若某个排列 σ 不是恒等排列, 则存在某个 i 使得 $\sigma(i) < i$ 。这是因为若对所有 i 都有 $\sigma(i) \geq i$, 则两边求和得

$$\sum_{i=1}^n \sigma(i) \geq \sum_{i=1}^n i,$$

而排列 σ 恰好是 $\{1, \dots, n\}$ 的重排, 故等号只能处处成立, 即 $\sigma(i) = i$ 。

因此对任何非恒等排列 σ , 都存在 i 使 $\sigma(i) < i$, 于是上三角矩阵满足

$$a_{i, \sigma(i)} = 0.$$

1.7. 行列式的进一步性质

故该排列对应项为零, 只有恒等排列 $\sigma = \text{id}$ 对应项保留下来, 于是

$$\det A = a_{11}a_{22} \cdots a_{nn}.$$

下三角情形同理。

Proposition 1.7.9.

若

$$A = \begin{pmatrix} B & C \\ 0 & D \end{pmatrix}$$

是块上三角矩阵, 其中 $B \in \mathbb{R}^{m \times m}$, $D \in \mathbb{R}^{(n-m) \times (n-m)}$, 则

$$\det A = \det B \cdot \det D.$$

块下三角矩阵同理。

Proof. 将 A 看作按两组指标分块后的矩阵。对行列式作 Leibniz 展开。若某一项对应的排列把后一块的某一行选到了前一块的某一列, 则必然会从左下角零块中取到某个元素, 故该项为零。

因此只有那些保持前 m 个行指标仍对应前 m 个列指标、后 $n-m$ 个行指标仍对应后 $n-m$ 个列指标的排列才可能贡献非零项。这样的排列恰好分解为前一块上的一个排列与后一块上的一个排列, 所以

$$\det A = \det B \cdot \det D.$$

Example 1.7.1.

设

$$A = \begin{pmatrix} 1 & 2 & 3 & 4 \\ 0 & 5 & 6 & 7 \\ 0 & 0 & 8 & 9 \\ 0 & 0 & 1 & 2 \end{pmatrix} = \begin{pmatrix} B & C \\ 0 & D \end{pmatrix},$$

其中

$$B = \begin{pmatrix} 1 & 2 \\ 0 & 5 \end{pmatrix}, \quad D = \begin{pmatrix} 8 & 9 \\ 1 & 2 \end{pmatrix}.$$

则

$$\det A = \det B \det D = (1 \cdot 5)(8 \cdot 2 - 9 \cdot 1) = 5 \cdot 7 = 35.$$

1.7.4 正交矩阵

Definition 1.7.5.

设 $P \in \mathbb{R}^{n \times n}$. 若

$$P^{\top} P = P P^{\top} = I,$$

则称 P 为正交矩阵。

Proposition 1.7.10.

矩阵 P 正交, 当且仅当它的列向量两两正交且都具有单位长度。

Proof. 设

$$P = [p_1 \ p_2 \ \cdots \ p_n],$$

其中 p_j 是第 j 列向量。则

$$P^{\top} P = \begin{pmatrix} p_1^{\top} p_1 & p_1^{\top} p_2 & \cdots & p_1^{\top} p_n \\ p_2^{\top} p_1 & p_2^{\top} p_2 & \cdots & p_2^{\top} p_n \\ \vdots & \vdots & \ddots & \vdots \\ p_n^{\top} p_1 & p_n^{\top} p_2 & \cdots & p_n^{\top} p_n \end{pmatrix}.$$

因此

$$P^{\top} P = I$$

当且仅当

$$p_i^{\top} p_j = \begin{cases} 1, & i = j, \\ 0, & i \neq j. \end{cases}$$

这正表示列向量两两正交且范数为 1。 ■

Proposition 1.7.11.

若 P 为正交矩阵, 则

$$P^{-1} = P^{\top}.$$

Proof. 由定义

$$P^{\top} P = P P^{\top} = I,$$

故 $P^{\top}$ 就是 P 的逆矩阵。 ■

Proposition 1.7.12.

若 P 为正交矩阵, 则它保持内积与范数不变, 即对任意 $x, y \in \mathbb{R}^n$,

$$\langle Px, Py \rangle = \langle x, y \rangle, \quad \|Px\| = \|x\|.$$

1.8. 伴随矩阵与克莱姆法则

Proof. 由转置运算,

$$\langle Px, Py \rangle = (Px)^\top (Py) = x^\top P^\top Py = x^\top y = \langle x, y \rangle.$$

取 $x = y$ 即得

$$\|Px\|^2 = \langle Px, Px \rangle = \langle x, x \rangle = \|x\|^2.$$

故

$$\|Px\| = \|x\|.$$

Proposition 1.7.13.

若 P 为正交矩阵, 则

$$\det P = \pm 1.$$

Proof. 对关系

$$P^\top P = I$$

取行列式, 得

$$\det(P^\top P) = \det I = 1.$$

又因为

$$\det(P^\top) = \det P,$$

故

$$(\det P)^2 = 1.$$

于是

$$\det P = \pm 1.$$

Sec 1.8 伴随矩阵与克莱姆法则

1.8.1 代数余子式与伴随矩阵

设 $A = (a_{ij}) \in \mathbb{R}^{n \times n}$. 删去第 i 行第 j 列后所得的 $(n-1) \times (n-1)$ 子矩阵的行列式记为 M_{ij} , 称为 (i, j) 余子式. 定义 **代数余子式**

$$C_{ij} := (-1)^{i+j} M_{ij}.$$

由这些代数余子式组成的矩阵

$$C = (C_{ij})$$

称为余子式矩阵, 而它的转置

$$\text{adj}(A) := C^\top$$

称为 A 的**伴随矩阵**.

Theorem 1.8.4.

对任意方阵 A , 都有

$$A \operatorname{adj}(A) = \operatorname{adj}(A) A = (\det A)I.$$

Proof. 证明第一式。记

$$B = A \operatorname{adj}(A), \quad B = (b_{ij}).$$

则

$$b_{ij} = \sum_{k=1}^n a_{ik} C_{jk}.$$

当 $i = j$ 时, 这正是按第 i 行展开 $\det A$ 的公式, 因此

$$b_{ii} = \det A.$$

当 $i \neq j$ 时, 考虑把矩阵 A 的第 j 行替换为第 i 行所得到的新矩阵 $\tilde{A}$ 。因为 $\tilde{A}$ 有两行相同, 所以

$$\det \tilde{A} = 0.$$

但按 $\tilde{A}$ 的第 j 行展开, 其代数余子式与原矩阵 A 的第 j 行代数余子式相同, 因此

$$0 = \det \tilde{A} = \sum_{k=1}^n a_{ik} C_{jk} = b_{ij}.$$

故

$$b_{ij} = \begin{cases} \det A, & i = j, \\ 0, & i \neq j. \end{cases}$$

于是

$$A \operatorname{adj}(A) = (\det A)I.$$

另一式同理可证。■

Corollary 1.8.1.

若 $\det A \neq 0$, 则

$$A^{-1} = \frac{1}{\det A} \operatorname{adj}(A).$$

Proof. 由

$$A \operatorname{adj}(A) = (\det A)I$$

两边同除以 $\det A$ 即得。■

1.8.2 克莱姆法则

考虑线性方程组

$$Ax = b,$$

1.8. 伴随矩阵与克莱姆法则

其中

$$A \in \mathbb{R}^{n \times n}, \quad x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}, \quad b = \begin{pmatrix} b_1 \\ \vdots \\ b_n \end{pmatrix}.$$

设 $\det A \neq 0$ 。对每个 $j = 1, \dots, n$, 记 A_j 为将 A 的第 j 列替换为向量 b 后得到的矩阵:

$$A_j = \begin{pmatrix} a_{11} & \cdots & a_{1,j-1} & b_1 & a_{1,j+1} & \cdots & a_{1n} \\ a_{21} & \cdots & a_{2,j-1} & b_2 & a_{2,j+1} & \cdots & a_{2n} \\ \vdots & & \vdots & \vdots & \vdots & & \vdots \\ a_{n1} & \cdots & a_{n,j-1} & b_n & a_{n,j+1} & \cdots & a_{nn} \end{pmatrix}.$$

Theorem 1.8.5.

克莱姆法则 若 $\det A \neq 0$, 则方程组 $Ax = b$ 的唯一解满足

$$x_j = \frac{\det A_j}{\det A}, \quad j = 1, \dots, n.$$

Proof. 由 $Ax = b$ 且 A 可逆,

$$x = A^{-1}b = \frac{1}{\det A} \operatorname{adj}(A)b.$$

于是第 j 个分量为

$$x_j = \frac{1}{\det A} \sum_{i=1}^n (\operatorname{adj}(A))_{ji} b_i = \frac{1}{\det A} \sum_{i=1}^n C_{ij} b_i.$$

另一方面, 按第 j 列展开 $\det A_j$, 因为第 j 列正是 b , 所以

$$\det A_j = \sum_{i=1}^n b_i C_{ij}.$$

因此

$$x_j = \frac{\det A_j}{\det A}.$$

Example 1.8.2.

求解方程组

$$\begin{cases} 2x + y = 5, \\ x + 3y = 7. \end{cases}$$

对应矩阵

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}, \quad b = \begin{pmatrix} 5 \\ 7 \end{pmatrix}.$$

先算

$$\det A = 2 \cdot 3 - 1 \cdot 1 = 5.$$

再算

$$A_1 = \begin{pmatrix} 5 & 1 \\ 7 & 3 \end{pmatrix}, \quad \det A_1 = 15 - 7 = 8,$$

$$A_2 = \begin{pmatrix} 2 & 5 \\ 1 & 7 \end{pmatrix}, \quad \det A_2 = 14 - 5 = 9.$$

故

$$x = \frac{\det A_1}{\det A} = \frac{8}{5}, \quad y = \frac{\det A_2}{\det A} = \frac{9}{5}.$$

Remark. *Cramer's Rule* 的二维直观：若把矩阵

$$A = [a_1 \ a_2]$$

看成由两列向量张成的平行四边形，则方程

$$Ax = b$$


就是把向量 b 表示成

$$b = x_1 a_1 + x_2 a_2.$$

在二维里，行列式的绝对值表示有向面积（*signed area*）的绝对值，因此

$$x_1 = \frac{\det[b \ a_2]}{\det[a_1 \ a_2]}, \quad x_2 = \frac{\det[a_1 \ b]}{\det[a_1 \ a_2]}.$$

这说明：*Cramer's Rule* 的分子就是“用 b 替换相应列后形成的新面积”，分母则是原来的基



From Nelsen (2000).

图 1.2: Cramer's Rule 的面积直观：替换列向量相当于替换相应的有向面积

准面积。

Sec 1.9 对称矩阵的正定性

给定对称矩阵 $A \in \mathbb{R}^{n \times n}$, 定义二次型

$$Q(x) = x^{\top} A x.$$

1.9.1 半正定、正定、负定

Definition 1.9.6.

设 $A \in \mathbb{R}^{n \times n}$ 为实对称矩阵。

1. 若对任意 $x \in \mathbb{R}^n$, 都有

$$x^{\top} A x \geq 0,$$

则称 A 为**正半定矩阵**;

2. 若对任意非零向量 $x \neq 0$, 都有

$$x^{\top} A x > 0,$$

则称 A 为**正定矩阵**;

3. 若对任意非零向量 $x \neq 0$, 都有

$$x^{\top} A x < 0,$$

则称 A 为**负定矩阵**;

4. 若对任意 x , 都有

$$x^{\top} A x \leq 0,$$

则称 A 为**负半定矩阵**。

Definition 1.9.7.

对实对称矩阵 A, B , 若 $A - B$ 正半定, 则记

$$A \geq B.$$

这在对称矩阵空间上定义了一个偏序关系。

1.9.2 利用正交对角化理解正定性

Theorem 1.9.6.

设 A 为实对称矩阵, 则存在正交矩阵 P 使

$$P^{\top}AP = \text{diag}(\lambda_1, \dots, \lambda_n),$$

其中 $\lambda_1, \dots, \lambda_n$ 是 A 的实特征值。

Proposition 1.9.14.

设 A 为实对称矩阵, 其特征值为 $\lambda_1, \dots, \lambda_n$ 。则

1. A 正定, 当且仅当所有特征值都严格大于零;
2. A 负定, 当且仅当所有特征值都严格小于零;
3. A 正半定, 当且仅当所有特征值都不小于零;
4. A 负半定, 当且仅当所有特征值都不大于零。

Proof. 由正交对角化, 存在正交矩阵 P 使

$$P^{\top}AP = \Lambda := \text{diag}(\lambda_1, \dots, \lambda_n).$$

对任意 $x \in \mathbb{R}^n$, 令

$$y = P^{\top}x.$$

由于 P 可逆, $x \neq 0$ 当且仅当 $y \neq 0$ 。于是

$$x^{\top}Ax = x^{\top}P\Lambda P^{\top}x = y^{\top}\Lambda y = \sum_{i=1}^n \lambda_i y_i^2.$$

若所有 $\lambda_i > 0$, 则对任意 $y \neq 0$,

$$\sum_{i=1}^n \lambda_i y_i^2 > 0,$$

故 A 正定。

反之, 若 A 正定, 取 $y = e_i$, 则

$$e_i^{\top}\Lambda e_i = \lambda_i > 0.$$

故所有特征值都正。其余情形同理。 ■

Example 1.9.3.

设

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

则其特征多项式为

$$\det(\lambda I - A) = \det \begin{pmatrix} \lambda - 2 & -1 \\ -1 & \lambda - 2 \end{pmatrix} = (\lambda - 2)^2 - 1 = (\lambda - 1)(\lambda - 3).$$

故特征值为 1, 3, 均为正, 因此 A 正定。

Sec 1.10 主子式与 Sylvester 判别法

1.10.1 主子式与顺序主子式

Definition 1.10.8.

设 $A = (a_{ij}) \in \mathbb{R}^{n \times n}$ 。

1. 任取指标集合

$$I = \{i_1, \dots, i_k\} \subset \{1, \dots, n\},$$

用这些相同的行指标与列指标取出的 $k \times k$ 子矩阵

$$A[I] := A[i_1, \dots, i_k; i_1, \dots, i_k]$$

的行列式

$$\det A[I]$$

称为 A 的一个主子式;

2. 特别地, 若

$$I = \{1, 2, \dots, k\},$$

则

$$\Delta_k := \det A_k, \quad A_k = \begin{pmatrix} a_{11} & \cdots & a_{1k} \\ \vdots & \ddots & \vdots \\ a_{k1} & \cdots & a_{kk} \end{pmatrix}$$

称为第 k 个顺序主子式或前导主子式。

例如对

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix},$$

前三个顺序主子式分别为

$$\begin{aligned} \Delta_1 &= a_{11}, \\ \Delta_2 &= \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21}, \end{aligned}$$

$$\Delta_3 = \det A.$$

1.10.2 正定矩阵的必要条件

Proposition 1.10.15.

若实对称矩阵 A 正定, 则它的所有顺序主子式都为正, 即

$$\Delta_k > 0, \quad k = 1, \dots, n.$$

Proof. 固定 k , 考虑左上角 $k \times k$ 主子矩阵 A_k 。对任意非零向量 $y \in \mathbb{R}^k$, 构造

$$x = \begin{pmatrix} y \\ 0 \end{pmatrix} \in \mathbb{R}^n.$$

由于 $x \neq 0$ 且 A 正定,

$$0 < x^\top A x = y^\top A_k y.$$

故 A_k 也是正定矩阵。于是 $\det A_k > 0$ 。因此

$$\Delta_k > 0.$$

1.10.3 Sylvester 判别法

Theorem 1.10.7.

Sylvester 判别法 设 A 为实对称矩阵, 则

1. A 正定, 当且仅当

$$\Delta_1 > 0, \Delta_2 > 0, \dots, \Delta_n > 0;$$

2. A 负定, 当且仅当

$$\Delta_1 < 0, \Delta_2 > 0, \Delta_3 < 0, \dots,$$

即

$$(-1)^k \Delta_k > 0, \quad k = 1, \dots, n.$$

Proof. 先证正定情形。

必要性已由上题证明。下面证充分性。对维数 n 用归纳法。

当 $n = 1$ 时显然成立。

设结论对 $n - 1$ 维成立。现设 $A \in \mathbb{R}^{n \times n}$ 为实对称矩阵, 且

$$\Delta_k > 0, \quad k = 1, \dots, n.$$

将 A 分块写为

$$A = \begin{pmatrix} A_{n-1} & b \\ b^\top & c \end{pmatrix},$$

1.10. 主子式与 SYLVESTER 判别法

其中 A_{n-1} 是左上角 $(n-1) \times (n-1)$ 主子矩阵。由于

$$\Delta_k > 0, \quad k = 1, \dots, n-1,$$

由归纳假设, A_{n-1} 正定, 从而可逆。

对任意

$$x = \begin{pmatrix} y \\ t \end{pmatrix} \in \mathbb{R}^n,$$

有

$$x^\top A x = y^\top A_{n-1} y + 2t b^\top y + ct^2.$$

由于 A_{n-1} 可逆, 可配方为

$$x^\top A x = (y + t A_{n-1}^{-1} b)^\top A_{n-1} (y + t A_{n-1}^{-1} b) + t^2 (c - b^\top A_{n-1}^{-1} b).$$

因此只需证明

$$c - b^\top A_{n-1}^{-1} b > 0.$$

由分块行列式公式,

$$\det A = \det A_{n-1} (c - b^\top A_{n-1}^{-1} b).$$

即

$$\Delta_n = \Delta_{n-1} (c - b^\top A_{n-1}^{-1} b).$$

因为 $\Delta_n > 0$ 且 $\Delta_{n-1} > 0$, 得

$$c - b^\top A_{n-1}^{-1} b > 0.$$

于是当 $x \neq 0$ 时, 上式右端严格大于零, 因此 A 正定。

负定情形只需注意

$$A \text{ 负定} \iff -A \text{ 正定}.$$

而 $-A$ 的第 k 个顺序主子式为

$$(-1)^k \Delta_k.$$

由正定判别法立即得到

$$(-1)^k \Delta_k > 0.$$

Example 1.10.4.

设

$$A = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 3 & 1 \\ 0 & 1 & 2 \end{pmatrix}.$$

计算顺序主子式:

$$\begin{aligned} \Delta_1 &= 2 > 0, \\ \Delta_2 &= \begin{vmatrix} 2 & 1 \\ 1 & 3 \end{vmatrix} = 6 - 1 = 5 > 0, \end{aligned}$$

$$\Delta_3 = \det A = 2 \begin{vmatrix} 3 & 1 \\ 1 & 2 \end{vmatrix} - 1 \begin{vmatrix} 1 & 1 \\ 0 & 2 \end{vmatrix} = 2(6 - 1) - 2 = 8 > 0.$$

因此由 Sylvester 判别法, A 正定。

1.10.4 二维与三维情形的快速判别

对

$$A = \begin{pmatrix} a & b \\ b & c \end{pmatrix}$$

这样的 2×2 实对称矩阵, 正定当且仅当

$$a > 0, \quad ac - b^2 > 0.$$

负定当且仅当

$$a < 0, \quad ac - b^2 > 0.$$

对

$$A = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{12} & a_{22} & a_{23} \\ a_{13} & a_{23} & a_{33} \end{pmatrix},$$

正定当且仅当

$$a_{11} > 0, \quad \begin{vmatrix} a_{11} & a_{12} \\ a_{12} & a_{22} \end{vmatrix} > 0, \quad \det A > 0.$$

Sec 1.11 与优化理论的联系

若 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 为二次连续可微函数, 则 Hessian 矩阵

$$H(x) = \nabla^2 f(x)$$

是实对称矩阵。因此在驻点 x^* 处:

1. 若 $H(x^*)$ 正定, 则 x^* 为严格局部极小点;
2. 若 $H(x^*)$ 负定, 则 x^* 为严格局部极大点;
3. 若 $H(x^*)$ 不定, 则 x^* 为鞍点。

因此, 顺序主子式判别法在经济学优化里最常见的形式就是:

$$\begin{aligned} \Delta_1 > 0, \Delta_2 > 0, \dots, \Delta_n > 0 &\implies \text{极小;} \\ (-1)^k \Delta_k > 0 \ (k = 1, \dots, n) &\implies \text{极大.} \end{aligned}$$

Sec 1.12 特征值、特征向量与对角化

1.12.1 定义

Definition 1.12.9.

设 $A \in \mathbb{R}^{n \times n}$. 若存在非零向量 $v \neq 0$ 与标量 λ 使

$$Av = \lambda v,$$

则称 λ 为 A 的**特征值**, v 为对应的**特征向量**.

1.12.2 特征值的求法

由

$$Av = \lambda v$$

可化为

$$(A - \lambda I)v = 0.$$

因 $v \neq 0$, 齐次线性方程组有非零解, 故

$$\det(A - \lambda I) = 0.$$

这个方程称为**特征方程**, 其左端是 λ 的 n 次多项式, 称为**特征多项式**.

Example 1.12.5.

设

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

则

$$\det(A - \lambda I) = \det \begin{pmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{pmatrix} = (2 - \lambda)^2 - 1.$$

化简得

$$(2 - \lambda)^2 - 1 = \lambda^2 - 4\lambda + 3 = (\lambda - 1)(\lambda - 3).$$

故特征值为

$$\lambda_1 = 1, \quad \lambda_2 = 3.$$

基表示 (Basis representation) 设 $\mathcal{B} = \{v_1, \dots, v_n\}$ 是 $\mathbb{R}^n$ 的一组基. 则任意向量 x 都可以唯一写成

$$x = \xi_1 v_1 + \dots + \xi_n v_n.$$

系数向量

$$[x]_{\mathcal{B}} := \begin{bmatrix} \xi_1 \\ \vdots \\ \xi_n \end{bmatrix}$$

称为 x 在基 $\mathcal{B}$ 下的坐标 (coordinates)。

矩阵表示 (Matrix representation) 若线性映射 $T(x) = Ax$ 的这组基恰好由特征向量组成, 即

$$Av_i = \lambda_i v_i, \quad i = 1, \dots, n,$$

那么对任意

$$x = \xi_1 v_1 + \cdots + \xi_n v_n$$

有

$$Ax = \xi_1 \lambda_1 v_1 + \cdots + \xi_n \lambda_n v_n.$$

也就是说, 在特征向量基下,

$$[Ax]_{\mathcal{B}} = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix} [x]_{\mathcal{B}}.$$

这正是“对角化”的本质: 换一组合适的基以后, 原本复杂的线性变换退化成各坐标方向上的独立伸缩。

1.12.3 对角化

Definition 1.12.10.

若存在可逆矩阵 P 与对角矩阵 D 使

$$A = PDP^{-1},$$

则称 A 可对角化。

Theorem 1.12.8.

若 A 有 n 个线性无关的特征向量 $v_1, \dots, v_n$, 对应特征值 $\lambda_1, \dots, \lambda_n$, 则 A 可对角化。

Proof. 令

$$P = [v_1 \ v_2 \ \cdots \ v_n], \quad D = \text{diag}(\lambda_1, \dots, \lambda_n).$$

由于 $v_1, \dots, v_n$ 线性无关, P 可逆。

另一方面,

$$AP = [Av_1 \ Av_2 \ \cdots \ Av_n] = [\lambda_1 v_1 \ \lambda_2 v_2 \ \cdots \ \lambda_n v_n] = PD.$$

1.12. 特征值、特征向量与对角化

左乘 P^{-1} 得

$$P^{-1}AP = D,$$

等价于

$$A = PDP^{-1}.$$

Theorem 1.12.9.

实对称矩阵一定可以正交对角化, 即存在正交矩阵 Q 使

$$Q^{\top}AQ = \Lambda$$

为对角矩阵。

为什么对角化重要 (Why Diagonalization Matters) 对角矩阵比一般矩阵容易处理得多:

1. 计算矩阵幂时,

$$A = PDP^{-1} \implies A^k = PD^kP^{-1},$$

而 D^k 只需把对角元分别升到 k 次方;

2. 研究线性动态系统

$$x_{t+1} = Ax_t$$

时, 特征值直接控制系统是收敛、发散还是振荡;

3. 在二次型与优化问题中, 对角化把

$$x^{\top}Ax$$

化成若干平方项的和, 因此可以直接读出正定性、负定性和 Hessian 的曲率信息。

这也是为什么特征值与对角化在数理经济学、动态系统和优化理论中如此重要。



Sec 2.1 总览

第二章的主线是：先在 **metric space (度量空间)** 中定义距离、收敛与紧性，再讨论 **continuity (连续性)**、**semi-continuity (半连续性)**、**Lipschitz continuity** 与 **fixed point (不动点)**。按照课件顺序，主要包含：

1. **Metric Spaces**: 度量、开球、闭球、开集与闭集；
2. **Convergence of Sequences**: 收敛、有界、Cauchy、上极限与下极限；
3. **Topological Properties**: 内点、闭包、边界、紧集、聚点与函数极限；
4. **Continuous Functions**: 连续映射、半连续、Lipschitz 连续、压缩映射与介值定理。

这一章为后续最优化理论中的“极值存在性”“连续依赖性”“固定点存在性”等结论提供了基本拓扑语言。

Sec 2.2 度量空间与收敛

2.2.1 度量的定义

Definition 2.2.1.

设 X 为非空集合。映射

$$d: X \times X \rightarrow \mathbb{R}$$

称为 X 上的一个**度量**，若对任意 $x, y, z \in X$,

1. $d(x, y) \geq 0$, 且 $d(x, y) = 0$ 当且仅当 $x = y$;
2. $d(x, y) = d(y, x)$;
3. $d(x, z) \leq d(x, y) + d(y, z)$ 。

称 (X, d) 为**度量空间**。

在 $\mathbb{R}^N$ 中常用度量包括：

$$d_2(x, y) = \|x - y\|_2 = \left(\sum_{i=1}^N |x_i - y_i|^2 \right)^{1/2},$$

$$d_p(x, y) = \left(\sum_{i=1}^N |x_i - y_i|^p \right)^{1/p} \quad (p \geq 1),$$

以及

$$d_{\infty}(x, y) = \max_{1 \leq i \leq N} |x_i - y_i|.$$

2.2.2 序列收敛

Definition 2.2.2.

设 (X, d) 为度量空间, $\{x_k\} \subset X$. 若存在 $x \in X$ 使得对任意 $\varepsilon > 0$, 存在正整数 K , 当 $k \geq K$ 时有

$$d(x_k, x) < \varepsilon,$$

则称 x_k 收敛到 x , 记作

$$x_k \rightarrow x.$$

Proposition 2.2.1.

极限若存在, 则唯一。

Proof. 设 $x_k \rightarrow x$ 且 $x_k \rightarrow y$. 由三角不等式,

$$d(x, y) \leq d(x, x_k) + d(x_k, y).$$

任取 $\varepsilon > 0$. 由 $x_k \rightarrow x$ 与 $x_k \rightarrow y$, 存在 K_1, K_2 , 使得当 $k \geq \max\{K_1, K_2\}$ 时,

$$d(x, x_k) < \frac{\varepsilon}{2}, \quad d(x_k, y) < \frac{\varepsilon}{2}.$$

故

$$d(x, y) < \varepsilon.$$

由于 ε 任意, 故 $d(x, y) = 0$, 于是 $x = y$. ■

2.2.3 有界序列与 Cauchy 序列

Definition 2.2.3.

序列 $\{x_k\} \subset X$ 称为**有界**, 若存在 $x_0 \in X$ 与 $M > 0$ 使

$$d(x_k, x_0) \leq M \quad \forall k.$$

Definition 2.2.4.

序列 $\{x_k\} \subset X$ 称为 **Cauchy 序列**, 若对任意 $\varepsilon > 0$, 存在 N 使得当 $m, n \geq N$ 时,

$$d(x_m, x_n) < \varepsilon.$$

Proposition 2.2.2.

任何收敛序列都是 *Cauchy* 序列。

Proof. 设 $x_k \rightarrow x$ 。任给 $\varepsilon > 0$ ，存在 N 使得当 $k \geq N$ 时

$$d(x_k, x) < \frac{\varepsilon}{2}.$$

于是当 $m, n \geq N$ 时，由三角不等式，

$$d(x_m, x_n) \leq d(x_m, x) + d(x, x_n) < \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon.$$

故 $\{x_k\}$ 为 *Cauchy* 序列。 ■

Definition 2.2.5.

若度量空间中每个 *Cauchy* 序列都收敛于该空间中的某点，则称该空间**完备**。

$\mathbb{R}^N$ 配以欧氏度量是完备的。

2.2.4 例：Cauchy 序列在 $\mathbb{Q}$ 中未必收敛

下面给出一个非常重要的例子，用来说明：**Cauchy 序列是否一定收敛，取决于所在度量空间是否完备**。虽然 $\mathbb{R}$ 是完备的，但 $\mathbb{Q}$ 不是完备的，因此在 $\mathbb{Q}$ 中可能存在 *Cauchy* 序列却没有极限点仍落在 $\mathbb{Q}$ 中。PPT 中给出的例子正是这一现象。

考虑度量空间

$$(\mathbb{Q}, \alpha), \quad \alpha(x, y) = |x - y|.$$

设 $\{F_k\}$ 为 Fibonacci 数列：

$$F_0 = 0, \quad F_1 = 1, \quad F_{k+1} = F_k + F_{k-1} \quad (k \geq 1).$$

定义有理数列

$$a_k := \frac{F_{k+1}}{F_k}, \quad k \geq 1.$$

由于每个 F_k 都是整数，所以每个 a_k 都是有理数，即

$$a_k \in \mathbb{Q}.$$

Proposition 2.2.1. 数列 $\{a_k\}$ 在度量空间 $(\mathbb{Q}, \alpha)$ 中是 *Cauchy* 序列，但它在 $\mathbb{Q}$ 中并不收敛。

Proof. 证明分两步进行。

第一步：证明 $\{a_k\}$ 是 *Cauchy* 序列。

先证明它在 $\mathbb{R}$ 中收敛。由递推关系

$$F_{k+1} = F_k + F_{k-1},$$

两边同除以 F_k , 得

$$a_k = \frac{F_{k+1}}{F_k} = 1 + \frac{F_{k-1}}{F_k} = 1 + \frac{1}{a_{k-1}}.$$

因此若 $a_k \rightarrow L$, 则极限 L 应满足

$$L = 1 + \frac{1}{L}.$$

移项得

$$L^2 - L - 1 = 0.$$

解得

$$L = \frac{1 \pm \sqrt{5}}{2}.$$

由于 $a_k > 0$, 故只能取正根:

$$L = \frac{1 + \sqrt{5}}{2}.$$

这就是黄金分割数。

下面说明 a_k 的确收敛到该极限。注意到前几项为

$$a_1 = 1, \quad a_2 = 2, \quad a_3 = \frac{3}{2}, \quad a_4 = \frac{5}{3}, \quad a_5 = \frac{8}{5}, \dots$$

进一步可验证奇数项子列与偶数项子列分别单调, 并且都被夹在正根

$$\varphi := \frac{1 + \sqrt{5}}{2}$$

附近。更直接地, 也可以利用已知公式

$$\lim_{k \rightarrow \infty} \frac{F_{k+1}}{F_k} = \varphi$$

得到

$$a_k \rightarrow \varphi \quad (k \rightarrow \infty)$$

在 $\mathbb{R}$ 中成立。

由于 $\mathbb{R}$ 是度量空间, 且 “收敛 $\Rightarrow$ Cauchy”, 于是 $\{a_k\}$ 在 $\mathbb{R}$ 中是 Cauchy 序列。又因为 $\mathbb{Q}$ 上使用的是与 $\mathbb{R}$ 相同的距离函数

$$\alpha(x, y) = |x - y|,$$

所以对任意 $\varepsilon > 0$, 存在 N , 使得当 $l, m \geq N$ 时,

$$\alpha(a_l, a_m) = |a_l - a_m| < \varepsilon.$$

因此 $\{a_k\}$ 在 $(\mathbb{Q}, \alpha)$ 中也是 Cauchy 序列。

第二步: 证明 $\{a_k\}$ 在 $\mathbb{Q}$ 中不收敛。

如果 $\{a_k\}$ 在 $\mathbb{Q}$ 中收敛于某个有理数 $q \in \mathbb{Q}$, 由于 $\mathbb{Q} \subset \mathbb{R}$, 它在 $\mathbb{R}$ 中也必收敛于同一个极限 q 。但上面已经说明

$$a_k \rightarrow \varphi = \frac{1 + \sqrt{5}}{2}$$

在 $\mathbb{R}$ 中成立, 因此必须有

$$q = \varphi.$$

这不可能, 因为

$$\varphi = \frac{1 + \sqrt{5}}{2} \notin \mathbb{Q}.$$

矛盾。

故 $\{a_k\}$ 在 $\mathbb{Q}$ 中不是收敛序列。

Example 2.1. 这个例子说明:

1. *Cauchy* 性质是一种“项与项彼此越来越接近”的内部稳定性;
2. 但仅有 *Cauchy* 性质并不能保证极限留在原空间中;
3. “每个 *Cauchy* 序列都收敛”正是完备性的本质;
4. 因而 $\mathbb{Q}$ 不是完备空间, 而 $\mathbb{R}$ 是完备空间。

在后续分析中, 这一点非常关键: 很多极限过程、最优化论证、函数空间讨论, 最终都依赖于所处空间的完备性。

Sec 2.3

实数列与 $\mathbb{R}^N$ 中序列的若干基本性质

2.3.1 实数列极限的代数性质

在 $\mathbb{R}$ 中, 收敛序列满足与一元分析完全一致的四条基本运算法则:

Proposition 2.3.3.

设 $\{x_k\}, \{y_k\} \subset \mathbb{R}$, 且

$$x_k \rightarrow x, \quad y_k \rightarrow y.$$

则成立:

1. $x_k + y_k \rightarrow x + y$;
2. $x_k - y_k \rightarrow x - y$;
3. $x_k y_k \rightarrow xy$;
4. 若 $y \neq 0$, 则 $\frac{x_k}{y_k} \rightarrow \frac{x}{y}$;
5. 若对所有 k 都有 $x_k \geq y_k$, 则 $x \geq y$ 。

Proof. 先证加法。任给 $\varepsilon > 0$, 由

$$x_k \rightarrow x, \quad y_k \rightarrow y,$$

存在 K_1, K_2 , 使得当 $k \geq K_1$ 时

$$|x_k - x| < \frac{\varepsilon}{2},$$

当 $k \geq K_2$ 时

$$|y_k - y| < \frac{\varepsilon}{2}.$$

2.3. 实数列与 $\mathbb{R}^N$ 中序列的若干基本性质

因此当

$$k \geq K := \max\{K_1, K_2\}$$

时, 由三角不等式,

$$|(x_k + y_k) - (x + y)| \leq |x_k - x| + |y_k - y| < \varepsilon.$$

故

$$x_k + y_k \rightarrow x + y.$$

减法完全类似, 因为

$$(x_k - y_k) - (x - y) = (x_k - x) - (y_k - y),$$

故

$$|(x_k - y_k) - (x - y)| \leq |x_k - x| + |y_k - y| \rightarrow 0.$$

再证乘法。将差拆开:

$$\begin{aligned} x_k y_k - xy &= x_k y_k - x y_k + x y_k - xy \\ &= (x_k - x) y_k + x (y_k - y). \end{aligned}$$

于是

$$|x_k y_k - xy| \leq |x_k - x| |y_k| + |x| |y_k - y|.$$

由于收敛序列必有界, $\{y_k\}$ 有界, 故存在常数 $M > 0$ 使

$$|y_k| \leq M.$$

从而

$$|x_k y_k - xy| \leq M |x_k - x| + |x| |y_k - y| \rightarrow 0.$$

故

$$x_k y_k \rightarrow xy.$$

再证除法。由于 $y_k \rightarrow y$ 且 $y \neq 0$, 取

$$\varepsilon_0 = \frac{|y|}{2} > 0.$$

存在 K_0 使得当 $k \geq K_0$ 时

$$|y_k - y| < \frac{|y|}{2}.$$

于是

$$|y_k| \geq |y| - |y_k - y| > \frac{|y|}{2} > 0.$$

故对充分大的 k , 分母不为零, 并且

$$\begin{aligned} \left| \frac{x_k}{y_k} - \frac{x}{y} \right| &= \left| \frac{x_k y - x y_k}{y_k y} \right| \\ &= \left| \frac{(x_k - x)y + x(y - y_k)}{y_k y} \right| \\ &\leq \frac{|y| |x_k - x| + |x| |y_k - y|}{|y_k| |y|}. \end{aligned}$$

由

$$|y_k| \geq \frac{|y|}{2}$$

可得

$$\left| \frac{x_k}{y_k} - \frac{x}{y} \right| \leq \frac{2}{|y|} |x_k - x| + \frac{2|x|}{|y|^2} |y_k - y| \rightarrow 0.$$

故

$$\frac{x_k}{y_k} \rightarrow \frac{x}{y}.$$

最后证不等式保持性。反设

$$x < y.$$

令

$$\varepsilon = \frac{y - x}{3} > 0.$$

由于 $x_k \rightarrow x$ 与 $y_k \rightarrow y$, 存在 K_1, K_2 使得当 $k \geq \max\{K_1, K_2\}$ 时,

$$|x_k - x| < \varepsilon, \quad |y_k - y| < \varepsilon.$$

于是

$$x_k < x + \varepsilon = \frac{2x + y}{3}, \quad y_k > y - \varepsilon = \frac{x + 2y}{3}.$$

由于

$$\frac{2x + y}{3} < \frac{x + 2y}{3},$$

故对充分大的 k 有

$$x_k < y_k,$$

这与 $x_k \geq y_k$ 对所有 k 成立矛盾。因此必有

$$x \geq y.$$



2.3.2 收敛序列必有界

一个非常常用的基本命题：**任何收敛序列都是有界序列**。这在后面证明乘法极限、紧性、Bolzano–Weierstrass 定理时都会反复使用。

Proposition 2.3.4.

设 $\{x_k\} \subset \mathbb{R}^N$, 若

$$x_k \rightarrow x,$$

则 $\{x_k\}$ 必有界。

Proof. 由收敛定义, 取 $\varepsilon = 1$, 则存在正整数 K , 使得当 $k \geq K$ 时,

$$\|x_k - x\| < 1.$$

2.3. 实数列与 $\mathbb{R}^N$ 中序列的若干基本性质

于是由三角不等式,

$$\|x_k\| \leq \|x_k - x\| + \|x\| < 1 + \|x\| \quad (k \geq K).$$

因此对所有充分大的 k , $\|x_k\|$ 都被 $\|x\| + 1$ 控制。

再令

$$b := \max\{\|x_1\|, \|x_2\|, \dots, \|x_{K-1}\|, \|x\| + 1\}.$$

则对任意 $k \in \mathbb{N}$ 都有

$$\|x_k\| \leq b.$$

故 $\{x_k\}$ 有界。

2.3.3 子列与子列极限

Definition 2.3.6.

设 $\{x_k\}_{k=1}^\infty$ 是一个序列。若存在严格递增的正整数序列

$$k_1 < k_2 < \dots < k_\ell < \dots,$$

则序列

$$\{x_{k_\ell}\}_{\ell=1}^\infty$$

称为原序列 $\{x_k\}$ 的一个子列。

Proposition 2.3.5.

若

$$x_k \rightarrow x,$$

且 $\{x_{k_\ell}\}$ 是 $\{x_k\}$ 的任意一个子列, 则

$$x_{k_\ell} \rightarrow x.$$

换言之, 收敛序列的任意子列都收敛到同一个极限。

Proof. 任给 $\varepsilon > 0$ 。由于

$$x_k \rightarrow x,$$

存在 K 使得当 $k \geq K$ 时,

$$d(x_k, x) < \varepsilon.$$

另一方面, 由于

$$k_1 < k_2 < \dots < k_\ell < \dots,$$

故

$$k_\ell \rightarrow \infty \quad (\ell \rightarrow \infty).$$

因此存在 ℓ_0 , 使得当 $\ell \geq \ell_0$ 时,

$$k_\ell \geq K.$$

于是对所有 $\ell \geq \ell_0$,

$$d(x_{k_\ell}, x) < \varepsilon.$$

故

$$x_{k_\ell} \rightarrow x.$$

这个命题的逆命题一般不成立: 一个序列的某个子列收敛, 并不能推出原序列收敛。但它对紧性理论极其重要, 因为紧性的定义正是“任意序列都有收敛子列”。

2.3.4 上极限与下极限

Definition 2.3.7.

设 $\{x_k\} \subset \mathbb{R}$ 为实数列。对每个 $l \in \mathbb{N}$, 定义尾集

$$\{x_k : k \geq l\}.$$

再定义

$$\alpha_l := \sup_{k \geq l} x_k, \quad \beta_l := \inf_{k \geq l} x_k.$$

则称

$$\limsup_{k \rightarrow \infty} x_k := \lim_{l \rightarrow \infty} \alpha_l, \quad \liminf_{k \rightarrow \infty} x_k := \lim_{l \rightarrow \infty} \beta_l$$

分别为数列 $\{x_k\}$ 的上极限与下极限。

Proposition 2.3.6.

序列 $\{\alpha_l\}$ 单调不增, 序列 $\{\beta_l\}$ 单调不减。

Proof. 因为当 l 增大时, 尾集

$$\{x_k : k \geq l+1\}$$

是

$$\{x_k : k \geq l\}$$

的子集, 所以其上确界不会增大, 即

$$\alpha_{l+1} \leq \alpha_l.$$

故 $\{\alpha_l\}$ 单调不增。

同理, 由于尾集缩小, 下确界不会减小, 因此

$$\beta_{l+1} \geq \beta_l.$$

故 $\{\beta_l\}$ 单调不减。

Proposition 2.3.7.

总有

$$\liminf_{k \rightarrow \infty} x_k \leq \limsup_{k \rightarrow \infty} x_k.$$

并且当且仅当两者相等时, 原序列收敛; 若

$$\liminf_{k \rightarrow \infty} x_k = \limsup_{k \rightarrow \infty} x_k = L,$$

则

$$x_k \rightarrow L.$$

Proof. 对每个 l , 由上确界与下确界定义显然有

$$\beta_l \leq x_k \leq \alpha_l \quad \forall k \geq l,$$

从而

$$\beta_l \leq \alpha_l.$$

令 $l \rightarrow \infty$ 即得

$$\liminf_{k \rightarrow \infty} x_k \leq \limsup_{k \rightarrow \infty} x_k.$$

若

$$\liminf_{k \rightarrow \infty} x_k = \limsup_{k \rightarrow \infty} x_k = L,$$

则对任意 $\varepsilon > 0$, 存在 L_0 , 使得当 $l \geq L_0$ 时,

$$L - \varepsilon < \beta_l \leq \alpha_l < L + \varepsilon.$$

于是对任意 $k \geq l \geq L_0$,

$$L - \varepsilon < \beta_l \leq x_k \leq \alpha_l < L + \varepsilon,$$

故

$$|x_k - L| < \varepsilon.$$

因此

$$x_k \rightarrow L.$$

反过来, 若 $x_k \rightarrow L$, 则任何尾集的上确界与下确界都趋于 L , 故

$$\limsup_{k \rightarrow \infty} x_k = \liminf_{k \rightarrow \infty} x_k = L.$$

Example 2.3.1.

设

$$x_k = (-1)^k.$$

则尾集始终包含 1 与 -1, 所以

$$\alpha_l = \sup_{k \geq l} x_k = 1, \quad \beta_l = \inf_{k \geq l} x_k = -1.$$

因此

$$\limsup_{k \rightarrow \infty} x_k = 1, \quad \liminf_{k \rightarrow \infty} x_k = -1.$$

由于二者不相等, 故该序列不收敛。

Sec 2.4 开集、闭集与邻域

2.4.1 开球与闭球

对 $x \in X$ 、 $r > 0$, 定义开球

$$B_r(x) := \{y \in X : d(x, y) < r\},$$

闭球

$$\overline{B}_r(x) := \{y \in X : d(x, y) \leq r\}.$$

2.4.2 开集与闭集

Definition 2.4.8.

集合 $U \subset X$ 称为**开集**, 若对任意 $x \in U$, 存在 $r > 0$ 使

$$B_r(x) \subset U.$$

集合 $F \subset X$ 称为**闭集**, 若其补集 $X \setminus F$ 是开集。

Proposition 2.4.8.

任意个开集的并仍为开集; 有限个开集的交仍为开集。

Proof. 先证并。设 $\{U_\alpha\}_{\alpha \in I}$ 都是开集, 记

$$U := \bigcup_{\alpha \in I} U_\alpha.$$

任取 $x \in U$, 则存在某个 α_0 使 $x \in U_{\alpha_0}$ 。由于 U_{α_0} 开, 存在 $r > 0$ 使

$$B_r(x) \subset U_{\alpha_0} \subset U.$$

故 U 开。

2.5. 内点、闭包与边界

再证有限交。设 $U_1, \dots, U_m$ 开, 取

$$x \in \bigcap_{j=1}^m U_j.$$

则对每个 j , 存在 $r_j > 0$ 使

$$B_{r_j}(x) \subset U_j.$$

令

$$r := \min\{r_1, \dots, r_m\} > 0,$$

则

$$B_r(x) \subset \bigcap_{j=1}^m U_j.$$

故有限交仍开。 ■

Proposition 2.4.9.

任意个闭集之交仍为闭集; 有限个闭集的并仍为闭集。

Proof. 由补集运算和 De Morgan 律立即得到:

$$X \setminus \left(\bigcap_{\alpha} F_{\alpha} \right) = \bigcup_{\alpha} (X \setminus F_{\alpha}),$$

$$X \setminus \left(\bigcup_{j=1}^m F_j \right) = \bigcap_{j=1}^m (X \setminus F_j).$$

右侧分别是开集的并与有限交, 故结论成立。 ■

Sec 2.5 内点、闭包与边界

Definition 2.5.9.

设 $A \subset X$ 。

1. 若存在 $r > 0$ 使 $B_r(x) \subset A$, 则称 x 为 A 的**内点**。
2. 若对任意 $r > 0$, 都有 $B_r(x) \cap A \neq \emptyset$, 则称 x 属于 A 的**闭包**, 记作 $\bar{A}$ 。
3. 定义 A 的**边界**

$$\partial A := \bar{A} \setminus \text{int}(A).$$

Proposition 2.5.10.

集合 $F \subset X$ 闭, 当且仅当它包含自身所有极限点; 等价地,

$$F = \bar{F}.$$

Proof. 先设 F 闭。要证 $\overline{F} \subset F$ 。若 $x \notin F$, 因 F^c 开, 存在 $r > 0$ 使

$$B_r(x) \subset F^c.$$

于是 $B_r(x) \cap F = \emptyset$, 故 $x \notin \overline{F}$ 。这说明 $\overline{F} \subset F$ 。而显然 $F \subset \overline{F}$, 故

$$F = \overline{F}.$$

反过来, 若 $F = \overline{F}$, 则

$$X \setminus F = X \setminus \overline{F}.$$

任取 $x \in X \setminus F$, 由 $x \notin \overline{F}$ 可知存在 $r > 0$ 使

$$B_r(x) \cap F = \emptyset,$$

即

$$B_r(x) \subset X \setminus F.$$

故 $X \setminus F$ 开, 因而 F 闭。 ■

Sec 2.6 紧集与 Heine-Borel 定理

2.6.1 紧性的序列定义

Definition 2.6.10.

集合 $K \subset \mathbb{R}^N$ 称为**紧集**, 若对任意序列 $\{x_k\} \subset K$, 都存在子序列 $\{x_{k_\ell}\}$ 与某个 $x \in K$, 使

$$x_{k_\ell} \rightarrow x.$$

2.6.2 紧集的基本性质

Proposition 2.6.11.

紧集必有界。

Proof. 反证。若 K 不有界, 则对每个正整数 m , 存在 $x_m \in K$ 使

$$\|x_m\| > m.$$

于是任意子序列 $\{x_{m_\ell}\}$ 仍满足

$$\|x_{m_\ell}\| > m_\ell \rightarrow \infty,$$

故不可能收敛。这与紧性矛盾。 ■

Proposition 2.6.12.

紧集必闭。

Proof. 设 $\{x_k\} \subset K$ 且 $x_k \rightarrow x$ 。由紧性, $\{x_k\}$ 存在收敛于某个 $y \in K$ 的子序列 $\{x_{k_\ell}\}$ 。但收敛序列的任意子序列仍收敛于同一极限, 因此

$$x_{k_\ell} \rightarrow x.$$

由极限唯一性, $x = y \in K$ 。故 K 闭。 ■

2.6.3 Heine-Borel 定理

Theorem 2.6.1.

Heine-Borel 对 $\mathbb{R}^N$ 中的集合 K , 下列两者等价:

1. K 紧;
2. K 闭且有界。

Proof (证明思路). 已证 $(1) \Rightarrow (2)$ 。

下面说明 $(2) \Rightarrow (1)$ 的思路。若 K 有界, 则存在 $a > 0$ 使

$$K \subset [-a, a]^N.$$

因此任意序列 $\{x_k\} \subset K$ 也是立方体中的有界序列。

当 $N = 1$ 时, $\{x_k\}$ 是区间 $[-a, a]$ 中的有界实数序列, 由实数完备性与单调子列构造, 可抽取收敛子序列。

对一般 N , 写

$$x_k = (x_k^{(1)}, x_k^{(2)}, \dots, x_k^{(N)}).$$

由于第一坐标序列有界, 可抽取子序列使第一坐标收敛; 再从该子序列中抽取子序列使第二坐标收敛; 如此反复, 经对角线过程得到一个子序列, 使所有坐标都收敛, 从而该子序列在 $\mathbb{R}^N$ 中收敛。设其极限为 x 。

由于 K 闭, 极限点 x 仍属于 K 。故任意序列都有收敛到 K 内点的子序列, 即 K 紧。 ■

Sec 2.7 聚点与函数极限

2

2.7.1 聚点

Definition 2.7.11.

设 (X, d) 为度量空间, $E \subset X$ 。若对任意 $\varepsilon > 0$,

$$(B_\varepsilon(\bar{x}) \setminus \{\bar{x}\}) \cap E \neq \emptyset,$$

则称 $\bar{x}$ 为 E 的**聚点** (cluster point)。

这一定义的含义是：无论把 $\bar{x}$ 附近的邻域取得多小，里面总能找到一个属于 E 且不同于 $\bar{x}$ 的点。因此，聚点正是定义函数极限时的自然“逼近位置”。

Example 2.7.2.

若 $E = (0, 1) \subset \mathbb{R}$ ，则区间 $[0, 1]$ 中的每一点都是 E 的聚点。特别地，0 与 1 虽然不属于 E ，但仍是 E 的聚点。

2.7.2 聚点处的函数极限

Definition 2.7.12.

设 (X, d_X) 、 (Y, d_Y) 为度量空间, $E \subset X$ ，映射

$$f: E \rightarrow Y,$$

并设 $\bar{x}$ 是 E 的一个聚点。若存在 $y \in Y$ ，使得对任意 $\varepsilon > 0$ ，存在 $\delta > 0$ ，只要

$$x \in E, \quad 0 < d_X(x, \bar{x}) < \delta,$$

就有

$$d_Y(f(x), y) < \varepsilon,$$

则称 f 在 $\bar{x}$ 处的极限为 y ，记作

$$\lim_{x \rightarrow \bar{x}} f(x) = y.$$

注意这里用的是去心邻域 (punctured neighborhood) 条件

$$0 < d_X(x, \bar{x}) < \delta,$$

因为讨论的是“当 x 靠近 $\bar{x}$ 而不一定等于 $\bar{x}$ 时”的行为。

Theorem 2.7.2.

在上述记号下,

$$\lim_{x \rightarrow \bar{x}} f(x) = y$$

当且仅当对任意满足

$$x_k \in E, \quad x_k \neq \bar{x}, \quad x_k \rightarrow \bar{x}$$

的序列, 都有

$$f(x_k) \rightarrow y.$$

Proof. 先证必要性。设

$$\lim_{x \rightarrow \bar{x}} f(x) = y.$$

任取满足 $x_k \neq \bar{x}$ 且 $x_k \rightarrow \bar{x}$ 的序列。对任意 $\varepsilon > 0$, 由极限定义可取 $\delta > 0$, 使得

$$0 < d_X(x, \bar{x}) < \delta \implies d_Y(f(x), y) < \varepsilon.$$

又由 $x_k \rightarrow \bar{x}$, 存在 K 使得当 $k \geq K$ 时

$$d_X(x_k, \bar{x}) < \delta.$$

由于 $x_k \neq \bar{x}$, 故

$$0 < d_X(x_k, \bar{x}) < \delta,$$

从而

$$d_Y(f(x_k), y) < \varepsilon \quad (k \geq K).$$

故 $f(x_k) \rightarrow y$ 。

再证充分性。反设序列判据成立, 但

$$\lim_{x \rightarrow \bar{x}} f(x) \neq y.$$

则存在某个 $\varepsilon_0 > 0$, 对任意 $n \in \mathbb{N}$ 都可找到 $x_n \in E$ 使

$$0 < d_X(x_n, \bar{x}) < \frac{1}{n}, \quad d_Y(f(x_n), y) \geq \varepsilon_0.$$

于是 $x_n \rightarrow \bar{x}$, 但 $f(x_n)$ 不可能收敛到 y , 与序列判据矛盾。故极限存在且等于 y 。 ■

Proposition 2.7.13.

若函数极限存在, 则极限唯一。

Proof. 若

$$\lim_{x \rightarrow \bar{x}} f(x) = y_1, \quad \lim_{x \rightarrow \bar{x}} f(x) = y_2,$$

则对任意满足 $x_k \neq \bar{x}$ 且 $x_k \rightarrow \bar{x}$ 的序列, 依据上一定理同时有

$$f(x_k) \rightarrow y_1, \quad f(x_k) \rightarrow y_2.$$

由序列极限唯一性, $y_1 = y_2$ 。 ■

2.7.3 极限的基本性质

下面记录实值函数极限最常用的代数性质。它们和实数列极限的对应结论完全平行。

Proposition 2.7.14.

设 $f, g: E \rightarrow \mathbb{R}$, 且 $\bar{x}$ 是 E 的聚点。若

$$\lim_{x \rightarrow \bar{x}} f(x) = \alpha, \quad \lim_{x \rightarrow \bar{x}} g(x) = \beta,$$

则:

1.

$$\lim_{x \rightarrow \bar{x}} (f + g)(x) = \alpha + \beta;$$

2.

$$\lim_{x \rightarrow \bar{x}} (fg)(x) = \alpha\beta;$$

3. 若存在 $r > 0$, 使得对所有满足

$$x \in E, \quad 0 < d_X(x, \bar{x}) < r$$

的点都成立

$$f(x) \geq g(x),$$

则

$$\alpha \geq \beta.$$

Proof. 利用上一小节的序列刻画。任取 $x_k \in E$, $x_k \neq \bar{x}$ 且 $x_k \rightarrow \bar{x}$, 则

$$f(x_k) \rightarrow \alpha, \quad g(x_k) \rightarrow \beta.$$

由实数列极限的代数性质,

$$f(x_k) + g(x_k) \rightarrow \alpha + \beta, \quad f(x_k)g(x_k) \rightarrow \alpha\beta.$$

再用函数极限的序列刻画, 便得前两条。

对于第三条, 由假设知当 k 足够大时有

$$f(x_k) \geq g(x_k).$$

对实数列取极限, 得到

$$\alpha \geq \beta.$$

Sec 2.8

连续函数

2.8.1

连续性的定义

Definition 2.8.13.

设 (X, d_X) 、 (Y, d_Y) 为度量空间, $E \subset X$, $f: E \rightarrow Y$ 。若对某点 $a \in E$, 任给 $\varepsilon > 0$, 存在 $\delta > 0$, 使得当 $x \in E$ 且

$$d_X(x, a) < \delta$$

时有

$$d_Y(f(x), f(a)) < \varepsilon,$$

则称 f 在点 a 连续。

Proposition 2.8.15.

若 a 是 E 的聚点, 则 f 在 a 连续, 当且仅当

$$\lim_{x \rightarrow a} f(x) = f(a).$$

Proof. 由连续性的定义可知: 对任意 $\varepsilon > 0$, 存在 $\delta > 0$, 使得只要

$$x \in E, \quad d_X(x, a) < \delta,$$

便有

$$d_Y(f(x), f(a)) < \varepsilon.$$

把条件加强为

$$0 < d_X(x, a) < \delta$$

当然仍成立, 因此

$$\lim_{x \rightarrow a} f(x) = f(a).$$

反过来, 若极限存在且等于 $f(a)$, 那么对任意 $\varepsilon > 0$, 存在 $\delta > 0$, 使得

$$0 < d_X(x, a) < \delta \implies d_Y(f(x), f(a)) < \varepsilon.$$

而当 $x = a$ 时,

$$d_Y(f(a), f(a)) = 0 < \varepsilon.$$

于是对所有满足 $d_X(x, a) < \delta$ 的 x 都有

$$d_Y(f(x), f(a)) < \varepsilon.$$

故 f 在 a 连续。 ■

Remark. 若 a 不是 E 的聚点, 而是 E 的一个 *isolated point* (孤立点), 则存在 $\delta > 0$ 使

$$B_\delta(a) \cap E = \{a\}.$$

此时连续性条件自动成立, 所以函数在孤立点处总是连续的。

2.8.2 序列刻画

Theorem 2.8.3.

f 在 a 连续, 当且仅当对任意满足 $x_k \rightarrow a$ 的序列 $\{x_k\} \subset E$, 都有

$$f(x_k) \rightarrow f(a).$$

Proof. 先证必要性。设 f 在 a 连续, 且 $x_k \rightarrow a$ 。任给 $\varepsilon > 0$, 由连续性存在 $\delta > 0$, 使得

$$d_X(x, a) < \delta \implies d_Y(f(x), f(a)) < \varepsilon.$$

又由 $x_k \rightarrow a$, 存在 K 使得当 $k \geq K$ 时

$$d_X(x_k, a) < \delta.$$

故当 $k \geq K$ 时,

$$d_Y(f(x_k), f(a)) < \varepsilon,$$

即 $f(x_k) \rightarrow f(a)$ 。

再证充分性。反设 f 在 a 不连续, 则存在 $\varepsilon_0 > 0$, 对任意 $n \in \mathbb{N}$, 总可取 $x_n \in E$ 使

$$d_X(x_n, a) < \frac{1}{n}, \quad d_Y(f(x_n), f(a)) \geq \varepsilon_0.$$

由前一式知 $x_n \rightarrow a$, 但后一式说明 $f(x_n)$ 不可能收敛到 $f(a)$, 矛盾。故 f 在 a 连续。 ■

Theorem 2.8.4.

设

$$f = (f_1, \dots, f_M) : E \subset \mathbb{R}^N \rightarrow \mathbb{R}^M.$$

则 f 在点 $a \in E$ 连续, 当且仅当每个分量函数

$$f_m : E \rightarrow \mathbb{R} \quad (m = 1, \dots, M)$$

都在 a 连续。

Proof. 若 f 在 a 连续, 则投影映射

$$\pi_m(y_1, \dots, y_M) = y_m$$

连续, 于是

$$f_m = \pi_m \circ f$$

在 a 连续。

反过来, 若每个 f_m 都在 a 连续, 则对任意序列 $x_k \rightarrow a$,

$$f_m(x_k) \rightarrow f_m(a) \quad (m = 1, \dots, M).$$

因此

$$f(x_k) = (f_1(x_k), \dots, f_M(x_k)) \rightarrow (f_1(a), \dots, f_M(a)) = f(a).$$

由序列刻画, f 在 a 连续。 ■

Theorem 2.8.5.

设 (X, d_X) 、 (Y, d_Y) 为度量空间, $E \subset X$, $a \in E$. 下列命题等价:

1. $f: E \rightarrow Y$ 在点 a 连续;
2. 对任意包含 $f(a)$ 的开集 $V \subset Y$, 都存在包含 a 的开集 $U \subset X$, 使

$$U \cap E \subset f^{-1}(V);$$

3. 对任意满足 $x_k \rightarrow a$ 的序列 $\{x_k\} \subset E$, 都有

$$f(x_k) \rightarrow f(a).$$

Proof. (1) $\Rightarrow$ (2): 任取包含 $f(a)$ 的开集 V . 由于 V 开, 存在 $\varepsilon > 0$ 使

$$B_\varepsilon(f(a)) \subset V.$$

由连续性, 存在 $\delta > 0$ 使

$$d_X(x, a) < \delta \implies d_Y(f(x), f(a)) < \varepsilon.$$

取

$$U := B_\delta(a),$$

则

$$U \cap E \subset f^{-1}(B_\varepsilon(f(a))) \subset f^{-1}(V).$$

(2) $\Rightarrow$ (1): 任给 $\varepsilon > 0$, 令

$$V := B_\varepsilon(f(a)).$$

由 (2), 存在包含 a 的开集 U 使

$$U \cap E \subset f^{-1}(V).$$

由于 U 开, 存在 $\delta > 0$ 使

$$B_\delta(a) \subset U.$$

于是当 $x \in E$ 且 $d_X(x, a) < \delta$ 时,

$$x \in U \cap E,$$

从而

$$f(x) \in V = B_\varepsilon(f(a)).$$

这正是连续性。

(1) $\Leftrightarrow$ (3) 正是上一小节已经证明过的序列刻画。

2.8.3 紧集上的连续函数

Theorem 2.8.6.

若 $K \subset \mathbb{R}^N$ 紧, 且

$$f: K \rightarrow \mathbb{R}^M$$

连续, 则像集

$$f(K) := \{f(x) : x \in K\}$$

也是紧集。

Proof. 任取序列 $\{y_k\} \subset f(K)$ 。对每个 k , 可取 $x_k \in K$ 使

$$y_k = f(x_k).$$

由于 K 紧, 存在子序列 $\{x_{k_\ell}\}$ 与某个 $x^* \in K$, 使

$$x_{k_\ell} \rightarrow x^*.$$

由连续性,

$$y_{k_\ell} = f(x_{k_\ell}) \rightarrow f(x^*).$$

而

$$f(x^*) \in f(K).$$

因此 $f(K)$ 中任意序列都有收敛到 $f(K)$ 内点的子序列, 故 $f(K)$ 紧。■

Theorem 2.8.7.

Weierstrass 极值定理 若 $K \subset \mathbb{R}^N$ 紧, 且 $f: K \rightarrow \mathbb{R}$ 连续, 则 f 在 K 上有最大值与最小值。

Proof (证明思路). 设

$$M := \sup_{x \in K} f(x).$$

由于上一个定理表明 $f(K) \subset \mathbb{R}$ 紧, 而实数中的紧集必闭且有界, 所以 $f(K)$ 有上确界且上确界仍属于 $f(K)$ 。

因此存在 $x^* \in K$ 使

$$f(x^*) = M.$$

下面给出等价的序列证明, 这种证明方式在优化中非常常用。

可取序列 $\{x_k\} \subset K$ 使

$$f(x_k) \rightarrow M.$$

由 K 紧, 存在子序列 $x_{k_\ell} \rightarrow x^* \in K$ 。由连续性,

$$f(x_{k_\ell}) \rightarrow f(x^*).$$

又因 $f(x_{k_\ell}) \rightarrow M$, 故

$$f(x^*) = M.$$

最大值存在。最小值同理。■

Sec 2.9

半连续函数、Lipschitz 连续与不动点定理

2.9.1 半连续函数

在通常的连续性定义中, 我们要求当 $x_k \rightarrow x$ 时,

$$f(x_k) \rightarrow f(x).$$

半连续性则只保留其中一个方向的不等式, 因此它比连续性弱, 但在最优化中仍足够强, 可以保证极值存在。

Definition 2.9.14.

设

$$f: \mathbb{R}^N \rightarrow [-\infty, \infty].$$

若对任意满足 $x_k \rightarrow x$ 的序列 $\{x_k\}$, 都有

$$f(x) \leq \liminf_{k \rightarrow \infty} f(x_k),$$

则称 f 在点 x 下半连续。

若对任意满足 $x_k \rightarrow x$ 的序列 $\{x_k\}$, 都有

$$f(x) \geq \limsup_{k \rightarrow \infty} f(x_k),$$

则称 f 在点 x 上半连续。

Proposition 2.9.16.

函数 f 上半连续, 当且仅当 $-f$ 下半连续。

Proof. 由定义,

$$f(x) \geq \limsup_{k \rightarrow \infty} f(x_k)$$

当且仅当

$$-f(x) \leq -\limsup_{k \rightarrow \infty} f(x_k).$$

而对任意实数列都有恒等式

$$-\limsup_{k \rightarrow \infty} a_k = \liminf_{k \rightarrow \infty} (-a_k),$$

因此上式等价于

$$-f(x) \leq \liminf_{k \rightarrow \infty} (-f(x_k)).$$

这正是 $-f$ 下半连续的定义。

Proposition 2.9.17.

若 f 在点 x 连续, 则 f 在该点既下半连续又上半连续。

Proof. 若 f 连续, 则对任意 $x_k \rightarrow x$,

$$f(x_k) \rightarrow f(x).$$

于是

$$\liminf_{k \rightarrow \infty} f(x_k) = \limsup_{k \rightarrow \infty} f(x_k) = f(x),$$

从而同时满足

$$f(x) \leq \liminf_{k \rightarrow \infty} f(x_k), \quad f(x) \geq \limsup_{k \rightarrow \infty} f(x_k).$$

故 f 既下半连续又上半连续。 ■

2.9.2 半连续函数在紧集上取极值

连续函数在紧集上一定能取到最大值和最小值。这个结论可以分别推广到上半连续与下半连续函数: 下半连续足以保证最小值存在, 上半连续足以保证最大值存在。

Theorem 2.9.8.

设 $K \subset \mathbb{R}^N$ 为紧集。

1. 若

$$f: K \rightarrow [-\infty, \infty]$$

下半连续, 则 f 在 K 上能取到最小值;

2. 若

$$f: K \rightarrow [-\infty, \infty]$$

上半连续, 则 f 在 K 上能取到最大值。

Proof. 只证第 1 条, 第 2 条可由对 $-f$ 应用第 1 条立即得到。

设

$$m := \inf_{x \in K} f(x).$$

根据下确界定义, 可取一列 $\{x_k\} \subset K$ 使

$$f(x_k) \rightarrow m$$

或至少满足

$$f(x_k) < m + \frac{1}{k}.$$

由于 K 紧, 序列 $\{x_k\}$ 存在收敛子列, 记为

$$x_{k_\ell} \rightarrow x^* \in K.$$

2.9. 半连续函数、LIPSCHITZ 连续与不动点定理

由下半连续性,

$$f(x^*) \leq \liminf_{\ell \rightarrow \infty} f(x_{k_\ell}).$$

而由构造

$$f(x_{k_\ell}) \rightarrow m,$$

故

$$f(x^*) \leq m.$$

另一方面, 由 m 是下确界, 必有

$$m \leq f(x^*).$$

于是

$$f(x^*) = m.$$

因此 f 在 K 上取到最小值。

对于第 2 条, 若 f 上半连续, 则 $-f$ 下半连续。由第 1 条, $-f$ 在 K 上取到最小值, 即存在 $x^* \in K$ 使

$$-f(x^*) = \min_{x \in K} (-f(x)).$$

这等价于

$$f(x^*) = \max_{x \in K} f(x).$$

故上半连续函数在紧集上取到最大值。 ■

2.9.3 Lipschitz 连续

Definition 2.9.15.

设 (X, d) 、 (Y, ρ) 为度量空间, 映射

$$f : X \rightarrow Y$$

称为 **Lipschitz 连续**, 若存在常数 $K \geq 0$, 使得对任意 $x, x' \in X$,

$$\rho(f(x), f(x')) \leq K d(x, x').$$

这样的常数 K 称为 f 的 **Lipschitz 常数**。

Proposition 2.9.18.

Lipschitz 连续函数一定连续。

Proof. 设 f 是 Lipschitz 连续的, 即存在 $K \geq 0$ 使

$$\rho(f(x), f(y)) \leq K d(x, y) \quad \forall x, y \in X.$$

任取 $\bar{x} \in X$ 与 $\varepsilon > 0$ 。

当 $K = 0$ 时, f 为常值函数, 显然连续。

以下设 $K > 0$ 。取

$$\delta := \frac{\varepsilon}{K}.$$

若

$$d(x, \bar{x}) < \delta,$$

则

$$\rho(f(x), f(\bar{x})) \leq K d(x, \bar{x}) < K \delta = \varepsilon.$$

故 f 在 $\bar{x}$ 连续。由于 $\bar{x}$ 任意, f 在 X 上连续。

Proposition 2.9.19.

连续函数未必是 *Lipschitz* 连续函数。

Example 2.2. 函数

$$f(x) = \sqrt{x}, \quad x \in [0, 1]$$

在 $[0, 1]$ 上连续, 但它不是 *Lipschitz* 连续的。

事实上, 若它是 *Lipschitz* 连续的, 则存在 $K > 0$ 使对任意 $x \in [0, 1]$,

$$|\sqrt{x} - \sqrt{0}| \leq K|x - 0|,$$

即

$$\sqrt{x} \leq Kx.$$

对 $x > 0$ 两边同除以 $\sqrt{x}$ 得

$$1 \leq K\sqrt{x}.$$

令 $x \rightarrow 0^+$, 右边趋于 0, 矛盾。因此 $\sqrt{x}$ 不是 *Lipschitz* 连续的。

2.9.4 压缩映射与不动点

Definition 2.9.16.

设 (X, d) 为度量空间, 映射

$$f: X \rightarrow X$$

称为 **压缩映射**, 若存在常数

$$K \in [0, 1)$$

使得对任意 $x, x' \in X$,

$$d(f(x), f(x')) \leq K d(x, x').$$

Definition 2.9.17.

若 $x_0 \in X$ 满足

$$f(x_0) = x_0,$$

则称 x_0 为映射 f 的一个 **不动点**。

Theorem 2.9.9.

压缩映射不动点定理 设 (X, d) 为完备度量空间, 且

$$f: X \rightarrow X$$

是压缩映射, 即存在 $K \in [0, 1)$ 使

$$d(f(x), f(y)) \leq Kd(x, y) \quad \forall x, y \in X.$$

则 f 存在唯一不动点, 即存在唯一的 $x_0 \in X$ 使

$$f(x_0) = x_0.$$

Proof. 任取 $x \in X$, 构造迭代序列

$$x, f(x), f^2(x), \dots, f^k(x), \dots$$

其中

$$f^k(x) = \underbrace{f \circ f \circ \dots \circ f}_{k \text{ 次}}(x).$$

先证这是一个 Cauchy 序列。由压缩性质,

$$d(f^k(x), f^{k+1}(x)) \leq K^k d(x, f(x)).$$

对任意 $m > l$, 由三角不等式,

$$\begin{aligned} d(f^l(x), f^m(x)) &\leq \sum_{k=l}^{m-1} d(f^k(x), f^{k+1}(x)) \\ &\leq \sum_{k=l}^{m-1} K^k d(x, f(x)) \\ &\leq \left(\sum_{k=l}^{\infty} K^k \right) d(x, f(x)) \\ &= \frac{K^l}{1-K} d(x, f(x)). \end{aligned}$$

由于 $0 \leq K < 1$, 所以当 $l \rightarrow \infty$ 时,

$$\frac{K^l}{1-K} d(x, f(x)) \rightarrow 0.$$

故 $\{f^l(x)\}$ 是 Cauchy 序列。

因为 (X, d) 完备, 存在某个 $x_0 \in X$ 使

$$f^l(x) \rightarrow x_0.$$

再证 x_0 是不动点。由于压缩映射必 Lipschitz 连续，从而连续，于是

$$f(x_0) = f\left(\lim_{l \rightarrow \infty} f^l(x)\right) = \lim_{l \rightarrow \infty} f^{l+1}(x) = x_0.$$

故 x_0 是不动点。

最后证唯一性。若 x_0, y_0 都是不动点，则

$$d(x_0, y_0) = d(f(x_0), f(y_0)) \leq K d(x_0, y_0).$$

移项得

$$(1 - K)d(x_0, y_0) \leq 0.$$

由于 $1 - K > 0$ 且距离非负，只能有

$$d(x_0, y_0) = 0,$$

故

$$x_0 = y_0.$$

唯一性得证。 ■

Example 2.3. 考虑映射

$$f(x) = \frac{x+1}{2}, \quad x \in \mathbb{R}.$$

在通常距离

$$d(x, y) = |x - y|$$

下，

$$|f(x) - f(y)| = \left| \frac{x+1}{2} - \frac{y+1}{2} \right| = \frac{1}{2}|x - y|.$$

因此 f 是压缩映射，Lipschitz 常数为

$$K = \frac{1}{2} < 1.$$

由于 $\mathbb{R}$ 是完备度量空间，故 f 有唯一不动点。解方程

$$f(x) = x$$

得

$$\frac{x+1}{2} = x \implies x = 1.$$

因此唯一不动点为

$$x_0 = 1.$$

2.9.5 介值定理

Theorem 2.9.10.

介值定理 设

$$f : D \rightarrow \mathbb{R}$$

连续, 且

$$[a, b] \subset D \subset \mathbb{R}.$$

若 y 介于 $f(a)$ 与 $f(b)$ 之间, 即

$$y \in [\min\{f(a), f(b)\}, \max\{f(a), f(b)\}],$$

则存在

$$c \in [a, b]$$

使得

$$f(c) = y.$$

Proof. 不妨设

$$f(a) \leq y \leq f(b).$$

定义集合

$$A := \{x \in [a, b] : f(x) \leq y\}.$$

由于 $a \in A$, 所以 A 非空; 又 $A \subset [a, b]$, 故它有上确界。记

$$c := \sup A.$$

下面证明 $f(c) = y$ 。

先证 $f(c) \leq y$ 。由于 $c = \sup A$, 存在序列 $\{x_k\} \subset A$ 使

$$x_k \rightarrow c, \quad x_k \leq c.$$

由 $x_k \in A$ 得

$$f(x_k) \leq y.$$

由连续性,

$$f(c) = \lim_{k \rightarrow \infty} f(x_k) \leq y.$$

再证 $f(c) \geq y$ 。反设

$$f(c) < y.$$

由连续性, 存在 $\delta > 0$, 使当

$$|x - c| < \delta$$

时,

$$|f(x) - f(c)| < y - f(c).$$

于是对这样的 x ,

$$f(x) < y.$$

特别地, 取某个

$$x \in (c, \min\{c + \delta, b\}),$$

则有 $f(x) < y$, 故 $x \in A$ 。但这与 c 是 A 的上确界矛盾。因此

$$f(c) \geq y.$$

综上,

$$f(c) \leq y, \quad f(c) \geq y,$$

故

$$f(c) = y.$$

定理得证。■

多元微积分回顾

Part

Sec 3.1 总览与核心思想

第三讲的主线与一元微积分完全一致：linear approximation (线性逼近)。一元情形中，

$$f(x) \approx f(a) + f'(a)(x - a),$$

说明在点 a 附近，非线性函数可以由一个线性函数近似。多元微积分的目标，就是把这一思想推广到

$$f: \mathbb{R}^n \rightarrow \mathbb{R} \quad \text{或更一般地} \quad f: \mathbb{R}^N \rightarrow \mathbb{R}^M$$

的情形。PPT 的结构依次为：Differentiation (可微与导数)、Vector notation and gradient (向量记号与梯度)、Mean-value theorem and Taylor's theorem (中值定理与 Taylor 定理)、Chain rule (链式法则)、Implicit Function Theorem and Inverse Function Theorem (隐函数定理与逆函数定理)。

Sec 3.2 Differentiation: 可微与导数的定义

3.2.1 一般定义：Differentiability in $\mathbb{R}^n$

设 $E \subseteq \mathbb{R}^n$ 为开集 (open set), $f: E \rightarrow \mathbb{R}$ 。我们希望刻画 f 在点 $x \in E$ 附近是否能够被某个线性函数良好逼近。

Definition 3.2.1.

函数 f 在点 $x \in E$ 可微 (differentiable)，如果存在一个向量 $a \in \mathbb{R}^n$ ，使得

$$\lim_{h \rightarrow 0} \frac{|f(x+h) - f(x) - h \cdot a|}{\|h\|} = 0.$$

此时称 a 为 f 在 x 的导数 (derivative)，记为

$$f'(x) = a.$$

这里的式子

$$f(x+h) - f(x) = h \cdot a + o(\|h\|)$$

表示：当 $h \rightarrow 0$ 时，增量 $f(x+h) - f(x)$ 的主导项是一个关于 h 的线性函数 $h \cdot a$ ，剩余误差相对于 $\|h\|$ 可以忽略。

这正是多元微积分最核心的思想：函数在一点附近的行为由其线性主部决定。

3.2.2 导数的唯一性 (Uniqueness of the Derivative)

一个基本定理: 如果同一个点的线性逼近向量可以取两个不同值, 那么这两个值必相等。也就是说, 导数若存在则唯一。

Theorem 3.2.1.

设 $E \subseteq \mathbb{R}^n$ 为开集, $f: E \rightarrow \mathbb{R}$ 。若在点 $x \in E$, 存在两个向量 $a, b \in \mathbb{R}^n$ 都满足

$$\lim_{h \rightarrow 0} \frac{|f(x+h) - f(x) - h \cdot a|}{\|h\|} = 0, \quad \lim_{h \rightarrow 0} \frac{|f(x+h) - f(x) - h \cdot b|}{\|h\|} = 0,$$

则

$$a = b.$$

Proof. 由三角不等式,

$$\begin{aligned} |h \cdot (a - b)| &= |h \cdot a - h \cdot b| \\ &= |(f(x+h) - f(x) - h \cdot b) - (f(x+h) - f(x) - h \cdot a)| \\ &\leq |f(x+h) - f(x) - h \cdot a| + |f(x+h) - f(x) - h \cdot b|. \end{aligned}$$

两边同除以 $\|h\|$, 得

$$\frac{|h \cdot (a - b)|}{\|h\|} \leq \frac{|f(x+h) - f(x) - h \cdot a|}{\|h\|} + \frac{|f(x+h) - f(x) - h \cdot b|}{\|h\|}.$$

令 $h \rightarrow 0$, 右边两项都趋于 0, 因此

$$\lim_{h \rightarrow 0} \frac{|h \cdot (a - b)|}{\|h\|} = 0.$$

任取单位向量 $u \in \mathbb{R}^n$, 令 $h = tu$, 其中 $t \rightarrow 0$, 则 $\|h\| = |t|$, 于是

$$\frac{|h \cdot (a - b)|}{\|h\|} = \frac{|tu \cdot (a - b)|}{|t|} = |u \cdot (a - b)|.$$

由上极限为 0, 知

$$|u \cdot (a - b)| = 0 \quad \forall u, \|u\| = 1.$$

因此

$$u \cdot (a - b) = 0 \quad \forall u, \|u\| = 1.$$

特别取

$$u = \frac{a - b}{\|a - b\|}$$

(若 $a \neq b$), 便得

$$u \cdot (a - b) = \|a - b\| > 0,$$

矛盾。故只能有

$$a - b = 0,$$

即 $a = b$ 。

3.2.3 可微必连续 (Differentiable $\Rightarrow$ Continuous)

强调：可微性 (differentiability) 比连续性 (continuity) 强。

Theorem 3.2.2.

设 $E \subseteq \mathbb{R}^n$ 为开集, $f: E \rightarrow \mathbb{R}$. 若 f 在 $x \in E$ 可微, 则 f 在 x 连续。

Proof. 由可微定义, 存在 $a \in \mathbb{R}^n$ 使

$$f(x+h) - f(x) = h \cdot a + r(h), \quad \frac{r(h)}{\|h\|} \rightarrow 0.$$

于是

$$|f(x+h) - f(x)| \leq |h \cdot a| + |r(h)|.$$

由 Cauchy-Schwarz 不等式,

$$|h \cdot a| \leq \|h\| \|a\|.$$

又因为 $r(h) = o(\|h\|)$, 故当 $h \rightarrow 0$ 时,

$$|r(h)| \leq \varepsilon(h) \|h\|, \quad \varepsilon(h) \rightarrow 0.$$

因此

$$|f(x+h) - f(x)| \leq \|h\| \|a\| + \varepsilon(h) \|h\| = \|h\| (\|a\| + \varepsilon(h)) \rightarrow 0.$$

所以

$$f(x+h) \rightarrow f(x),$$

即 f 在 x 连续。 ■

Sec 3.3 从二维线性逼近到偏导数 (Partial Derivatives)

3.3.1 二维情形的线性逼近

从 $f(x_1, x_2)$ 的二维情形进入。若在点 (a_1, a_2) 附近作线性近似, 则自然写成

$$f(x_1, x_2) \approx p_1(x_1 - a_1) + p_2(x_2 - a_2) + q.$$

其中常数项 q 必须满足在基点精确取值, 因此

$$q = f(a_1, a_2).$$

而 p_1, p_2 则应当刻画函数沿坐标方向的变化率。

因此我们得到更具体的近似式

$$f(x_1, x_2) \approx f(a_1, a_2) + p_1(x_1 - a_1) + p_2(x_2 - a_2).$$

3.3.2 偏导数的定义

Definition 3.3.2.

设 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, 在点 (a_1, a_2) 处, 定义关于第一个变量的**偏导数** (partial derivative)

$$\frac{\partial f}{\partial x_1}(a_1, a_2) := \lim_{x_1 \rightarrow a_1} \frac{f(x_1, a_2) - f(a_1, a_2)}{x_1 - a_1},$$

定义关于第二个变量的偏导数

$$\frac{\partial f}{\partial x_2}(a_1, a_2) := \lim_{x_2 \rightarrow a_2} \frac{f(a_1, x_2) - f(a_1, a_2)}{x_2 - a_2}.$$

其含义是: 计算某个变量的变化率时, 把其他变量固定 (hold others constant)。

因此:

$\frac{\partial f}{\partial x_1}$ 是沿 x_1 方向的变化率 (rate of change in the x_1 direction),

$\frac{\partial f}{\partial x_2}$ 是沿 x_2 方向的变化率。

3.3.3 一个偏导计算的例子

$$f(x_1, x_2) = x_1 + 2x_2 + 3x_1^2 + 4x_1x_2 + 5x_2^2.$$

对 x_1 求偏导时, 把 x_2 看作常数:

$$\frac{\partial f}{\partial x_1} = 1 + 0 + 6x_1 + 4x_2 + 0 = 1 + 6x_1 + 4x_2.$$

对 x_2 求偏导时, 把 x_1 看作常数:

$$\frac{\partial f}{\partial x_2} = 0 + 2 + 0 + 4x_1 + 10x_2 = 2 + 4x_1 + 10x_2.$$

因此该函数的两个一阶偏导数为

$$f_{x_1}(x_1, x_2) = 1 + 6x_1 + 4x_2, \quad f_{x_2}(x_1, x_2) = 2 + 4x_1 + 10x_2.$$

Sec 3.4 光滑性的层次 (Levels of Smoothness)

多元函数的 regularity (正则性、光滑程度) 区分为几个层次:

1. **Partially differentiable**: 所有偏导数存在;
2. **Differentiable**: 函数承认局部线性逼近 (local linear approximation);
3. C^1 **function**: 一阶偏导存在且连续;
4. C^n **function**: 直到 n 阶的导数都存在且连续。

包含关系是

$$C^m \subseteq C^1 \subseteq \text{Differentiable} \subseteq \text{Partially differentiable}.$$

需要特别说明的是：这个关系链中，真正普遍正确并且最常用的是

$$C^1 \implies \text{Differentiable} \implies \text{Partially differentiable}.$$

而“所有偏导都存在”本身并不足以推出可微；PPT 把“partially differentiable”放在最弱层次，其本意是强调：偏导存在只是最初级条件，真正重要的是 linear approximation。

Sec 3.5 二维可微的正式定义

Definition 3.5.3.

函数 f 在点 (a_1, a_2) 可微，如果存在数 p_1, p_2 以及误差项 $\epsilon(h_1, h_2)$ ，使得

$$f(a_1 + h_1, a_2 + h_2) - f(a_1, a_2) = p_1 h_1 + p_2 h_2 + \epsilon(h_1, h_2),$$

并且

$$\frac{\epsilon(h_1, h_2)}{\sqrt{h_1^2 + h_2^2}} \rightarrow 0 \quad \text{当 } (h_1, h_2) \rightarrow (0, 0).$$

这里

$$p_1 = \frac{\partial f}{\partial x_1}(a_1, a_2), \quad p_2 = \frac{\partial f}{\partial x_2}(a_1, a_2).$$

这一定义表明：在二维中，可微就是存在一个一阶线性主部

$$p_1 h_1 + p_2 h_2$$

使误差项相对于点到基点的距离

$$\sqrt{h_1^2 + h_2^2}$$

来说是高阶小量。

特别指出： C^1 函数一定可微。下面给出这个结论的标准证明。

Theorem 3.5.3.

若 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ 在点 (a_1, a_2) 的邻域内具有连续的一阶偏导数，即 $f \in C^1$ ，则 f 在 (a_1, a_2) 可微。

Proof. 记

$$a = (a_1, a_2), \quad h = (h_1, h_2).$$

考虑增量

$$f(a_1 + h_1, a_2 + h_2) - f(a_1, a_2).$$

将其拆为两步：

$$\begin{aligned} & f(a_1 + h_1, a_2 + h_2) - f(a_1, a_2) \\ &= [f(a_1 + h_1, a_2 + h_2) - f(a_1, a_2 + h_2)] + [f(a_1, a_2 + h_2) - f(a_1, a_2)]. \end{aligned}$$

对第一项, 把 $x_2 = a_2 + h_2$ 固定, 视为一元函数

$$\phi(t) = f(t, a_2 + h_2).$$

由一元中值定理,

$$f(a_1 + h_1, a_2 + h_2) - f(a_1, a_2 + h_2) = \frac{\partial f}{\partial x_1}(a_1 + \theta_1 h_1, a_2 + h_2)h_1$$

其中 $\theta_1 \in (0, 1)$ 。

同理, 对第二项, 把 $x_1 = a_1$ 固定, 定义

$$\psi(t) = f(a_1, t),$$

则存在 $\theta_2 \in (0, 1)$ 使

$$f(a_1, a_2 + h_2) - f(a_1, a_2) = \frac{\partial f}{\partial x_2}(a_1, a_2 + \theta_2 h_2)h_2.$$

因此

$$\begin{aligned} & f(a_1 + h_1, a_2 + h_2) - f(a_1, a_2) \\ &= \frac{\partial f}{\partial x_1}(a_1 + \theta_1 h_1, a_2 + h_2)h_1 + \frac{\partial f}{\partial x_2}(a_1, a_2 + \theta_2 h_2)h_2. \end{aligned}$$

再加减

$$\frac{\partial f}{\partial x_1}(a_1, a_2)h_1 + \frac{\partial f}{\partial x_2}(a_1, a_2)h_2,$$

得到

$$\begin{aligned} & f(a + h) - f(a) \\ &= \frac{\partial f}{\partial x_1}(a)h_1 + \frac{\partial f}{\partial x_2}(a)h_2 + r(h), \end{aligned}$$

其中

$$\begin{aligned} r(h) &= \left[\frac{\partial f}{\partial x_1}(a_1 + \theta_1 h_1, a_2 + h_2) - \frac{\partial f}{\partial x_1}(a_1, a_2) \right] h_1 \\ &\quad + \left[\frac{\partial f}{\partial x_2}(a_1, a_2 + \theta_2 h_2) - \frac{\partial f}{\partial x_2}(a_1, a_2) \right] h_2. \end{aligned}$$

由于一阶偏导连续, 当 $h \rightarrow 0$ 时, 方括号中的两项都趋于 0。于是

$$\begin{aligned} \frac{|r(h)|}{\|h\|} &\leq \left| \frac{\partial f}{\partial x_1}(a_1 + \theta_1 h_1, a_2 + h_2) - \frac{\partial f}{\partial x_1}(a_1, a_2) \right| \frac{|h_1|}{\|h\|} \\ &\quad + \left| \frac{\partial f}{\partial x_2}(a_1, a_2 + \theta_2 h_2) - \frac{\partial f}{\partial x_2}(a_1, a_2) \right| \frac{|h_2|}{\|h\|} \rightarrow 0. \end{aligned}$$

故

$$f(a + h) - f(a) = \frac{\partial f}{\partial x_1}(a)h_1 + \frac{\partial f}{\partial x_2}(a)h_2 + o(\|h\|),$$

即 f 在 a 可微。

Sec 3.6

Vector notation and gradient: 向量记号与梯度

3.6.1 向量形式的可微

二维可微可写成更紧凑的 vector form (向量形式):

$$a = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}, \quad p = \begin{bmatrix} p_1 \\ p_2 \end{bmatrix}, \quad h = \begin{bmatrix} h_1 \\ h_2 \end{bmatrix}.$$

则

$$f(a+h) - f(a) = p \cdot h + \epsilon(h), \quad \frac{\epsilon(h)}{\|h\|} \rightarrow 0.$$

其中

$$\|h\| = \sqrt{h \cdot h} = \sqrt{h_1^2 + h_2^2}.$$

3.6.2 梯度 (Gradient)

Definition 3.6.4.

函数 f 在点 $a = (a_1, a_2)$ 的**梯度** (gradient) 定义为

$$\nabla f(a) := \begin{bmatrix} \frac{\partial f}{\partial x_1}(a_1, a_2) \\ \frac{\partial f}{\partial x_2}(a_1, a_2) \end{bmatrix}.$$

因此线性逼近可以写成

$$f(a+h) - f(a) = \nabla f(a) \cdot h + \epsilon(h).$$

对于一般的 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 梯度写作

$$\nabla f(a) = \begin{bmatrix} \frac{\partial f}{\partial x_1}(a) \\ \vdots \\ \frac{\partial f}{\partial x_n}(a) \end{bmatrix}.$$

3.6.3 一阶最优条件 (First-Order Condition)

无约束优化 (unconstrained optimization) 中的最基本结论:

Theorem 3.6.4.

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在点 x^* 可微。若 x^* 是问题

$$\max_x f(x)$$

的一个内点局部最优解 (*local maximizer*), 则

$$\nabla f(x^*) = 0.$$

同样地, 若 x^* 是内点局部最小值点 (*local minimizer*), 结论也成立。

Proof. 任取方向 $d \in \mathbb{R}^n$, 考虑一元函数

$$\varphi(t) = f(x^* + td).$$

由于 x^* 是局部最优点, 所以 $t = 0$ 是 φ 的局部极值点, 因此一元微积分给出

$$\varphi'(0) = 0.$$

另一方面, 由链式法则,

$$\varphi'(0) = \nabla f(x^*) \cdot d.$$

故

$$\nabla f(x^*) \cdot d = 0 \quad \forall d \in \mathbb{R}^n.$$

特别取 $d = e_i$ (第 i 个标准基向量), 得

$$\frac{\partial f}{\partial x_i}(x^*) = 0 \quad i = 1, \dots, n.$$

因此

$$\nabla f(x^*) = 0.$$

3.6.4 方向导数 (Directional Derivative) 与最速上升方向

Definition 3.6.5.

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在点 a 可微, $d \in \mathbb{R}^n$. 定义 f 在点 a 沿方向 d 的**方向导数** (directional derivative) 为

$$D_d f(a) := \lim_{t \rightarrow 0} \frac{f(a + td) - f(a)}{t},$$

若极限存在。

Theorem 3.6.5.

若 f 在点 a 可微, 则

$$D_d f(a) = \nabla f(a) \cdot d.$$

Proof. 由可微性,

$$f(a+td) - f(a) = \nabla f(a) \cdot (td) + r(td), \quad \frac{r(td)}{\|td\|} \rightarrow 0.$$

两边除以 t , 得

$$\frac{f(a+td) - f(a)}{t} = \nabla f(a) \cdot d + \frac{r(td)}{t}.$$

又因为

$$\left| \frac{r(td)}{t} \right| = \frac{|r(td)|}{\|td\|} \|d\| \rightarrow 0,$$

故

$$D_d f(a) = \nabla f(a) \cdot d.$$

特别地, 若取坐标方向

$$d = e_i,$$

则

$$D_{e_i} f(a) = \nabla f(a) \cdot e_i = \frac{\partial f}{\partial x_i}(a).$$

也就是说, **partial derivative (偏导数)** 只是 **directional derivative (方向导数)** 在坐标轴方向上的特殊情形。一般的单位向量方向导数并不等于某一个单独偏导, 而是梯度在该方向上的投影。

若 $\|d\| = 1$, 由 Cauchy-Schwarz 不等式,

$$\nabla f(a) \cdot d \leq \|\nabla f(a)\| \|d\| = \|\nabla f(a)\|.$$

等号成立当且仅当

$$d = \frac{\nabla f(a)}{\|\nabla f(a)\|} \quad (\nabla f(a) \neq 0).$$

因此:

Proposition 3.6.1.

梯度向量 $\nabla f(a)$ 指向函数在点 a 的**最速上升方向** (*direction of steepest increase*)。

3.6.5 例子: 距离函数

$$f(x_1, x_2) = \sqrt{x_1^2 + x_2^2}.$$

这个函数的 level sets (等值集) 是圆

$$x_1^2 + x_2^2 = c^2.$$

它沿着离原点越远的方向增大, 因此最快增长方向应该是半径方向。

直接计算:

$$\frac{\partial f}{\partial x_1} = \frac{x_1}{\sqrt{x_1^2 + x_2^2}}, \quad \frac{\partial f}{\partial x_2} = \frac{x_2}{\sqrt{x_1^2 + x_2^2}}.$$

故

$$\nabla f(x_1, x_2) = \begin{bmatrix} \frac{x_1}{\sqrt{x_1^2 + x_2^2}} \\ \frac{x_2}{\sqrt{x_1^2 + x_2^2}} \end{bmatrix}.$$

若记点 (x_1, x_2) 的极角为 θ , 则

$$x_1 = r \cos \theta, \quad x_2 = r \sin \theta,$$

从而

$$\nabla f(x_1, x_2) = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix},$$

恰好是沿半径方向的单位向量。这与几何直觉完全一致。

Sec 3.7 Mean Value Theorem and Taylor's Theorem

3.7.1 多元中值定理 (Mean Value Theorem)

Theorem 3.7.6.

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在连接 a, b 的线段上可微, 则存在 $\theta \in (0, 1)$, 使得

$$f(b) - f(a) = \nabla f((1 - \theta)a + \theta b) \cdot (b - a).$$

Proof. 定义一元函数

$$\varphi(t) = f(a + t(b - a)), \quad t \in [0, 1].$$

则

$$\varphi(1) - \varphi(0) = f(b) - f(a).$$

由一元中值定理, 存在 $\theta \in (0, 1)$ 使

$$\varphi(1) - \varphi(0) = \varphi'(\theta).$$

又由链式法则,

$$\varphi'(\theta) = \nabla f(a + \theta(b - a)) \cdot (b - a).$$

故

$$f(b) - f(a) = \nabla f((1 - \theta)a + \theta b) \cdot (b - a).$$

这就是一元中值定理

$$\frac{f(b) - f(a)}{b - a} = f'(c)$$

在多元情形下的推广。

3.7.2 Hessian 矩阵与二阶 Taylor 公式

Definition 3.7.6.

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 具有二阶偏导数, 则其 **Hessian 矩阵** 定义为

$$\nabla^2 f(x) = \left(\frac{\partial^2 f}{\partial x_i \partial x_j}(x) \right)_{1 \leq i, j \leq n}.$$

例如在二维中,

$$\nabla^2 f = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} \end{bmatrix}.$$

其中 (m, n) 元素就是

$$\frac{\partial^2 f}{\partial x_m \partial x_n}.$$

Theorem 3.7.7.

若 $f \in C^2$, 则 **Hessian 矩阵** 是对称矩阵 (*symmetric matrix*), 即

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}.$$

Theorem 3.7.8.

二阶 *Taylor approximation* 设 $f \in C^2$, 则对任意与 a 足够接近的 x , 存在 $\theta \in (0, 1)$ 使

$$f(x) = f(a) + \nabla f(a) \cdot (x - a) + \frac{1}{2}(x - a)^\top \nabla^2 f(\xi)(x - a),$$

其中

$$\xi = (1 - \theta)a + \theta x.$$

Proof. 定义一元函数

$$\varphi(t) = f(a + t(x - a)), \quad t \in [0, 1].$$

对一元函数 φ 在 $t = 0$ 处使用二阶 Taylor 公式, 得存在 $\theta \in (0, 1)$ 使

$$\varphi(1) = \varphi(0) + \varphi'(0) + \frac{1}{2}\varphi''(\theta).$$

逐项计算:

$$\varphi(1) = f(x), \quad \varphi(0) = f(a),$$

$$\varphi'(0) = \nabla f(a) \cdot (x - a),$$

而

$$\varphi''(\theta) = (x - a)^\top \nabla^2 f(a + \theta(x - a))(x - a).$$

代回即得

$$f(x) = f(a) + \nabla f(a) \cdot (x - a) + \frac{1}{2}(x - a)^T \nabla^2 f(\xi)(x - a).$$

这个式子在最优化中非常重要，因为它说明驻点附近的函数形状主要由 Hessian 决定。

Sec 3.8 Vector-Valued Functions 与 Jacobian Matrix

3.8.1 向量值函数 (Vector-Valued Functions)

可接着推广到

$$f: \mathbb{R}^N \rightarrow \mathbb{R}^M.$$

此时

$$f(x) = \begin{bmatrix} f_1(x_1, \dots, x_N) \\ f_2(x_1, \dots, x_N) \\ \vdots \\ f_M(x_1, \dots, x_N) \end{bmatrix}.$$

例如当 $N = M = 2$ 时,

$$f(x) = \begin{bmatrix} f_1(x_1, x_2) \\ f_2(x_1, x_2) \end{bmatrix}.$$

3.8.2 向量值函数的可微性

Definition 3.8.7.

设 $f: \mathbb{R}^N \rightarrow \mathbb{R}^M$ 。称 f 在点

$$a = (a_1, \dots, a_N)$$

可微，如果存在一个 $M \times N$ 矩阵 A ，使得

$$f(a + h) - f(a) = Ah + \epsilon(h),$$

并且

$$\frac{\|\epsilon(h)\|}{\|h\|} \rightarrow 0 \quad (h \rightarrow 0).$$

也就是说，向量值函数在一点附近仍然可以被某个**线性映射**近似，而这个线性映射的矩阵表示就是其导数。

3.8.3 Jacobian 矩阵

Definition 3.8.8.

设 $f: \mathbb{R}^N \rightarrow \mathbb{R}^M$ 。其在点 a 的 **Jacobian matrix** (Jacobian 矩阵) 记为 $Df(a)$, 定义为

$$Df(a) = \begin{bmatrix} \frac{\partial f_1}{\partial x_1}(a) & \cdots & \frac{\partial f_1}{\partial x_N}(a) \\ \vdots & \ddots & \vdots \\ \frac{\partial f_M}{\partial x_1}(a) & \cdots & \frac{\partial f_M}{\partial x_N}(a) \end{bmatrix}.$$

其第 (m, n) 个元素为

$$\frac{\partial f_m}{\partial x_n}(a).$$

当 $M = 1$ 时, f 退化为实值函数, 此时

$$Df(a) = \left[\frac{\partial f}{\partial x_1}(a) \quad \cdots \quad \frac{\partial f}{\partial x_N}(a) \right],$$

也就是梯度的转置:

$$Df(a) = [\nabla f(a)]^\top.$$

Jacobian 的两个作用:

1. 它是导数的矩阵表示;
2. 它出现在线性逼近中:

$$f(a+h) - f(a) = Df(a)h + \epsilon(h).$$

Sec 3.9 Chain Rule: 链式法则

3.9.1 一般形式

设

$$f: \mathbb{R}^N \rightarrow \mathbb{R}^M, \quad g: \mathbb{R}^M \rightarrow \mathbb{R}^L.$$

若 f 在 a 可微, g 在 $b = f(a)$ 可微, 则其线性逼近分别写作

$$f(a+h) - f(a) = Ah + \epsilon(h), \quad \frac{\|\epsilon(h)\|}{\|h\|} \rightarrow 0,$$

$$g(b+k) - g(b) = Bk + \delta(k), \quad \frac{\|\delta(k)\|}{\|k\|} \rightarrow 0.$$

Theorem 3.9.9.

在上述条件下, 复合函数

$$g \circ f: \mathbb{R}^N \rightarrow \mathbb{R}^L$$

在点 a 可微, 且

$$D(g \circ f)(a) = Dg(b) Df(a).$$

Proof. 设

$$Df(a) = A, \quad Dg(b) = B.$$

则

$$f(a+h) = f(a) + Ah + \epsilon(h) = b + Ah + \epsilon(h).$$

将

$$k = Ah + \epsilon(h)$$

代入 g 的线性展开式, 得

$$\begin{aligned} g(f(a+h)) - g(f(a)) &= g(b+k) - g(b) \\ &= Bk + \delta(k) \\ &= B(Ah + \epsilon(h)) + \delta(k) \\ &= BAh + B\epsilon(h) + \delta(k). \end{aligned}$$

由于

$$\frac{\|\epsilon(h)\|}{\|h\|} \rightarrow 0,$$

故

$$\frac{\|B\epsilon(h)\|}{\|h\|} \leq \|B\| \frac{\|\epsilon(h)\|}{\|h\|} \rightarrow 0.$$

又因为

$$k = Ah + \epsilon(h) = O(\|h\|),$$

所以

$$\frac{\|\delta(k)\|}{\|h\|} = \frac{\|\delta(k)\|}{\|k\|} \cdot \frac{\|k\|}{\|h\|} \rightarrow 0.$$

因此

$$g(f(a+h)) - g(f(a)) = BAh + o(\|h\|),$$

即 $g \circ f$ 在 a 可微, 且

$$D(g \circ f)(a) = BA = Dg(b) Df(a).$$

3.9.2 PPT 中的一维参数例子

设

$$g = g(x_1, x_2), \quad f(t) = \begin{bmatrix} f_1(t) \\ f_2(t) \end{bmatrix}.$$

则

$$Dg = \begin{bmatrix} \frac{\partial g}{\partial x_1} & \frac{\partial g}{\partial x_2} \end{bmatrix}, \quad Df = \begin{bmatrix} f'_1(t) \\ f'_2(t) \end{bmatrix}.$$

因此

$$\frac{d}{dt}g(f_1(t), f_2(t)) = Dg Df = \frac{\partial g}{\partial x_1} f'_1(t) + \frac{\partial g}{\partial x_2} f'_2(t).$$

更一般地, 若

$$f: \mathbb{R}^N \rightarrow \mathbb{R}^M, \quad g: \mathbb{R}^M \rightarrow \mathbb{R},$$

则

$$\frac{\partial(g \circ f)}{\partial x_n} = \sum_{m=1}^M \frac{\partial g}{\partial y_m} \frac{\partial f_m}{\partial x_n}.$$

这正是多元链式法则的分量表达式。

Sec 3.10

Implicit Function Theorem: 隐函数定理

3.10.1 动机: 无差异曲线 (Indifference Curves)

我们可以用经济学中的 indifference curve (无差异曲线) 说明隐函数思想。设效用水平固定为

$$u(x, y) = c.$$

若问: 当 good 1 的消费量 x 变化时, good 2 的消费量 y 需要如何变化, 才能保持同样的 utility level (效用水平)?

这相当于说: 方程

$$u(x, y) = c$$

在局部上把 y 隐式地定义为 x 的函数

$$y = y(x).$$

于是

$$u(x, y(x)) = c.$$

对 x 求导, 利用链式法则,

$$u_x(x, y(x)) \cdot 1 + u_y(x, y(x)) y'(x) = 0.$$

因此

$$y'(x) = -\frac{u_x(x, y(x))}{u_y(x, y(x))}.$$

在某点 (x_0, y_0) 处,

$$y'(x_0) = -\frac{u_x(x_0, y_0)}{u_y(x_0, y_0)}.$$

这正是 indifference curve 的 slope (斜率) 公式。

3.10.2 一维内生变量的隐函数求导

上面的过程可抽象为：给定

$$f(x, y) = 0,$$

其中 y 是 endogenous variable (内生变量), x 是 exogenous variable (外生变量)。若在局部上

$$y = g(x),$$

则有

$$f(x, g(x)) = 0.$$

对 x 求导：

$$f_x + f_y g'(x) = 0.$$

故

$$g'(x) = -\frac{f_x}{f_y}.$$

这里

$$f_x = \frac{\partial f}{\partial x}, \quad f_y = \frac{\partial f}{\partial y}.$$

3.10.3 多维版本的矩阵形式

推广： x 是 m 维外生变量， y 是 n 维内生变量。设

$$f : \mathbb{R}^m \times \mathbb{R}^n \rightarrow \mathbb{R}^n,$$

并且隐式关系写作

$$f(x, g(x)) = 0.$$

对 x 求导，得到

$$D_x f + D_y f D_x g = 0.$$

如果 $D_y f$ 可逆，则

$$D_x g = -(D_y f)^{-1} D_x f.$$

其中：

$$D_x f$$

是 f 关于 x 的 Jacobian matrix；其第 (i, j) 个元素是

$$\frac{\partial f_i}{\partial x_j}.$$

3.10.4 隐函数定理 (Implicit Function Theorem)

Theorem 3.10.10.

设

$$f: \mathbb{R}^m \times \mathbb{R}^n \rightarrow \mathbb{R}^n$$

是 *continuously differentiable* (连续可微) 的。若

$$f(x_0, y_0) = 0$$

且

$$D_y f(x_0, y_0)$$

是 *regular / invertible* (可逆) 的, 则存在 x_0 的邻域 U 、 y_0 的邻域 V , 以及一个函数

$$g: U \rightarrow V$$

使得:

1. 对任意 $x \in U$,

$$f(x, y) = 0 \iff y = g(x);$$

2. g 是 *continuously differentiable*;

- 3.

$$D_x g(x) = -(D_y f(x, y))^{-1} D_x f(x, y), \quad y = g(x).$$

这个定理的核心意义是: 只要关于内生变量 y 的 Jacobian 可逆, 就可以把方程组局部解成 $y = g(x)$ 的形式。

3.10.5 例子: 圆

$$F(x, y) = x^2 + y^2 - 25 = 0$$

这是半径为 5 的圆。

在圆上的点 $(3, 4)$, 有

$$F_y(x, y) = 2y.$$

由于

$$F_y(3, 4) = 8 \neq 0,$$

所以在 $(3, 4)$ 附近, 可以将 y 局部表示为 x 的函数:

$$y = \sqrt{25 - x^2}.$$

由隐函数求导公式,

$$y'(x) = -\frac{F_x}{F_y} = -\frac{2x}{2y} = -\frac{x}{y}.$$

$$F(x, y) = x^2 + y^2 - 25 = 0$$




图 3.1: 隐函数定理的图形直观: 同一条曲线在不同点可能适合解出不同变量

在点 $(3, 4)$,

$$y'(3) = -\frac{3}{4}.$$

这与图中切线 slope 的几何直观一致。

同时也要注意: 在点 $(5, 0)$ 处,

$$F_y(5, 0) = 0,$$

此时不能在该点附近把 y 局部表示为 x 的单值函数, 因为该点附近圆有垂直切线; 但由于

$$F_x(5, 0) = 10 \neq 0,$$

反而可以把 x 局部表示为 y 的函数。这正体现了隐函数定理中“哪个变量方向上 Jacobian 可逆, 就能解出哪个变量”的思想。

3.10.6 经济学应用: Consumer Demand and Comparative Statics

最后给出一个数理经济学中的应用。消费者问题写成

$$\max_x u(x) \quad \text{s.t.} \quad p \cdot x = I.$$

其 first-order conditions (FOCs) 可以写成一个方程组

$$F(x, p, I) = 0.$$

在适当 regularity conditions 下, 隐函数定理表明: 需求函数 (demand function) 在局部上可写为

$$x = x(p, I).$$

于是我们可以进行 comparative statics (比较静态), 计算诸如

$$\frac{\partial x}{\partial p}, \quad \frac{\partial x}{\partial I}$$

这样的导数。

这说明隐函数定理并不只是一个抽象分析定理，而是经济学中需求理论、均衡分析与比较静态的基础工具。

Sec 3.11 Inverse Function Theorem: 逆函数定理

最后给出 inverse function theorem (逆函数定理)。

Theorem 3.11.11.

设

$$f: \mathbb{R}^n \rightarrow \mathbb{R}^n$$

是 *continuously differentiable* 的。若在点 x_0 ,

$$Df(x_0)$$

是 *regular / invertible* 的, 记

$$y_0 = f(x_0),$$

则存在 y_0 的邻域 V , 使得:

1. 若记

$$U = f^{-1}(V),$$

则

$$f: U \rightarrow V$$

是 *bijective* (双射, *one-to-one and onto*);

2. 逆映射

$$g = f^{-1}: V \rightarrow U$$

是 *continuously differentiable*;

3. 对任意 $y \in V$,

$$Dg(y) = Df(g(y))^{-1}.$$

这个定理的直观含义是: 如果在点 x_0 处, 函数的线性近似

$$Df(x_0)$$

本身已经可逆, 那么原函数在该点附近也像一个可逆线性映射, 于是局部上可以反解。

下面给出导数公式的推导。

Proof (导数公式的推导). 既然

$$g = f^{-1},$$

则在局部上有

$$g(f(x)) = x.$$

对两边求导, 使用链式法则:

$$Dg(f(x)) Df(x) = I.$$

令

$$y = f(x),$$

则

$$Dg(y) Df(g(y)) = I.$$

由于

$$Df(g(y))$$

可逆，两边右乘其逆矩阵，得

$$Dg(y) = Df(g(y))^{-1}.$$



多元无约束优化

Part

Sec 4.1 总览

本讲讨论 Multi-Variable Unconstrained Optimization, 即多元无约束优化问题。课程的结构依次为:

1. Example of Single Variable Optimization
2. First and Second-order Conditions
3. Convex Optimization
4. Numerical Computation

核心问题是: 当目标函数 $f(x)$ 可微时, 如何刻画其最优解 (optimal solution), 以及在无法显式求解时如何用数值算法 (numerical algorithms) 逼近解。

Sec 4.2 单变量优化例子

4.2.1 垄断者利润最大化问题 (Monopoly Equilibrium Problem)

我们首先从一个单变量优化问题出发:

垄断者 (monopolist) 面临需求函数

$$p = 50 - 2x$$

和总成本函数

$$C(x) = 20 + 2x + 0.5x^2.$$

问题是: What is the price and output that maximizes profit?

利润函数 (profit function) 为

$$\pi(x) = px - C(x).$$

代入需求函数:

$$\pi(x) = (50 - 2x)x - (20 + 2x + 0.5x^2).$$

展开得

$$\pi(x) = 50x - 2x^2 - 20 - 2x - 0.5x^2 = 48x - 2.5x^2 - 20.$$

要使利润最大化, 只需最大化二次函数

$$\pi(x) = 48x - 2.5x^2 - 20.$$

4.3. 多元无约束优化的一般问题 (GENERAL UNCONSTRAINED OPTIMIZATION PROBLEM)

一阶条件 (First-Order Condition) 对 $\pi(x)$ 求导:

$$\pi'(x) = 48 - 5x.$$

令一阶导数为零:

$$48 - 5x = 0 \implies x^* = \frac{48}{5} = 9.6.$$

二阶条件 (Second-Order Condition) 继续求二阶导数:

$$\pi''(x) = -5 < 0.$$

因此利润函数是严格凹函数 (strictly concave), 故该驻点必为最大值点。

于是最优产量为

$$x^* = 9.6.$$

最优价格为

$$p^* = 50 - 2x^* = 50 - 19.2 = 30.8.$$

例子的意义 这个例子说明:

1. 优化问题的第一步是写出目标函数;
2. 通过 **first-order condition** 找到候选解;
3. 再通过 **second-order condition** 判断该候选解是最大值、最小值还是其他驻点。

这正是本讲接下来多变量优化的基本框架。

Sec 4.3

多元无约束优化的一般问题 (General Unconstrained Optimization Problem)

考虑无约束优化问题

$$\min f(x),$$

其中 f 是定义在 $\mathbb{R}^n$ 上的可微函数 (differentiable function)。

如果 x^* 是一个解 (solution), 则必须满足

$$\nabla f(x^*) = 0.$$

这里

$$\nabla f(x) = \begin{bmatrix} \frac{\partial f}{\partial x_1}(x) \\ \frac{\partial f}{\partial x_2}(x) \\ \vdots \\ \frac{\partial f}{\partial x_n}(x) \end{bmatrix}$$

是目标函数的 **gradient (梯度)**。

在二维情形,

$$\nabla f(x) = \begin{bmatrix} \frac{\partial f}{\partial x_1}(x) \\ \frac{\partial f}{\partial x_2}(x) \end{bmatrix}.$$

Sec 4.4 一阶条件 (First-Order Conditions)

4.4.1 必要性但非充分性

条件

$$\nabla f(x^*) = 0$$

称为最优性的一阶条件 (first-order condition for optimality)。

它是必要条件 (necessary condition), 但不是充分条件 (sufficient condition)。也就是说:

- 若 x^* 是局部最优解或全局最优解, 则通常必须有

$$\nabla f(x^*) = 0;$$

- 但反过来, 若某点满足

$$\nabla f(x^*) = 0,$$

它不一定是极大值或极小值点, 也可能是 saddle point (鞍点)。

4.4.2 几个基本定义

Definition 4.4.1.

若

$$\nabla f(x^*) = 0,$$

则称 x^* 为一个 stationary point (驻点)。

Definition 4.4.2.

若对任意 x 都有

$$f(x) \geq f(x^*),$$

则称 x^* 是无约束最小化问题的 global solution (全局解), 也即 global minimum (全局最小值点)。

Definition 4.4.3.

若存在 x^* 的某个邻域, 使得对所有与 x^* 足够接近且不等于 x^* 的 x , 有

$$f(x) > f(x^*),$$

则称 x^* 为 local solution (局部解), 也即 local minimum (局部最小值点)。

类似地, 对于最大化问题, 只需将不等号方向反过来即可。

Sec 4.5 经济学例子：市场间产量配置 (Monopolist Output Allocation Across Markets)

一个多变量经济学例子：price-discriminating monopolist (价格歧视垄断者) 如何在两个市场之间分配产量。

设两个市场的收入函数分别为

$$R_1(q_1), \quad R_2(q_2),$$

成本函数只依赖总产量

$$C = c(q_1 + q_2).$$

于是利润函数为

$$\pi(q_1, q_2) = R_1(q_1) + R_2(q_2) - c(q_1 + q_2).$$

一阶条件 利润最大化的一阶条件为

$$\frac{\partial \pi}{\partial q_1}(q_1^*, q_2^*) = R_1'(q_1^*) - c'(q_1^* + q_2^*) = 0,$$

$$\frac{\partial \pi}{\partial q_2}(q_1^*, q_2^*) = R_2'(q_2^*) - c'(q_1^* + q_2^*) = 0.$$

因此有

$$R_1'(q_1^*) = c'(q_1^* + q_2^*), \quad R_2'(q_2^*) = c'(q_1^* + q_2^*).$$

从而推出

$$R_1'(q_1^*) = R_2'(q_2^*).$$

经济学解释 这说明：

A price-discriminating monopolist allocates output across markets to equalize marginal revenues.

也就是说，价格歧视垄断者会在不同市场之间配置产量，使得各市场的 **marginal revenue (边际收益)** 相等，并且都等于 **marginal cost (边际成本)**。

这是多变量优化在经济学中的一个典型应用：通过多元一阶条件导出最优配置规则。

Sec 4.6 经济学例子：边际收益与需求弹性 (Demand Elasticity)

对于垄断者利润最大化，还可以从需求弹性 (price elasticity of demand) 的角度理解一阶条件。

设反需求函数为

$$p = p(q).$$

总收益为

$$R(q) = p(q)q.$$

因此边际收益

$$MR = R'(q) = p(q) + q \frac{dp}{dq}.$$

定义需求价格弹性

$$\varepsilon = \frac{dq}{dp} \frac{p}{q}.$$

代回边际收益公式：

$$MR = p + \frac{p}{\varepsilon} = p \left(1 + \frac{1}{\varepsilon} \right).$$

4.6.1 Lerner Index

利润最大化要求

$$MR = MC.$$

代入上式得

$$p \left(1 + \frac{1}{\varepsilon} \right) = MC.$$

移项整理：

$$p - MC = -\frac{p}{\varepsilon}.$$

两边同除以 p ：

$$\frac{p - MC}{p} = -\frac{1}{\varepsilon}.$$

这就是著名的 **Lerner Index**：

$$\boxed{\frac{p - MC}{p} = -\frac{1}{\varepsilon}}.$$

4.6.2 经济学含义

这说明：

1. markup (加成率)

$$\frac{p - MC}{p}$$

与需求弹性的绝对值成反比；

2. 当需求越缺乏弹性 (less elastic) 时，企业可以收取更高的加成。

Sec 4.7 Cournot 竞争例子

一个经典的经济学优化模型：**Cournot competition** (古诺竞争)。

两个企业生产同质产品，市场需求函数为

$$p = 100 - (q_1 + q_2),$$

其中 q_i 是第 i 个企业的产量。假设生产成本为零。

第 i 个企业的利润函数为

$$\pi_i = pq_i = (100 - (q_1 + q_2))q_i, \quad i = 1, 2.$$

展开得

$$\pi_i = 100q_i - (q_1 + q_2)q_i.$$

4.7.1 最佳反应函数 (Best Response)

对于企业 1,

$$\pi_1(q_1, q_2) = 100q_1 - q_1^2 - q_1q_2.$$

对 q_1 求偏导,

$$\frac{\partial \pi_1}{\partial q_1} = 100 - 2q_1 - q_2.$$

令其为零,

$$100 - 2q_1 - q_2 = 0 \implies q_1 = \frac{100 - q_2}{2}.$$

同理, 对于企业 2,

$$q_2 = \frac{100 - q_1}{2}.$$

联立解得对称均衡

$$q_1^* = q_2^* = \frac{100}{3}.$$

总产量为

$$Q^* = \frac{200}{3},$$

价格为

$$p^* = 100 - \frac{200}{3} = \frac{100}{3}.$$

4.7.2 一般化到 n 个相同企业

在 n 个相同企业时, 若总产量为

$$Q = \sum_{i=1}^n q_i,$$

则第 i 个企业利润为

$$\pi_i = (100 - Q)q_i.$$

对称均衡下所有企业产量相同, 即 $q_i = q$, 于是

$$Q = nq.$$

对任一企业的一阶条件为

$$100 - 2q - (n-1)q = 0,$$

即

$$100 - (n+1)q = 0.$$

4.8. 关于一阶条件的进一步说明

所以

$$q^* = \frac{100}{n+1}, \quad Q^* = \frac{100n}{n+1}, \quad p^* = \frac{100}{n+1}.$$

这个例子说明, 多元优化不仅适用于单个决策者, 也适用于博弈论中每个参与者分别最优化时的均衡求解。

Sec 4.8 关于一阶条件的进一步说明

从严格数学上看, “满足一阶条件的点未必是最优解, 因此 FOC 不是充分条件; 但在可微内点最优问题中, FOC 是必要条件。”

因此应准确表述为:


1. 若 x^* 是可微无约束优化问题的内点最优解, 则 x^* 必为 stationary point;
2. 但 stationary point 不一定是最优解。

Sec 4.9 局部极值与鞍点的图形理解


4.9.1 在两个方向上都是局部极小或局部极大

下图展示两种最基本的局部极值形状:

1. Local minimum in both x_1 and x_2 directions
2. Local maximum in both x_1 and x_2 directions



(a) Local minimum in both x_1 and x_2 directions



(b) Local maximum in both x_1 and x_2 directions

图 4.1: 两个坐标方向上均呈现局部极小或局部极大的图形直观

其几何含义是:

- 如果在点 $x^* = (x_1^*, x_2^*)$ 附近, 沿 x_1 方向和沿 x_2 方向切开来看, 函数图形都像“碗底”, 那么该点可能是局部极小值点;

4.10. 二阶充分条件 (SUFFICIENT CONDITION FOR OPTIMALITY: SECOND-ORDER CONDITION)

- 如果沿两个方向切开都像“山顶”，那么该点可能是局部极大值点。

但要注意：只检查坐标方向通常还不够，真正的局部最优要求沿所有方向都满足相应性质。

4.9.2 一个方向最小、另一个方向最大：鞍点 (Saddle Point)

另两种典型情形是：

1. Local minimum in x_1 direction and local maximum in x_2 direction
2. Local maximum in x_1 direction and local minimum in x_2 direction

这种点在一个方向上像谷底、在另一个方向上像山顶，因此既不是局部最小值，也不是局部最大值，而是 saddle point (鞍点)。

这正是为什么仅有

$$\nabla f(x^*) = 0$$

还不够，需要用二阶条件 (second-order condition) 进一步判断。

Sec 4.10 二阶充分条件 (Sufficient Condition for Optimality: Second-Order Condition)

Proposition 4.10.1.

设 f 是二次连续可微函数 (twice continuously differentiable, C^2)，且

$$\nabla f(x^*) = 0.$$

如果 Hessian 矩阵

$$\nabla^2 f(x^*)$$

满足：

1. *positive definite* (正定)，则 x^* 是 *local minimum* (局部极小值点)；
2. *negative definite* (负定)，则 x^* 是 *local maximum* (局部极大值点)。

4.10.1 推导

设 $x = x^* + h$ 。由 Taylor 定理，

$$f(x^* + h) = f(x^*) + \langle \nabla f(x^*), h \rangle + \frac{1}{2} \langle h, \nabla^2 f(x^* + \alpha h) h \rangle,$$

其中 $0 < \alpha < 1$ 。

由于 x^* 是 stationary point,

$$\nabla f(x^*) = 0,$$

4.10. 二阶充分条件 (SUFFICIENT CONDITION FOR OPTIMALITY: SECOND-ORDER CONDITION)

所以

$$f(x^* + h) = f(x^*) + \frac{1}{2} \langle h, \nabla^2 f(x^* + \alpha h) h \rangle.$$

令

$$Q = \nabla^2 f(x^*).$$

如果 h 足够小, 则

$$\nabla^2 f(x^* + \alpha h)$$

会接近 Q 。因此, 函数值差

$$f(x) - f(x^*)$$

的符号主要由二次型

$$\langle h, Qh \rangle = h^\top Qh$$

决定。

于是:

- 若对所有非零 h ,

$$h^\top Qh > 0,$$

则

$$f(x) > f(x^*)$$

对 x 充分接近 x^* 成立, 所以 x^* 是局部极小值点;

- 若对所有非零 h ,

$$h^\top Qh < 0,$$

则

$$f(x) < f(x^*),$$

因此 x^* 是局部极大值点。

4.10.2 二维情形的 Hessian

在两变量情形中,

$$\nabla^2 f = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} \end{bmatrix}.$$

若 $f \in C^2$, 则混合偏导相等,

$$\frac{\partial^2 f}{\partial x_1 \partial x_2} = \frac{\partial^2 f}{\partial x_2 \partial x_1},$$

所以 Hessian 是对称矩阵 (symmetric matrix)。

Sec 4.11 二阶条件的例子

4

4.11.1 一维例子

$$f(x) = x^3 - 3x.$$

求导得

$$f'(x) = 3x^2 - 3 = 3(x^2 - 1).$$

故 stationary points 为

$$x = \pm 1.$$

继续求二阶导数:

$$f''(x) = 6x.$$

于是

$$f''(1) = 6 > 0,$$

所以 $x = 1$ 是局部极小值点;

$$f''(-1) = -6 < 0,$$

所以 $x = -1$ 是局部极大值点。

4.11.2 二维例子: 正定 Hessian

$$f(x_1, x_2) = x_1^2 + x_1x_2 + x_2^2.$$

梯度为

$$\nabla f(x_1, x_2) = \begin{bmatrix} 2x_1 + x_2 \\ x_1 + 2x_2 \end{bmatrix}.$$

令梯度为零:

$$2x_1 + x_2 = 0, \quad x_1 + 2x_2 = 0.$$

解得唯一 stationary point

$$(x_1^*, x_2^*) = (0, 0).$$

Hessian 为

$$\nabla^2 f = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

计算其特征值或主子式:

$$\Delta_1 = 2 > 0, \quad \Delta_2 = 4 - 1 = 3 > 0.$$

因此 Hessian 正定, 所以 $(0, 0)$ 是局部极小值点。事实上该函数是严格凸的, 因此它还是全局最小值点。

4.11.3 鞍点例子

$$f(x_1, x_2) = x_1^2 - x_2^2.$$

梯度为

$$\nabla f(x_1, x_2) = \begin{bmatrix} 2x_1 \\ -2x_2 \end{bmatrix}.$$

所以唯一 stationary point 为

$$(0, 0).$$

Hessian 为

$$\nabla^2 f = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}.$$

这个矩阵既不是正定，也不是负定，而是 **indefinite (不定)**。因此 $(0, 0)$ 不是极大值点也不是极小值点，而是鞍点。

这与函数图形完全一致：沿 x_1 方向看是开口向上的抛物线，沿 x_2 方向看是开口向下的抛物线。

Sec 4.12 凸优化 (Convex Optimization)

4.12.1 凸函数的定义 (Definition: Convex Function)

Definition 4.12.4.

函数 f 称为 **convex (凸函数)**，如果对任意 x_1, x_2 以及任意

$$0 \leq \alpha \leq 1,$$

都有

$$f((1 - \alpha)x_1 + \alpha x_2) \leq (1 - \alpha)f(x_1) + \alpha f(x_2).$$

也就是说，函数图像上任意两点之间的线段都位于图像上方。

Definition 4.12.5.

若反向不等式成立，即

$$f((1 - \alpha)x_1 + \alpha x_2) \geq (1 - \alpha)f(x_1) + \alpha f(x_2),$$

则称 f 为 **concave (凹函数)**。

显然，

$$f \text{ is concave} \iff -f \text{ is convex}.$$




图 4.2: 凸函数的几何刻画: 函数图像位于切线之上

4.12.2 凸函数与 Hessian 的关系

Theorem 4.12.1.

若 f 是二次连续可微函数, 则:

1. f 是 *convex*, 当且仅当 Hessian

$$\nabla^2 f(x)$$

在每一点都是 *positive semidefinite* (半正定);

2. f 是 *concave*, 当且仅当 Hessian 在每一点都是 *negative semidefinite* (半负定)。

4.12.3 解释

这个结论是一维情形

$$f''(x) \geq 0 \iff f \text{ convex}$$

的多元推广。二阶导数在多元中由 Hessian 取代, 而“非负”则由二次型条件

$$h^\top \nabla^2 f(x) h \geq 0 \quad \forall h$$

来表达。

Sec 4.13 凸函数的另一种刻画

Proposition 4.13.2.

设 f 可微, 则 f 是 (严格) 凸函数当且仅当对任意 $x \neq y$,

$$f(y) - f(x) \geq (>) \langle \nabla f(x), y - x \rangle.$$

这一定理表明: **convex function lies above its tangent hyperplane**, 即凸函数在任一点处都位于其切平面 (或切线) 的上方。

4.13.1 证明

先证必要性。设 f 是凸函数。定义

$$\phi(t) = f(x + t(y - x)), \quad t \in [0, 1].$$

由于 f 凸, ϕ 是一元凸函数。于是对一元凸函数, 有

$$\phi(1) - \phi(0) \geq \phi'(0).$$

写回原变量,

$$f(y) - f(x) \geq \nabla f(x) \cdot (y - x).$$

反过来, 若对任意 x, y 都有

$$f(y) - f(x) \geq \nabla f(x) \cdot (y - x),$$

则可利用这条支持超平面 (supporting hyperplane) 不等式推出 Jensen 型凸性不等式, 从而得到 f 凸。

4.13.2 图形解释

图 4.2 说明:

- 在点 x 处作切线, 其斜率为

$$\nabla f(x);$$

- 当移动到另一个点 y 时, 函数真实值

$$f(y)$$

高于切线的线性预测值

$$f(x) + \nabla f(x) \cdot (y - x).$$

这正是

$$f(y) - f(x) \geq \nabla f(x) \cdot (y - x)$$

的几何图像。

Sec 4.14

凸函数上的最优性刻画

Theorem 4.14.2.

设 f 是可微的 *convex* (或 *concave*) 函数。则:

1. 若 f 是 *convex*, 则 x^* 是 f 的最小值点, 当且仅当

$$\nabla f(x^*) = 0;$$

2. 若 f 是 *concave*, 则 x^* 是 f 的最大值点, 当且仅当

$$\nabla f(x^*) = 0.$$

即:

- 对 convex function, stationary point 自动是 **global minimum**;
- 对 concave function, stationary point 自动是 **global maximum**。

4.14.1 证明思路 (Hint: Taylor's Theorem)

若 f 是凸函数, 则由上一节的刻画,

$$f(y) - f(x^*) \geq \nabla f(x^*) \cdot (y - x^*).$$

若

$$\nabla f(x^*) = 0,$$

则

$$f(y) \geq f(x^*) \quad \forall y,$$

因此 x^* 是全局最小值点。

反之, 若 x^* 是可微凸函数的最小值点, 则由一般一阶必要条件必有

$$\nabla f(x^*) = 0.$$

凹函数情形完全类似。

这个定理非常重要, 因为它说明: 在凸优化中, 一阶条件不再只是必要条件, 而是**充要条件**。

Sec 4.15 二次函数 (Quadratic Functions)**4.15.1 形式与记号 (Form and Notation)**

课件写出二元二次函数的一般形式:

$$f(x_1, x_2) = a + b_1x_1 + b_2x_2 + c_1x_1^2 + c_2x_1x_2 + c_3x_2^2.$$

为了写成矩阵形式, 令

$$c_1 = \frac{1}{2}q_{11}, \quad c_2 = q_{12}, \quad c_3 = \frac{1}{2}q_{22}.$$

则

$$f(x_1, x_2) = a + b_1x_1 + b_2x_2 + \frac{1}{2}q_{11}x_1^2 + q_{12}x_1x_2 + \frac{1}{2}q_{22}x_2^2.$$

令

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}, \quad Q = \begin{bmatrix} q_{11} & q_{12} \\ q_{12} & q_{22} \end{bmatrix}.$$

则可写成紧凑形式

$$f(x) = a + \langle b, x \rangle + \frac{1}{2}\langle x, Qx \rangle.$$

也即

$$f(x) = a + b^\top x + \frac{1}{2}x^\top Qx.$$

4.15.2 梯度与 Hessian

对该函数求梯度:

$$\nabla f(x) = b + Qx.$$

更具体地,

$$\nabla f(x) = \begin{bmatrix} b_1 + q_{11}x_1 + q_{12}x_2 \\ b_2 + q_{12}x_1 + q_{22}x_2 \end{bmatrix}.$$

Hessian 则为

$$\nabla^2 f(x) = Q.$$

即二次函数的 Hessian 是常数矩阵, 与 x 无关。

4.15.3 凸性与凹性

由上一节定理:

- 若 Q positive semidefinite, 则 f convex;
- 若 Q negative semidefinite, 则 f concave.

4.15.4 最优解公式

一阶条件为

$$0 = \nabla f(x) = b + Qx.$$

若 Q 可逆, 则

$$x^* = -Q^{-1}b.$$

并且:

- 若 Q positive definite, 则

$$x^* = -Q^{-1}b$$

是 f 的最小值点;

- 若 Q negative definite, 则它是最大值点。

这个结论自然推广到任意维数。

Sec 4.16 数值计算 (Numerical Computation)

接下来主要讨论非线性方程求根 (root-finding) 和无约束优化中的迭代算法。

Sec 4.17 一维非线性求根：二分法 (Bisection Method)

4.17.1 问题背景

Bisection Method 是一种简单而稳健 (simple and robust) 的求根方法, 用于连续函数在有界区间上的 root-finding。

其理论基础是 Intermediate Value Theorem (介值定理):

若 f 在区间 $[a, b]$ 上连续, 且

$$f(a) \cdot f(b) < 0,$$

则 f 在 (a, b) 内至少存在一个根。

4.17.2 基本原理

若

$$f(a), f(b)$$

异号, 则中点

$$c = \frac{a+b}{2}$$

把区间分成两半。由于函数连续, 必有一半区间仍然保留异号性质, 因此根仍被“夹在”这半个区间中。

然后不断重复这一过程, 就能逐步缩小根所在区间。

4.17.3 算法过程 (Process)

1. 从区间 $[a, b]$ 开始, 其中

$$f(a)f(b) < 0.$$

2. 计算中点

$$c = \frac{a+b}{2}.$$

4.17. 一维非线性求根：二分法 (BISECTION METHOD)

3. 计算 $f(c)$:

- 若 $f(c)$ 与 $f(a)$ 同号，则把左端点换成 c ;
- 若 $f(c)$ 与 $f(b)$ 同号，则把右端点换成 c 。

4. 重复迭代，直到达到所需精度。

4.17.4 Matlab 代码

```

1 s = sign(f(a));
2 x = (a+b)/2;
3 d = (b-a)/2;
4 while d > tol
5     d = d/2;
6     if s == sign(f(x))
7         x = x + d;
8     else
9         x = x - d;
10    end
11 end

```

其含义是：

- s 记录左端点函数值的符号；
- x 是当前中点；
- d 是半区间长度；
- 每次迭代将区间长度减半；
- 根据中点函数值与左端点函数值是否同号，决定向左还是向右更新。

4.17.5 收敛速度 (Convergence Rate and Order)

迭代收敛的形式化定义：

若迭代序列 $x_n \rightarrow x^*$ ，且对充分大的 n ，存在常数 $C > 0$ 和 $\rho > 0$ 使

$$|x_{n+1} - x^*| \leq C|x_n - x^*|^\rho,$$

则：

- C 称为 **convergence rate**;
- ρ 称为 **convergence order**。

分类如下：

- 若 $C < 1$ 且 $\rho = 1$ ，称为 **linear convergence (线性收敛)**;
- 若 $1 < \rho < 2$ ，称为 **superlinear convergence (超线性收敛)**;

- 若 $\rho = 2$, 称为 **quadratic convergence (二次收敛)**。

对于二分法, 每次区间长度减半, 因此误差大约也减半, 所以它是**线性收敛**, 收敛率为 $\frac{1}{2}$ 。

Sec 4.18 割线法与假位法

4.18.1 基本思想

这两种方法都假设: 函数在根附近可以近似看成线性的 (approximately linear near the root)。

因此:

- 用两点确定一条直线;
- 用这条直线与 x 轴的交点作为下一次的根近似;
- 每轮迭代后更新一个端点。

它们通常在 smooth functions 上比 bisection 更快。

4.18.2 割线法 (Secant Method)

Secant Method 使用最近两次迭代点

$$x_0, x_1$$

所确定的割线, 下一步取该割线与横轴交点。

设函数值为

$$f(x_0), \quad f(x_1).$$

割线方程为

$$y - f(x_1) = \frac{f(x_1) - f(x_0)}{x_1 - x_0}(x - x_1).$$

令 $y = 0$, 解得下一次迭代点

$$x_2 = x_1 - f(x_1) \frac{x_1 - x_0}{f(x_1) - f(x_0)}.$$

一般迭代公式为

$$x_{n+1} = x_n - f(x_n) \frac{x_n - x_{n-1}}{f(x_n) - f(x_{n-1})}.$$




图 4.3: Secant Method: 用两点割线与横轴的交点生成下一次迭代

4.18.3 假位法 (False Position Method)

False Position Method (regula falsi) 也用割线与横轴的交点作为新点, 但它始终保留一对异号端点, 因此根一直被夹在区间内。

若当前区间为

$$[a_n, b_n], \quad f(a_n)f(b_n) < 0,$$

则先取割线与横轴交点

$$c_n = b_n - f(b_n) \frac{b_n - a_n}{f(b_n) - f(a_n)}.$$

然后根据符号决定保留哪一半区间:

- 若

$$f(a_n)f(c_n) < 0,$$

则令

$$a_{n+1} = a_n, \quad b_{n+1} = c_n;$$

- 若

$$f(c_n)f(b_n) < 0,$$

则令

$$a_{n+1} = c_n, \quad b_{n+1} = b_n.$$

因此 False Position 与 Secant Method 使用的是同一个几何近似点, 但前者额外强制保留 bracketing property (夹逼性质)。

其优点是:

- 始终保持 bracketing;
- 稳定性更强。

缺点是某些情况下会出现“长迭代”(long iterations), 即一侧端点长时间几乎不动, 导致收敛慢。

4.18.4 Secant Method 的 Matlab 代码

```

1 while iteration < max_iterations
2     f0 = f(x0);
3     f1 = f(x1);
4     x2 = x1 - f1*(x1-x0)/(f1-f0);
5     if abs(x2-x1) < tolerance
6         break;
7     end
8     x0 = x1;
9     x1 = x2;
10    iteration = iteration + 1;
11 end

```

4.18.5 两种方法的比较

- Secant Method:

- 保留最近一次先前估计;
- 对足够光滑的函数通常收敛更快;
- 收敛阶约为黄金分割比

$$\varphi = \frac{1 + \sqrt{5}}{2} \approx 1.618;$$

- 对不够连续或初值不好时, 不保证收敛。

- False Position:

- 收敛阶较低;
- 但始终保持根被夹在区间中, 稳定性更强。

4.18.6 长迭代例子 (Example of Long Iterations)

图中展示了 False Position 可能出现的现象: 若函数一侧非常陡而另一侧非常平, 则每次割线与横轴的交点都偏向平缓一侧, 导致某个端点几乎不更新, 从而迭代次数很多。

这说明: 保持 bracketing 虽然安全, 但有时代价是收敛慢。

Sec 4.19 牛顿法 (Newton's Method / Newton-Raphson Method)

4.19.1 基本思想

大多数非线性问题 (most nonlinear problems) 都用 Newton's method 或其变体求解。其突出特点是:




图 4.4: False Position Method: 保持夹逼时可能出现一侧端点长期不动的情形

- 需要同时计算函数值 $f(x)$ 和导数 $f'(x)$;
- 几何上, 它在当前点作切线 (tangent line), 再把切线与横轴的交点作为下一次迭代点。




图 4.5: Newton's Method: 用当前点切线的横轴截距更新根的近似值

4.19.2 数学推导

在点 x 附近作 Taylor 展开:

$$f(x + \varepsilon) \approx f(x) + f'(x)\varepsilon + \frac{f''(x)}{2}\varepsilon^2 + \dots$$

若根就在附近, 即

$$f(x + \varepsilon) = 0$$

且 ε 很小, 则忽略高阶项, 得到

$$0 \approx f(x) + f'(x)\varepsilon.$$

因此

$$\varepsilon \approx -\frac{f(x)}{f'(x)}.$$

于是新的迭代点应取为

$$x + \varepsilon = x - \frac{f(x)}{f'(x)}.$$

所以牛顿法迭代公式为

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}.$$

4.19.3 收敛性质

在根附近、且满足适当正则条件时, Newton method 具有 **quadratic convergence** (二次收敛)。

Theorem 4.19.3.

设 x^* 是方程

$$f(x) = 0$$

的一个 *simple root* (单根), 即

$$f(x^*) = 0, \quad f'(x^*) \neq 0,$$

并且 $f \in C^2$ 。若初值 x_0 足够接近 x^* , 则 Newton 迭代

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$

满足

$$e_{n+1} = \frac{f''(\xi_n)}{2f'(x_n)} e_n^2, \quad e_n := x_n - x^*,$$

其中 ξ_n 位于 x_n 与 x^* 之间。

Proof. 在点 x_n 处把 f 对 x^* 作二阶 Taylor 展开:

$$f(x^*) = f(x_n) + f'(x_n)(x^* - x_n) + \frac{1}{2}f''(\xi_n)(x^* - x_n)^2,$$

其中 ξ_n 介于 x_n 与 x^* 之间。由于 $f(x^*) = 0$, 且

$$x^* - x_n = -e_n,$$

故

$$0 = f(x_n) - f'(x_n)e_n + \frac{1}{2}f''(\xi_n)e_n^2.$$

整理得

$$f(x_n) = f'(x_n)e_n - \frac{1}{2}f''(\xi_n)e_n^2.$$

现在把它代回 Newton 公式：

$$\begin{aligned}
 e_{n+1} &= x_{n+1} - x^* \\
 &= x_n - \frac{f(x_n)}{f'(x_n)} - x^* \\
 &= e_n - \frac{f(x_n)}{f'(x_n)} \\
 &= e_n - \frac{f'(x_n)e_n - \frac{1}{2}f''(\xi_n)e_n^2}{f'(x_n)} \\
 &= \frac{f''(\xi_n)}{2f'(x_n)} e_n^2.
 \end{aligned}$$

由于 $x_n \rightarrow x^*$ 时, $f'(x_n) \rightarrow f'(x^*) \neq 0$, 所以上式中的系数在根附近保持有界, 于是存在常数 $C > 0$ 使

$$|e_{n+1}| \leq C|e_n|^2$$

对充分大的 n 成立。这就是 quadratic convergence 的精确含义：误差大致按“平方”速度缩小, 因此每迭代一步, 有效数字通常会明显增加。

4.19.4 一维 Newton Method 的 Matlab 代码

```

1 while iteration < max_iterations
2     fx = f(x0);
3     dfx = df(x0);
4     x1 = x0 - fx/dfx;
5     if abs(x1-x0) < tolerance
6         break;
7     end
8     x0 = x1;
9     iteration = iteration + 1;
10 end

```

4.19.5 优点与局限 (Advantages and Limitations)

- Newton method 是首选方法 (method of choice), 当：
 - 导数可以高效计算；
 - 导数在根附近连续且非零。
- 实际应用中, 它常用于 “polish up” 已经通过其他方法找到的近似根；
- 只需 1-2 步, 就可能把有效数字提高很多。

但它也有明显局限：

- global convergence 很差;
- 若初始点选得不好, 可能发散、跳到别的根附近, 甚至形成循环。

4.19.6 失败例子 (Failure Examples)

给出两种失败图形:

1. 若函数在某点附近切线方向把迭代带离目标根, 则 Newton 法可能跑向远处;
2. 某些函数形状下, 迭代点可能在两个位置之间来回跳动, 形成 cycle。

因此 Newton method 虽然快, 但需要良好的初值和正则条件。

Sec 4.20 多维牛顿法 (Newton Method in Multiple Dimensions)

4.20.1 求解非线性方程组

考虑

$$F: \mathbb{R}^N \rightarrow \mathbb{R}^N,$$

要求解

$$F(x) = 0.$$

在当前点 $x = a$ 处, Taylor 近似为

$$F(x) \approx F(a) + DF(a)(x - a),$$

其中

$$DF(a)$$

是 $N \times N$ Jacobian 矩阵。

若令线性近似等于零, 即

$$F(a) + DF(a)(x - a) = 0,$$

则可得

$$x = a - [DF(a)]^{-1}F(a).$$

因此多维 Newton 迭代为

$$x_{n+1} = x_n - [DF(x_n)]^{-1}F(x_n).$$

4.20.2 MATLAB 实现思路

```

1 for it = 1:maxit
2     [fval, fjac] = f(x);
3     x = x - fjac\fval;
4     if norm(fval) < tol
5         break
6     end
7 end

```

这里:

- fval 表示函数值向量 $F(x)$;
- fjac 表示 Jacobian $DF(x)$;
- fjac\fval 在 Matlab 中表示解线性方程组

$$DF(x), d = F(x),$$

即

$$d = [DF(x)]^{-1}F(x),$$

然后更新

$$x \leftarrow x - d.$$

Sec 4.21

牛顿法用于数值优化 (Newton Method for Numerical Optimization)

4.21.1 从 Taylor 近似推导

若要最小化或最大化一个二次连续可微函数 $f(x)$, 在当前点 $x = a$ 处用二阶 Taylor 近似:

$$f(x) \approx f(a) + \langle \nabla f(a), x - a \rangle + \frac{1}{2} \langle x - a, \nabla^2 f(a)(x - a) \rangle.$$

为了找到这个二次近似的极值点, 对 x 求梯度并令其为零:

$$0 = \nabla f(a) + \nabla^2 f(a)(x - a).$$

因此

$$x = a - [\nabla^2 f(a)]^{-1} \nabla f(a).$$

于是 Newton 法在优化中的迭代公式为

$$x_{n+1} = x_n - [\nabla^2 f(x_n)]^{-1} \nabla f(x_n).$$

4.21.2 与方程求解的关系

优化 Newton method 本质上是把

$$F(x) = \nabla f(x)$$

代入多维 Newton 法。因此：

- 求解

$$\nabla f(x) = 0$$

就是在找 stationary points;

- Newton step 使用了局部二次近似;
- 要求 Hessian

$$\nabla^2 f(x_n)$$

非奇异 (non-singular)。

4.21.3 正式算法 (Formal Algorithm)

1. 初始化:

- 选定初值 x_0 ;
- 给定误差容忍度 $\varepsilon > 0$ 。

2. 对 $n = 0, 1, 2, \dots$ 迭代计算

$$x_{n+1} = x_n - [\nabla^2 f(x_n)]^{-1} \nabla f(x_n).$$

3. 停止准则: 若

$$|x_{n+1} - x_n| < \varepsilon,$$

则停止, 并返回 x_{n+1} 作为近似解。

Sec 4.22 Newton Method 在经济学中的应用

课件指出, 很多经济学模型都需要求解非线性方程或优化问题, 而 Newton method 提供了快速数值程序。

4.22.1 优化问题

例如消费者或厂商优化问题, 其 first-order condition 为

$$\nabla f(x) = 0.$$

Newton update 为

$$x_{t+1} = x_t - [\nabla^2 f(x_t)]^{-1} \nabla f(x_t).$$

4.22.2 均衡计算 (Equilibrium Computation)

例如:

- 宏观模型中的 steady states;
- 一般均衡模型中的 market clearing conditions。

这类问题通常归结为求解非线性方程组

$$F(x) = 0.$$

Newton method 通过局部二次近似 (local quadratic approximation) 快速定位解。

Sec 4.23 梯度法 (Gradient Method / Steepest Descent Method)**4.23.1 几何解释**

先看 gradient 的几何意义:

- 梯度 $\nabla f(x)$ 指向函数增长最快的方向;
- 因此, 若目标是最小化 f , 最自然的下降方向就是

$$-\nabla f(x).$$

沿这个方向作一维搜索 (line search), 就得到 gradient method。

4.23.2 基本思想

考虑最小化问题

$$\min f(x),$$

其中 f 可微。设当前近似点为 a , 记

$$g = \nabla f(a).$$

则沿直线

$$x = a - tg, \quad t > 0$$

搜索新的近似解。

定义单变量函数

$$\phi(t) = f(a - tg).$$

然后在 $t > 0$ 上最小化 $\phi(t)$ 。若最优步长为 t^* , 则新的迭代点为

$$x_{\text{new}} = a - t^*g.$$

这就是 gradient method, 也称 steepest descent method。

4.23.3 算法步骤

1. 选择初值 x_0 和误差容忍度 $\varepsilon > 0$;

2. 对 $n = 0, 1, 2, \dots$:

- 计算梯度

$$g_n = \nabla f(x_n);$$

- 定义一元函数

$$\phi(t) = f(x_n - tg_n);$$

- 用一维优化算法在 $t > 0$ 上最小化 $\phi(t)$;
- 记最优步长为 t_n ;
- 更新

$$x_{n+1} = x_n - t_n g_n.$$

3. 若

$$|x_{n+1} - x_n| < \varepsilon,$$

则停止, x_{n+1} 为近似解。

4.23.4 图形理解 (Graphic Illustration)

等高线图 (contour plot) 说明:

- 从当前点 x^0 出发;
- 梯度方向是最陡上升方向;
- 因而负梯度方向是最陡下降方向;
- 每次迭代沿负梯度方向向下移动, 并配合 line search 选步长。




图 4.6: Gradient Method: 在等高线图上沿负梯度方向下降并配合 line search

在狭长等高线问题中, 梯度法可能呈现“之”字形前进, 因此虽然稳健, 但收敛速度可能不如 Newton method。

4.23.5 例子 (Gradient Method)

$$f(x_1, x_2) = x_1^2 + 2x_2^2 - 2x_1x_2 - 2x_2.$$

并要求从 $x^0 = (0, 0)$ 开始尝试 gradient algorithm。

先求梯度:

$$\nabla f(x_1, x_2) = \begin{bmatrix} 2x_1 - 2x_2 & 4x_2 - 2x_1 - 2 \end{bmatrix}.$$

因此在初始点 $x^0 = (0, 0)$ 处,

$$g_0 = \nabla f(0, 0) = \begin{bmatrix} 0 & -2 \end{bmatrix}.$$

故负梯度方向为

$$-g_0 = \begin{bmatrix} 0 & 2 \end{bmatrix}.$$

沿该方向搜索:

$$x(t) = x^0 - tg_0 = \begin{bmatrix} 0 & 0 \end{bmatrix} + t \begin{bmatrix} 0 & 2 \end{bmatrix} = \begin{bmatrix} 0 & 2t \end{bmatrix}.$$

于是

$$\phi(t) = f(0, 2t) = 2(2t)^2 - 2(2t) = 8t^2 - 4t.$$

对其求导:

$$\phi'(t) = 16t - 4.$$

令

$$16t - 4 = 0 \implies t_0 = \frac{1}{4}.$$

因此

$$x^1 = x^0 - t_0 g_0 = \begin{bmatrix} 0 & 0 \end{bmatrix} - \frac{1}{4} \begin{bmatrix} 0 & -2 \end{bmatrix} = \begin{bmatrix} 0 & \frac{1}{2} \end{bmatrix}.$$

这说明 gradient method 的每一步都可以分解为:

1. 求当前梯度;
2. 确定下降方向;
3. 在该方向做 line search;
4. 更新迭代点。

Sec 4.24 本讲总结

第四讲的逻辑可以概括为以下几条主线:

1. Unconstrained optimization 的基本候选点来自一阶条件

$$\nabla f(x^*) = 0.$$

2. 仅有 FOC 不够, 需要二阶条件:

- Hessian positive definite $\Rightarrow$ local minimum;
- Hessian negative definite $\Rightarrow$ local maximum;
- Hessian indefinite $\Rightarrow$ saddle point.

3. 对于 **convex / concave functions**, stationary point 自动是全局最优点。

4. 对于 **quadratic functions**,

$$f(x) = a + b^\top x + \frac{1}{2}x^\top Qx,$$

可直接由

$$x^* = -Q^{-1}b$$

求解。

5. 在无法解析求解时, 可采用数值算法:

- **Bisection Method**: 稳健但较慢;
- **Secant / False Position**: 更快, 但稳定性有所差异;
- **Newton Method**: 局部极快, 但依赖导数和初值;
- **Gradient Method**: 基于最速下降方向, 适合一般优化问题。

多元等式约束优化

Part

Sec 5.1 导入

第四讲讨论的是 **unconstrained optimization**，即没有约束的最优化问题；这一讲开始讨论 **constrained optimization**，尤其是 **equality constraints**（等式约束）情形。两者的区别为：

- 在 **unconstrained problems** 中，我们可以在整个可行域上自由选择 x ；
- 在 **constrained problems** 中，可选的 x 必须满足某些限制；
- 本讲的重点是：把这些限制写成 **functional equations**（函数方程）

$$g(x) = 0,$$

并研究如何在这种约束下做优化。

核心方法是 **Method of Lagrange Multipliers**，即**拉格朗日乘子法**。它用来处理这样的问题：

$$\max_x f(x) \quad \text{subject to } g(x) = 0,$$

或

$$\min_x f(x) \quad \text{subject to } g(x) = 0.$$

这一方法的关键在于：

1. 把约束问题转化为一个带额外变量 λ 的“扩展”无约束问题；
2. 借助一阶条件与二阶条件刻画最优点；
3. 其中乘子 λ 本身往往还有重要的经济学含义。

Sec 5.2 例子：消费者效用最大化

5.2.1 问题

考虑两个 goods（商品）：

- good 1: apples
- good 2: bananas

消费者的 satisfaction (满足) 由 utility function (效用函数) 表示为

$$u(c_1, c_2) = \log c_1 + \log c_2,$$

其中：

- c_1 表示 good 1 的消费量；
- c_2 表示 good 2 的消费量。

已知：

- prices: p_1, p_2 ;
- budget / wealth: w 。

若购买 c_1, c_2 单位商品，则 expenditure (支出) 为

$$p_1 c_1 + p_2 c_2.$$

预算约束 (budget constraint) 为

$$p_1 c_1 + p_2 c_2 = w.$$

因此问题写成：

$$\max_{c_1, c_2} u(c_1, c_2) = \log c_1 + \log c_2$$

subject to

$$p_1 c_1 + p_2 c_2 = w.$$

这里：

- **Decision variables:** c_1, c_2 ;
- **Parameters:** p_1, p_2, w 。

5.2.2 解答：直接代入法

先给出一个 “trick”：

由预算约束

$$p_1 c_1 + p_2 c_2 = w$$

解出

$$c_2 = \frac{w - p_1 c_1}{p_2}.$$

把它代回目标函数，就得到一个单变量无约束问题：

$$\max_{c_1} \log c_1 + \log \left(\frac{w - p_1 c_1}{p_2} \right).$$

这样就可以直接使用单变量 calculus 求解。

5.2.3 Why study the general theory?

这种方法数学上当然正确, 但 **too special to be useful**, 原因是:

1. 这个等式约束恰好能方便地解出一个变量;
2. 代入之后恰好可以把问题降成单变量问题;
3. 但如果是三变量甚至更多变量, 或者多个约束, 这种方法就会非常繁琐, 甚至根本无法实施。

所以我们需要一个更一般、更系统的方法, 即 **Lagrangian method**。

Sec 5.3 二元函数的约束优化

5.3.1 从无约束到有约束

设

$$f(x_1, x_2)$$

是一个严格凹函数 (strictly concave function), 并且

$$f \in C^2.$$

在无约束情形下, 如果

$$(x_1^*, x_2^*)$$

是最优解, 那么它满足

$$f_i(x_1^*, x_2^*) = 0, \quad i = 1, 2.$$

也就是

$$f_1(x_1^*, x_2^*) = 0, \quad f_2(x_1^*, x_2^*) = 0.$$

现在加入一个 constraint (约束)

$$g(x_1, x_2) = 0.$$

这时可行点 (feasible solutions) 不再是整个平面, 而只剩下约束曲线

$$G = \{(x_1, x_2) : g(x_1, x_2) = 0\}.$$

因此:

- 无约束问题: 在整个 $\mathbb{R}^2$ 中找最优点;
- 有约束问题: 只能在约束曲线 G 上找最优点。

5.3.2 几何解释

若

$$(x_1^*, x_2^*)$$

是 constrained optimum (约束最优点), 那么它是:

- constraint curve

$$G: g(x_1, x_2) = 0$$

与

- objective function 的 level curve (等值线)

$$f(x_1, x_2) = f^*$$

之间的 tangency point (切点)。

也就是说, 最优点处, 目标函数的等值线和约束曲线相切。这是 constrained optimization 的基本几何特征。




图 5.1: 二元等式约束优化的几何直观: 约束曲线与目标函数等值线在最优点相切

Sec 5.4 约束优化的代数解

几何上的“相切”可以转化为代数条件。

5.4.1 切线条件 (Tangency condition)

目标函数的 level curve

$$f(x_1, x_2) = \text{constant}$$

两边微分, 得到

$$f_1(x_1, x_2) dx_1 + f_2(x_1, x_2) dx_2 = 0.$$

因此其斜率为

$$\frac{dx_2}{dx_1} = -\frac{f_1(x_1, x_2)}{f_2(x_1, x_2)}.$$

同样, 约束曲线

$$g(x_1, x_2) = 0$$

两边微分, 得

$$g_1(x_1, x_2) dx_1 + g_2(x_1, x_2) dx_2 = 0,$$

故其斜率为

$$\frac{dx_2}{dx_1} = -\frac{g_1(x_1, x_2)}{g_2(x_1, x_2)}.$$

在最优点处两条曲线相切, 因此斜率相等:

$$-\frac{f_1(x_1^*, x_2^*)}{f_2(x_1^*, x_2^*)} = -\frac{g_1(x_1^*, x_2^*)}{g_2(x_1^*, x_2^*)}.$$

即

$$\frac{f_1(x_1^*, x_2^*)}{f_2(x_1^*, x_2^*)} = \frac{g_1(x_1^*, x_2^*)}{g_2(x_1^*, x_2^*)}.$$

5.4.2 可行性条件

当然, 最优点还必须满足可行性:

$$g(x_1^*, x_2^*) = 0.$$

所以二元单约束问题的解应满足如下方程组:

$$\frac{f_1(x_1^*, x_2^*)}{f_2(x_1^*, x_2^*)} = \frac{g_1(x_1^*, x_2^*)}{g_2(x_1^*, x_2^*)}, \quad g(x_1^*, x_2^*) = 0.$$

这就是几何切点条件的代数表达。

Sec 5.5 约束优化的替换方法

课件接着用 substitution method 再次说明上述切点条件的来源。

5.5.1 把约束写成隐函数

若约束

$$g(x_1, x_2) = 0$$

可以局部解成

$$x_2 = \gamma(x_1),$$

则约束曲线就是函数图像

$$G = \{(x_1, \gamma(x_1))\}.$$

由隐函数求导公式,

$$\gamma'(x_1) = -\frac{g_1(x_1, \gamma(x_1))}{g_2(x_1, \gamma(x_1))}.$$

5.5.2 化为无约束问题

把

$$x_2 = \gamma(x_1)$$

代入目标函数, 得到单变量函数

$$\varphi(x_1) = f(x_1, \gamma(x_1)).$$

于是 constrained optimization 转化为

$$\max \varphi(x_1).$$

一阶条件为

$$\varphi'(x_1^*) = 0.$$

利用 chain rule,

$$\varphi'(x_1^*) = f_1(x_1^*, \gamma(x_1^*)) + f_2(x_1^*, \gamma(x_1^*))\gamma'(x_1^*) = 0.$$

再代入

$$\gamma'(x_1^*) = -\frac{g_1(x_1^*, x_2^*)}{g_2(x_1^*, x_2^*)},$$

便得到

$$f_1(x_1^*, x_2^*) - f_2(x_1^*, x_2^*) \frac{g_1(x_1^*, x_2^*)}{g_2(x_1^*, x_2^*)} = 0,$$

整理即得

$$\frac{f_1(x_1^*, x_2^*)}{f_2(x_1^*, x_2^*)} = \frac{g_1(x_1^*, x_2^*)}{g_2(x_1^*, x_2^*)}.$$

这说明 substitution method 与 tangency condition 完全一致。

Sec 5.6 受限最优解的拉格朗日特征 (Lagrangian Characterization of Constrained Optima)

现在进入本讲最核心的定理。

5.6.1 双变量、单约束情况

考虑问题

$$\max_{x_1, x_2} f(x_1, x_2) \quad \text{s.t.} \quad g(x_1, x_2) = 0,$$

其中 f, g 都是 continuously differentiable (连续可微) 函数。

若

$$x^* = (x_1^*, x_2^*)$$

是该约束问题的解, 并且 x^* 不是 g 的 stationary point, 也就是

$$g'(x^*) \neq 0,$$

更具体地说,

$$\nabla g(x^*) \neq 0,$$

那么存在一个实数

$$\lambda^*$$

使得

$$(x_1^*, x_2^*, \lambda^*)$$

是拉格朗日函数

$$L(x_1, x_2, \lambda) \equiv f(x_1, x_2) + \lambda g(x_1, x_2)$$

的 stationary point。

也就是说它满足:

$$\frac{\partial L}{\partial x_1} = f_1(x_1^*, x_2^*) + \lambda^* g_1(x_1^*, x_2^*) = 0,$$

$$\frac{\partial L}{\partial x_2} = f_2(x_1^*, x_2^*) + \lambda^* g_2(x_1^*, x_2^*) = 0,$$

$$\frac{\partial L}{\partial \lambda} = g(x_1^*, x_2^*) = 0.$$

5.6.2 为什么它与相切条件一致?

前两个式子可写成

$$\nabla f(x^*) + \lambda^* \nabla g(x^*) = 0.$$

也就是

$$\nabla f(x^*) = -\lambda^* \nabla g(x^*).$$

这说明在最优点处,

$$\nabla f(x^*)$$

与

$$\nabla g(x^*)$$

平行 (parallel)。

而:

- ∇f 垂直于 f 的 level curve;
- ∇g 垂直于 $g = 0$ 的 constraint curve。

所以两者平行, 就意味着两条曲线相切。这与前面的几何解释完全一致。

Sec 5.7 多变量和多约束的拉格朗日方法

把拉格朗日方法推广到一般情形。

5.7.1 Generalized problem

设:

- f 是 n 个变量的 scalar function;
- g 是一个 $m \times 1$ vector-valued function, 代表 m 个约束:

$$g(x) = \begin{bmatrix} g_1(x) \\ \vdots \\ g_m(x) \end{bmatrix}.$$

问题写成

$$\max_x f(x) \quad \text{s.t.} \quad g(x) = 0.$$

5.7.2 Jacobian matrix of constraints

定义约束函数的 Jacobian matrix:

$$Dg(x) = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \cdots & \frac{\partial g_1}{\partial x_n} \\ \frac{\partial g_2}{\partial x_1} & \cdots & \frac{\partial g_2}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_m}{\partial x_1} & \cdots & \frac{\partial g_m}{\partial x_n} \end{bmatrix}.$$

若

$$x^*$$

是 constrained optimization 的解, 并且

$$\text{rank } Dg(x^*) = m,$$

那么存在乘子

$$\lambda_1^*, \dots, \lambda_m^*$$

使得

$$(x^*, \lambda^*)$$

是 Lagrangian

$$L(x, \lambda) \equiv f(x) + \lambda_1 g_1(x) + \cdots + \lambda_m g_m(x)$$

的 stationary point。

5.7.3 First-Order Conditions

因此一阶条件为

$$\begin{aligned} \frac{\partial L}{\partial x_i} &= 0, & i &= 1, \dots, n, \\ \frac{\partial L}{\partial \lambda_j} &= 0, & j &= 1, \dots, m. \end{aligned}$$

展开后就是:

$$\nabla f(x^*) = \lambda_1 \nabla g_1(x^*) + \cdots + \lambda_m \nabla g_m(x^*).$$

5.7.4 Equivalent characterization

这个等式非常重要。它说明：

在约束最优点处，目标函数的梯度可以表示成约束函数梯度的线性组合。

几何上， $\nabla g_1, \dots, \nabla g_m$ 张成了约束面法空间 (normal space)，而

$$\nabla f(x^*)$$

位于这个法空间中。这意味着在所有 feasible directions (可行方向) 上，目标函数的一阶变化都为零。

Sec 5.8 非退化约束限定 (Nondegenerate Constraint Qualification, NDCQ)

5.8.1 Definition

课件特别提出一个关键条件：

$$\text{rank } Dg(x^*) = m.$$

这个条件叫做

Nondegenerate Constraint Qualification (NDCQ).

它的意义是：约束在最优点附近 “足够独立”，即没有局部冗余。

5.8.2 为什么需要 NDCQ ?

若 NDCQ 失败，则可能出现：

- 最优点存在；
- 但它不满足某个拉格朗日乘子的一阶方程组；
- 因此拉格朗日方法可能漏掉这个最优点。

也就是说，NDCQ 是拉格朗日一阶条件成立的关键前提之一。

Sec 5.9 示例：约束优化问题

5.9.1 Example 1

考虑

$$\max_{(x_1, x_2)} x_1^2 - x_2^2 \quad \text{s.t.} \quad x_1^2 + x_2^2 = 1.$$

这是在单位圆上最大化双曲面函数。

约束

$$g(x_1, x_2) = x_1^2 + x_2^2 - 1 = 0.$$

其梯度为

$$\nabla g(x_1, x_2) = \begin{bmatrix} 2x_1 \\ 2x_2 \end{bmatrix}.$$

在单位圆上它从不为零，因此 NDCQ 满足。

拉格朗日函数为

$$L(x_1, x_2, \lambda) = x_1^2 - x_2^2 + \lambda(x_1^2 + x_2^2 - 1).$$

一阶条件：

$$2x_1 + 2\lambda x_1 = 0,$$

$$-2x_2 + 2\lambda x_2 = 0,$$

$$x_1^2 + x_2^2 = 1.$$

由前两式可得：

- 若 $x_1 \neq 0$ ，则 $\lambda = -1$ ；
- 若 $x_2 \neq 0$ ，则 $\lambda = 1$ 。

为使约束成立并取得最大值，应取

$$x_1 = \pm 1, \quad x_2 = 0,$$

对应最大值

$$f = 1.$$

最小值则在

$$x_1 = 0, \quad x_2 = \pm 1$$

处达到，对应

$$f = -1.$$

5.9.2 Example 2

再看

$$\max x_1 \quad \text{s.t.} \quad x_1^3 + x_2^2 = 0.$$

约束写为

$$g(x_1, x_2) = x_1^3 + x_2^2.$$

其 feasible set 满足

$$x_2^2 = -x_1^3.$$

因为左边非负，所以必须有

$$x_1 \leq 0.$$

因此目标

$$\max x_1$$

的最优值显然是

$$x_1^* = 0.$$

此时由约束得

$$x_2^* = 0.$$

也就是说最优点为

$$(0, 0).$$

但此时

$$\nabla g(0, 0) = \begin{bmatrix} 3x_1^2 \\ 2x_2 \end{bmatrix}_{(0,0)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

所以 NDCQ 不满足。

这正说明：最优点明明存在，但拉格朗日乘子法的一阶条件未必能把它捕捉出来。

Sec 5.10

拉格朗日方法的重要注意事项

5.10.1

Without NDCQ

如果最优点不满足 NDCQ，那么：

- 它可能不会出现在 Lagrangian 的 stationary points 里；
- 于是该方法可能失效。

5.10.2

With NDCQ

即便满足 NDCQ，拉格朗日一阶条件也仍然只是 **necessary conditions**，不是 sufficient conditions。

因此：

- 找到 stationary point 之后，还必须进一步检验；
- 检验的核心，是研究目标函数沿 constraint surface 的 local convexity/concavity，也就是二阶条件。

Sec 5.11

应用：Cobb-Douglas 效用函数

课件接下来给出经济学中的标准应用：Cobb-Douglas utility function：

$$U(x_1, x_2) = x_1^\alpha x_2^{1-\alpha}, \quad 0 < \alpha < 1.$$

下面给出两个 consumer problems：

5.11.1 Primal Problem (Utility Maximization)

$$\max U(x_1, x_2) \quad \text{s.t.} \quad p_1 x_1 + p_2 x_2 = m.$$

这就是消费者在预算约束下的效用最大化问题。

5.11.2 Dual Problem (Expenditure Minimization)

$$\min e = p_1 x_1 + p_2 x_2 \quad \text{s.t.} \quad U(x_1, x_2) = \bar{u}.$$

这就是为达到给定 utility level 所需最小支出的 expenditure minimization problem。这两个问题在微观经济学中是对偶的 (dual)。

Sec 5.12 Setup: Two-Variable, One-Constraint Problem

重新回到一般形式：

$$\text{objective: } f(x_1, x_2), \quad \text{constraint: } g(x_1, x_2) = 0.$$

定义 Lagrangian:

$$L(x_1, x_2, \lambda) = f(x_1, x_2) + \lambda g(x_1, x_2).$$

若

$$(x_1^*, x_2^*, \lambda^*)$$

是 stationary point, 则 first-order necessary conditions 为:

$$\frac{\partial L}{\partial x_1} = f_1(x_1^*, x_2^*) + \lambda^* g_1(x_1^*, x_2^*) = 0,$$

$$\frac{\partial L}{\partial x_2} = f_2(x_1^*, x_2^*) + \lambda^* g_2(x_1^*, x_2^*) = 0,$$

$$\frac{\partial L}{\partial \lambda} = g(x_1^*, x_2^*) = 0.$$

这就是二元单约束问题最标准的 Lagrangian setup。

Sec 5.13 Hessian Matrix of the Lagrange Function

接下来引入 bordered Hessian matrix (边界 Hessian 矩阵)。

5.13.1 Bordered Hessian

定义

$$\bar{H} = \begin{bmatrix} 0 & g_1 & g_2 \\ g_1 & f_{11} + \lambda^* g_{11} & f_{12} + \lambda^* g_{12} \\ g_2 & f_{21} + \lambda^* g_{21} & f_{22} + \lambda^* g_{22} \end{bmatrix}.$$

这里所有偏导数都在 stationary point

$$(x_1^*, x_2^*, \lambda^*)$$

处求值。

注意，下右角的 2×2 block 实际上就是 Lagrangian 对 x 变量的 Hessian:

$$\nabla_{xx}^2 L(x^*, \lambda^*).$$

如果约束是线性的 (linear constraints), 即

$$g_{ij} = 0,$$

那么 bordered Hessian 会简化为: 目标函数 Hessian 再用约束梯度向量做 border。

Sec 5.14

拉格朗日优化的二阶条件：双变量情形

对于二元单约束问题，有非常简洁的二阶判别：

若

$$(x_1^*, x_2^*, \lambda^*)$$

是 Lagrangian 的 stationary point, 则：

1. 若

$$|\bar{H}| > 0,$$

则得到 local maximum;

2. 若

$$|\bar{H}| < 0,$$

则得到 local minimum。

5.14.1

为什么这里符号与无约束 Hessian 判别不同？

这是因为 constrained optimization 并不是在所有方向上看 curvature, 而是只看 feasible directions 上的 curvature。

Sec 5.15

Why Does the Bordered Hessian Look Like This?

5

5.15.1 Feasible directions

对问题

$$\max f(x_1, x_2) \quad \text{s.t.} \quad g(x_1, x_2) = 0,$$

在最优点附近，一个小变动

$$d = (d_1, d_2)$$

若要保持可行，就必须满足

$$\nabla g(x^*) \cdot d = 0.$$

这里：

•

$$\nabla g(x^*) = (g_1, g_2)$$

是 constraint 的 normal vector (法向量)；

- feasible movements 必须位于约束的 tangent direction (切向方向) 上。

5.15.2 Curvature along the constraint

真正要检查的 curvature 不是所有方向上的，而只是 constraint surface 上的。

而 curvature 由 Lagrangian 的 Hessian

$$\nabla_{xx}^2 L(x^*, \lambda^*)$$

测量。

因此 bordered Hessian

$$\bar{H} = \begin{bmatrix} 0 & g_1 & g_2 \\ g_1 & L_{11} & L_{12} \\ g_2 & L_{21} & L_{22} \end{bmatrix}$$

把两部分合在一起：

- 第一行/列：编码 constraint direction；
- 右下 block：编码 curvature；
- 合起来：只检查沿约束的 curvature。

更具体地，在二元单约束情形中，feasible directions 满足

$$g_1 d_1 + g_2 d_2 = 0.$$

只要 $(g_1, g_2) \neq (0, 0)$ ，就可以取一个非零切向量

$$d = \begin{bmatrix} g_2 \\ -g_1 \end{bmatrix},$$

因为这时

$$\nabla g(x^*) \cdot d = g_1 g_2 - g_2 g_1 = 0.$$

记

$$\nabla_{xx}^2 L(x^*, \lambda^*) = \begin{bmatrix} L_{11} & L_{12} \\ L_{21} & L_{22} \end{bmatrix}.$$

在 stationary point 处, 一阶项沿 feasible direction 自动消失, 所以二阶变化由

$$d^\top \nabla_{xx}^2 L(x^*, \lambda^*) d$$

控制。直接计算可得

$$d^\top \nabla_{xx}^2 L d = g_2^2 L_{11} - 2g_1 g_2 L_{12} + g_1^2 L_{22}.$$

另一方面, 若 $L \in C^2$, 则 $L_{12} = L_{21}$, 于是 bordered Hessian 的行列式满足

$$\det \bar{H} = \det \begin{bmatrix} 0 & g_1 & g_2 \\ g_1 & L_{11} & L_{12} \\ g_2 & L_{21} & L_{22} \end{bmatrix} = -g_2^2 L_{11} + 2g_1 g_2 L_{12} - g_1^2 L_{22}.$$

因此

$$d^\top \nabla_{xx}^2 L d = -\det \bar{H}.$$

这就解释了符号为什么与无约束问题相反:

- 若要得到 local maximum, 则沿可行切向量必须向下弯曲, 即

$$d^\top \nabla_{xx}^2 L d < 0,$$

因而

$$\det \bar{H} > 0;$$

- 若要得到 local minimum, 则沿可行切向量必须向上弯曲, 即

$$d^\top \nabla_{xx}^2 L d > 0,$$

因而

$$\det \bar{H} < 0.$$

这就是 bordered Hessian 的来源, 也是双变量情形二阶判别法则背后的真正几何机制。

Sec 5.16

Second-Order Conditions: n -variable case

课件接着把 bordered Hessian 的判别扩展到一般 n 变量、一个等式约束的情形。
若 Lagrange function

$$f(x_1, \dots, x_n) + \lambda g(x_1, \dots, x_n)$$

在

$$(x_1^*, \dots, x_n^*, \lambda^*)$$

处有 stationary value, 则:

5.16.1 For Minimum

若要求

$$\min f(x_1, \dots, x_n) \quad \text{s.t.} \quad g(x_1, \dots, x_n) = 0,$$

则条件是：

All principal minors of $|\bar{H}|$ are strictly negative.

更准确地说，是从相应阶数开始考察 bordered Hessian 的 successive principal minors，它们都应严格为负。

5.16.2 For Maximum

若要求

$$\max f(x_1, \dots, x_n) \quad \text{s.t.} \quad g(x_1, \dots, x_n) = 0,$$

则条件是：

- successive principal minors alternate in sign;
- 整个 bordered Hessian 的行列式符号与

$$(-1)^n$$

相同。

二维、三维时这种规律分别表现为：

$$\begin{vmatrix} 0 & g_1 & g_2 \\ g_1 & L_{11} & L_{12} \\ g_2 & L_{21} & L_{22} \end{vmatrix} > 0,$$

$$\begin{vmatrix} 0 & g_1 & g_2 & g_3 \\ g_1 & L_{11} & L_{12} & L_{13} \\ g_2 & L_{21} & L_{22} & L_{23} \\ g_3 & L_{31} & L_{32} & L_{33} \end{vmatrix} < 0,$$

依此交替。

5.16.3 补充说明

这一部分在很多教材中写法略有差别，原因在于：

- 有的教材用 maximization 版本的 Lagrangian；
- 有的教材用 minimization 版本；
- 有的把检查的主子式从不同阶开始计数。

因此实际使用时，最好与课堂课件的符号约定保持一致，不要混用其他教材的判别表。

Sec 5.17

示例：预算约束下的 Cobb-Douglas 效用

$$\max U(x_1, x_2) = x_1^\alpha x_2^{1-\alpha} \quad \text{s.t.} \quad p_1 x_1 + p_2 x_2 = m, \quad 0 < \alpha < 1.$$

并要求讨论：indifference curve 与 budget line 的 tangency point 是否真的是 local maximum。

5.17.1 Step 1: Construct the Lagrangian

构造

$$L(x_1, x_2, \lambda) = x_1^\alpha x_2^{1-\alpha} + \lambda(m - p_1 x_1 - p_2 x_2).$$

5.17.2 Step 2: First-order conditions

分别对 x_1, x_2, λ 求偏导：

$$\frac{\partial L}{\partial x_1} = \alpha x_1^{\alpha-1} x_2^{1-\alpha} - \lambda p_1 = 0,$$

$$\frac{\partial L}{\partial x_2} = (1-\alpha) x_1^\alpha x_2^{-\alpha} - \lambda p_2 = 0,$$

$$\frac{\partial L}{\partial \lambda} = m - p_1 x_1 - p_2 x_2 = 0.$$

前两式相除，得到

$$\frac{\alpha x_1^{\alpha-1} x_2^{1-\alpha}}{(1-\alpha) x_1^\alpha x_2^{-\alpha}} = \frac{p_1}{p_2}.$$

化简得

$$\frac{\alpha}{1-\alpha} \frac{x_2}{x_1} = \frac{p_1}{p_2}.$$

即

$$x_2 = \frac{1-\alpha}{\alpha} \frac{p_1}{p_2} x_1.$$

再代入预算约束

$$p_1 x_1 + p_2 x_2 = m,$$

得到

$$p_1 x_1 + p_2 \left(\frac{1-\alpha}{\alpha} \frac{p_1}{p_2} x_1 \right) = m.$$

化简：

$$p_1 x_1 + \frac{1-\alpha}{\alpha} p_1 x_1 = m,$$

$$p_1 x_1 \left(1 + \frac{1-\alpha}{\alpha} \right) = m.$$

注意

$$1 + \frac{1-\alpha}{\alpha} = \frac{1}{\alpha},$$

因此

$$p_1 x_1 \cdot \frac{1}{\alpha} = m \implies x_1^* = \frac{\alpha m}{p_1}.$$

类似地,

$$x_2^* = \frac{(1 - \alpha)m}{p_2}.$$

这就是 Cobb-Douglas utility 的 Marshallian demand (马歇尔需求):

$$x_1^* = \frac{\alpha m}{p_1}, \quad x_2^* = \frac{(1 - \alpha)m}{p_2}.$$

5.17.3 Step 3: Why is the tangency point a true local maximum?

仅有 tangency 只给出 necessary condition, 还需要验证它确实是 local maximum。这里可以从两种角度说明:

方法一：直接利用偏好性质 因为

$$U(x_1, x_2) = x_1^\alpha x_2^{1-\alpha}, \quad 0 < \alpha < 1,$$

其对数形式为

$$\log U(x_1, x_2) = \alpha \log x_1 + (1 - \alpha) \log x_2,$$

而

$$\log x$$

是 strict concave function, 所以 $\log U$ 是严格凹的。严格递增变换不改变最优点, 因此 U 的 upper contour sets 也是严格凸偏好结构, 对预算线上的切点给出的就是唯一极大值点。

方法二：沿约束检查二阶条件 把预算约束直接解成

$$x_2 = \frac{m - p_1 x_1}{p_2}, \quad 0 < x_1 < \frac{m}{p_1}.$$

于是原问题等价于一元问题

$$\max_{0 < x_1 < m/p_1} \psi(x_1) := x_1^\alpha \left(\frac{m - p_1 x_1}{p_2} \right)^{1-\alpha}.$$

由于对数函数严格递增, 最大化 ψ 等价于最大化

$$\ell(x_1) := \log \psi(x_1) = \alpha \log x_1 + (1 - \alpha) \log(m - p_1 x_1) - (1 - \alpha) \log p_2.$$

对 ℓ 求导:

$$\ell'(x_1) = \frac{\alpha}{x_1} - \frac{(1 - \alpha)p_1}{m - p_1 x_1}.$$

令 $\ell'(x_1) = 0$, 得到

$$\frac{\alpha}{x_1} = \frac{(1 - \alpha)p_1}{m - p_1 x_1},$$

从而

$$x_1^* = \frac{\alpha m}{p_1}, \quad x_2^* = \frac{m - p_1 x_1^*}{p_2} = \frac{(1 - \alpha)m}{p_2}.$$

现在看二阶导数：

$$\ell''(x_1) = -\frac{\alpha}{x_1^2} - \frac{(1 - \alpha)p_1^2}{(m - p_1 x_1)^2} < 0 \quad \forall x_1 \in \left(0, \frac{m}{p_1}\right).$$

因此 ℓ 在整个可行区间上都是 **strictly concave (严格凹)** 的，所以它的驻点必是唯一的全球极大值点。由于 $\log$ 是严格递增变换，这也说明 ψ ，从而原效用函数 U ，在预算线上的切点确实是一个 true local maximum，而且实际上还是唯一的 global maximum。

若用 bordered Hessian 语言来表述，同样会得到“沿预算线切向方向二阶导数为负”的结论；这里把约束代入并化为一元问题，是最直接也最透明的验证方式。

由于预算约束是线性的，

$$g(x_1, x_2) = m - p_1 x_1 - p_2 x_2,$$

所以

$$g_{ij} = 0.$$

于是 bordered Hessian 可简化。再考虑效用函数的二阶导数：

$$U_{11} = \alpha(\alpha - 1)x_1^{\alpha-2}x_2^{1-\alpha} < 0,$$

$$U_{22} = -(1 - \alpha)\alpha x_1^\alpha x_2^{-\alpha-1} < 0,$$

$$U_{12} = \alpha(1 - \alpha)x_1^{\alpha-1}x_2^{-\alpha} > 0.$$

在预算约束切向方向上，效用函数呈现局部向下弯曲，因此切点是 local maximum。结合 Cobb-Douglas 偏好的严格准凹性 (strict quasiconcavity)，该点实际上还是唯一全局最优解。

Sec 5.18 本讲总结

第五讲的逻辑可以概括为以下几层：

1. 从 **unconstrained optimization** 过渡到 **constrained optimization**；
2. 对等式约束问题

$$\max f(x) \text{ s.t. } g(x) = 0,$$

几何上最优点表现为 level curve 与 constraint surface 的 tangency；

3. 代数上，最优点满足

$$\nabla f(x^*) = \lambda_1 \nabla g_1(x^*) + \cdots + \lambda_m \nabla g_m(x^*);$$

4. 这一关系通过 **Lagrangian**

$$L(x, \lambda) = f(x) + \sum_{j=1}^m \lambda_j g_j(x)$$

的一阶条件统一表达；

5. NDCQ

$$\text{rank } Dg(x^*) = m$$

是拉格朗日方法成立的重要 regularity condition;

6. 一阶条件只是 necessary, 需要进一步利用 **bordered Hessian** 做二阶判别;
7. 在经济学中, Cobb-Douglas utility maximization 与 expenditure minimization 是该方法的典型应用。

比较静态与包络定理

Part

Sec 6.1 总览

第六章讨论当 **exogenous variables (外生变量)** 发生变化时，模型中的 **endogenous variables (内生变量)** 与最优值如何变化。这一章的主线有第四步：

1. 从最简单的隐函数方程

$$f(x^*, \alpha) = 0$$

出发，建立比较静态 (comparative statics) 的基本思想；

2. 把比较静态推广到多变量方程组、无约束优化和等式约束优化；
3. 用 bordered Hessian 与 Cramer's rule 把比较静态写成显式公式；
4. 进一步研究 **Envelope Theorem (包络定理)**，说明参数变化对最优值函数的影响为何只取决于“直接效应”。

这一章在经济学中的典型应用包括：市场均衡价格如何随收入变化、最优投入如何随要素价格变化、消费者需求的 Slutsky 分解、间接效用函数 (indirect utility function)、支出函数 (expenditure function)、Roy's Identity 与 Shephard's Lemma。

Sec 6.2 比较静态的基本思想 (Comparative Statics Analysis)

经济模型中通常有两类变量：

- **Endogenous variables (内生变量)**：模型内部决定、需要模型解释的变量；
- **Exogenous variables (外生变量)**：由模型外部给定、被视为参数的变量。

比较静态分析的核心任务是：

当外生变量改变时，均衡值、最优选择或最优值如何变化？

6.2.1 动机一：线性市场模型

设市场需求与供给分别为

$$D = a - bp + cy, \quad a, b, c > 0,$$

$$S = \alpha + \beta p, \quad \alpha, \beta > 0,$$

其中：

- p 是价格 (price);
- y 是消费者总收入 (aggregate income);
- D 随价格上升而下降, 随收入上升而上升;
- S 随价格上升而上升。

市场均衡满足

$$D(p, y) - S(p) = 0.$$

代入得到

$$a - bp + cy - (\alpha + \beta p) = 0,$$

即

$$a - \alpha + cy - (b + \beta)p = 0.$$

因此均衡价格为

$$p^*(y) = \frac{a - \alpha + cy}{b + \beta}.$$

对收入 y 求导:

$$\frac{dp^*}{dy} = \frac{c}{b + \beta} > 0.$$

所以在线性市场模型中, 收入上升会提高均衡价格。这个结论正是比较静态分析想要刻画的对象。




图 6.1: 线性市场模型中的均衡: 需求曲线与供给曲线的交点决定 p^*

6.2.2 动机二: 垄断者产出税

考虑一垄断厂商, 其逆需求函数 (inverse demand function) 和成本函数为

$$p = a - bq, \quad a, b > 0,$$

$$C(q) = cq^2, \quad c > 0.$$

6.3. 单方程比较静态：隐函数方法 (IMPLICIT FUNCTION APPROACH)

政府对每单位产量征收产出税 (output tax) t 。利润函数为

$$\pi(q; t) = p(q)q - C(q) - tq.$$

代入具体形式,

$$\pi(q; t) = (a - bq)q - cq^2 - tq = (a - t)q - (b + c)q^2.$$

一阶条件为

$$\frac{\partial \pi}{\partial q} = a - t - 2(b + c)q = 0,$$

因此最优产量为

$$q^*(t) = \frac{a - t}{2(b + c)}.$$

再对税率 t 求导:

$$\frac{dq^*}{dt} = -\frac{1}{2(b + c)} < 0.$$

于是, 税率上升会降低利润最大化产量。这个例子说明: 比较静态并不只研究一般均衡或市场均衡, 也广泛用于最优化问题。




图 6.2: 产出税对垄断者最优产量的影响: 税率上升使边际利润曲线下移

Sec 6.3

单方程比较静态：隐函数方法 (Implicit Function Approach)

6.3.1 一般形式

设模型均衡由方程

$$f(x^*, \alpha) = 0$$

给出, 其中:

- x^* 是内生变量的均衡值;
- α 是外生参数;

- f 可微。

我们的目标是求

$$\frac{dx^*}{d\alpha}$$

并判断其符号。

Theorem 6.3.1.

设 $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ 可微，且在某点 (x^*, α) 满足

$$f(x^*, \alpha) = 0, \quad f_x(x^*, \alpha) \neq 0.$$

则在该点附近， x^* 可写成 α 的可微函数，且

$$\frac{dx^*}{d\alpha} = -\frac{f_\alpha(x^*, \alpha)}{f_x(x^*, \alpha)}.$$

Proof. 由于 $f_x(x^*, \alpha) \neq 0$ ，由 **Implicit Function Theorem (隐函数定理)**，在该点附近存在可微函数 $x^*(\alpha)$ 使

$$f(x^*(\alpha), \alpha) = 0.$$

对上式关于 α 求导：

$$f_x(x^*(\alpha), \alpha) \frac{dx^*}{d\alpha} + f_\alpha(x^*(\alpha), \alpha) = 0.$$

整理即得

$$\frac{dx^*}{d\alpha} = -\frac{f_\alpha(x^*, \alpha)}{f_x(x^*, \alpha)}.$$

6.3.2 市场均衡例子

在上一节的市场模型中，令

$$f(p, y) := D(p, y) - S(p).$$

则均衡价格 $p^*(y)$ 满足

$$f(p^*(y), y) = 0.$$

应用隐函数公式，

$$\frac{dp^*}{dy} = -\frac{f_y}{f_p} = -\frac{D_y}{D_p - S_p}.$$

在通常假设下：

$$D_y > 0, \quad D_p < 0, \quad S_p > 0.$$

因此

$$D_p - S_p < 0,$$

从而

$$\frac{dp^*}{dy} > 0.$$

所以“收入提高会推高价格”这一结论，并不依赖线性函数的具体形式；只要 excess demand (超额需求) 函数具有通常的符号性质，就能得到同样的定性结论。

Sec 6.4

多变量比较静态 (Comparative Statics with Multiple Variables)

6.4.1 两个内生变量、两个外生变量

设有两个内生变量

$$x_1^*, x_2^*$$

和两个外生变量

$$\alpha_1, \alpha_2.$$

均衡由方程组

$$f^1(x_1^*, x_2^*, \alpha_1, \alpha_2) = 0,$$

$$f^2(x_1^*, x_2^*, \alpha_1, \alpha_2) = 0$$

给出。

假设

$$x_1^* = x_1^*(\alpha_1, \alpha_2), \quad x_2^* = x_2^*(\alpha_1, \alpha_2)$$

在局部可微。对 α_1 求全导数可得

$$f_{x_1}^1 \frac{\partial x_1^*}{\partial \alpha_1} + f_{x_2}^1 \frac{\partial x_2^*}{\partial \alpha_1} + f_{\alpha_1}^1 = 0,$$

$$f_{x_1}^2 \frac{\partial x_1^*}{\partial \alpha_1} + f_{x_2}^2 \frac{\partial x_2^*}{\partial \alpha_1} + f_{\alpha_1}^2 = 0.$$

写成矩阵形式:

$$\begin{bmatrix} f_{x_1}^1 & f_{x_2}^1 \\ f_{x_1}^2 & f_{x_2}^2 \end{bmatrix} \begin{bmatrix} \frac{\partial x_1^*}{\partial \alpha_1} \\ \frac{\partial x_2^*}{\partial \alpha_1} \end{bmatrix} = - \begin{bmatrix} f_{\alpha_1}^1 \\ f_{\alpha_1}^2 \end{bmatrix}.$$

记 Jacobian matrix (雅可比矩阵)

$$J = \begin{bmatrix} f_{x_1}^1 & f_{x_2}^1 \\ f_{x_1}^2 & f_{x_2}^2 \end{bmatrix}, \quad |J| = f_{x_1}^1 f_{x_2}^2 - f_{x_2}^1 f_{x_1}^2.$$

若

$$|J| \neq 0,$$

则该线性系统可解, 比较静态导数存在且局部唯一。

6.4.2 利用 Cramer's rule 求显式公式

由 Cramer's rule (克拉默法则),

$$\frac{\partial x_1^*}{\partial \alpha_1} = \frac{\det \begin{bmatrix} -f_{\alpha_1}^1 & f_{x_2}^1 \\ -f_{\alpha_1}^2 & f_{x_2}^2 \end{bmatrix}}{|J|} = -\frac{f_{\alpha_1}^1 f_{x_2}^2 - f_{\alpha_1}^2 f_{x_2}^1}{|J|},$$

$$\frac{\partial x_2^*}{\partial \alpha_1} = \frac{\det \begin{bmatrix} f_{x_1}^1 & -f_{\alpha_1}^1 \\ f_{x_1}^2 & -f_{\alpha_1}^2 \end{bmatrix}}{|J|} = -\frac{f_{x_1}^1 f_{\alpha_1}^2 - f_{x_1}^2 f_{\alpha_1}^1}{|J|}.$$

对 α_2 完全类似:

$$\begin{aligned} \frac{\partial x_1^*}{\partial \alpha_2} &= -\frac{f_{\alpha_2}^1 f_{x_2}^2 - f_{\alpha_2}^2 f_{x_2}^1}{|J|}, \\ \frac{\partial x_2^*}{\partial \alpha_2} &= -\frac{f_{x_1}^1 f_{\alpha_2}^2 - f_{x_1}^2 f_{\alpha_2}^1}{|J|}. \end{aligned}$$

这些公式的重要意义在于: 比较静态的符号完全由 Jacobian 的符号结构与参数进入方式决定。

6.4.3 Cramer's rule 回顾

设线性方程组

$$Ax = b,$$

其中 A 是 $n \times n$ 矩阵, $x = (x_1, \dots, x_n)^\top$, $b = (b_1, \dots, b_n)^\top$ 。若

$$D := \det(A) \neq 0,$$

并记 D_i 为把 A 的第 i 列替换为向量 b 后所得矩阵的行列式, 则

$$x_i = \frac{D_i}{D}, \quad i = 1, \dots, n.$$

比较静态公式之所以经常写成“某个行列式除以某个 Jacobian 或 bordered Hessian 行列式”, 正是因为它们本质上都来自 Cramer's rule。

Sec 6.5 无约束优化问题的比较静态 (Comparative Statics for Unconstrained Optimization)

6.5.1 一般问题

考虑参数化优化问题

$$\max_{x \in \mathbb{R}^n} F(x; a),$$

其中:

- $x = (x_1, \dots, x_n)$ 是选择变量;
- a 是外生参数;
- F 可微。

若 $x^*(a)$ 是局部最优解, 则一阶必要条件为

$$\frac{\partial F}{\partial x_i}(x^*(a); a) = 0, \quad i = 1, \dots, n.$$

6.5. 无约束优化问题的比较静态 (COMPARATIVE STATICS FOR UNCONSTRAINED OPTIMIZATION)

6.5.2 Implicit Function Theorem 与 Hessian

把一阶条件视为一个关于 x 的方程组。该方程组对 x 的 Jacobian 为

$$\left[\frac{\partial^2 F}{\partial x_i \partial x_j} \right]_{i,j=1}^n = \nabla_{xx}^2 F(x^*(a); a),$$

即 Hessian matrix (海森矩阵)。

Proposition 6.5.1.

若

$$\det \nabla_{xx}^2 F(x^*(a); a) \neq 0,$$

则一阶条件在局部可唯一解出 $x^*(a)$ 为参数 a 的可微函数。

特别地, 若是在最大化问题中满足二阶充分条件

$$\nabla_{xx}^2 F(x^*(a); a) \text{ negative definite},$$

则 Hessian 必可逆, 因此比较静态在局部成立。

6.5.3 比较静态公式

对一阶条件

$$\nabla_x F(x^*(a); a) = 0$$

关于参数 a 求导, 得到

$$\nabla_{xx}^2 F(x^*(a); a) \frac{dx^*(a)}{da} + \nabla_{xa}^2 F(x^*(a); a) = 0.$$

因此

$$\frac{dx^*(a)}{da} = -[\nabla_{xx}^2 F(x^*(a); a)]^{-1} \nabla_{xa}^2 F(x^*(a); a).$$

这就是无约束优化的比较静态公式。它说明:

- Hessian 刻画局部曲率 (curvature);
- mixed partials (交叉偏导) 刻画参数变化如何直接影响一阶条件;
- 两者共同决定最优解如何响应参数变化。

6.5.4 例子: 竞争性厂商的要素需求

考虑利润最大化问题

$$\max_{L, K} \pi(L, K; w, r) = pf(L, K) - wL - rK,$$

其中 p 给定, w, r 分别是工资率与资本租金率。

一阶条件为

$$pf_L(L^*, K^*) - w = 0,$$

$$pf_K(L^*, K^*) - r = 0.$$

对工资率 w 求导:

$$pf_{LL} \frac{\partial L^*}{\partial w} + pf_{LK} \frac{\partial K^*}{\partial w} - 1 = 0,$$

$$pf_{KL} \frac{\partial L^*}{\partial w} + pf_{KK} \frac{\partial K^*}{\partial w} = 0.$$

写成矩阵形式:

$$p \begin{bmatrix} f_{LL} & f_{LK} \\ f_{KL} & f_{KK} \end{bmatrix} \begin{bmatrix} \frac{\partial L^*}{\partial w} \\ \frac{\partial K^*}{\partial w} \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

若生产函数严格凹, 则

$$\begin{bmatrix} f_{LL} & f_{LK} \\ f_{KL} & f_{KK} \end{bmatrix}$$

负定, 从而其行列式为负且 $f_{LL}, f_{KK} < 0$ 。应用 Cramer's rule,

$$\frac{\partial L^*}{\partial w} = \frac{f_{KK}}{p(f_{LL}f_{KK} - f_{LK}^2)} < 0.$$

这说明工资上升会降低最优劳动需求。至于

$$\frac{\partial K^*}{\partial w} = -\frac{f_{KL}}{p(f_{LL}f_{KK} - f_{LK}^2)},$$

其符号取决于劳动与资本在技术上是 substitutes (替代品) 还是 complements (互补品)。

Sec 6.6

等式约束优化问题的比较静态 (Comparative Statics for Equality Constrained Optimization)

6.6.1 一般形式

考虑问题

$$\max_x F(x; a) \quad \text{s.t.} \quad g(x; a) = b.$$

定义

$$h(x; a, b) := b - g(x; a),$$

并构造拉格朗日函数

$$L(x, \lambda; a, b) = F(x; a) + \lambda h(x; a, b).$$

一阶条件为

$$\frac{\partial L}{\partial \lambda} = h(x^*; a, b) = 0,$$

$$\frac{\partial L}{\partial x_i} = \frac{\partial F}{\partial x_i}(x^*; a) + \lambda^* \frac{\partial h}{\partial x_i}(x^*; a, b) = 0, \quad i = 1, \dots, n.$$

这给出了 $n+1$ 个方程, 未知数是

$$\lambda^*, x_1^*, \dots, x_n^*.$$

6.6. 等式约束优化问题的比较静态 (COMPARATIVE STATICS FOR EQUALITY CONSTRAINED OPTIMIZATION)

6.6.2 Jacobian 与 bordered Hessian

把这些一阶条件对 (λ, x) 求偏导, 得到的 Jacobian 正是 bordered Hessian (加边海森矩阵) 结构。若该 Jacobian 可逆, 则由隐函数定理, 最优解与乘子都可写成参数 (a, b) 的可微函数。

更准确地说, 在二元单约束情形中, 若约束写成

$$g(x_1, x_2; \alpha) = 0,$$

拉格朗日函数为

$$L(x_1, x_2, \lambda; \alpha) = F(x_1, x_2; \alpha) + \lambda g(x_1, x_2; \alpha),$$

则一阶条件为

$$g(x_1^*, x_2^*; \alpha) = 0,$$

$$L_{x_1}(x_1^*, x_2^*, \lambda^*; \alpha) = 0,$$

$$L_{x_2}(x_1^*, x_2^*, \lambda^*; \alpha) = 0.$$

6.6.3 二维、单约束情形的矩阵推导

对参数 α_j 求导, 得到

$$g_{x_1} \frac{\partial x_1^*}{\partial \alpha_j} + g_{x_2} \frac{\partial x_2^*}{\partial \alpha_j} + g_{\alpha_j} = 0,$$

$$L_{x_1 \lambda} \frac{\partial \lambda^*}{\partial \alpha_j} + L_{x_1 x_1} \frac{\partial x_1^*}{\partial \alpha_j} + L_{x_1 x_2} \frac{\partial x_2^*}{\partial \alpha_j} + L_{x_1 \alpha_j} = 0,$$

$$L_{x_2 \lambda} \frac{\partial \lambda^*}{\partial \alpha_j} + L_{x_2 x_1} \frac{\partial x_1^*}{\partial \alpha_j} + L_{x_2 x_2} \frac{\partial x_2^*}{\partial \alpha_j} + L_{x_2 \alpha_j} = 0.$$

注意

$$L_{x_1 \lambda} = g_{x_1}, \quad L_{x_2 \lambda} = g_{x_2}, \quad L_{\lambda \lambda} = 0.$$

因此矩阵形式为

$$\underbrace{\begin{bmatrix} 0 & g_{x_1} & g_{x_2} \\ g_{x_1} & L_{x_1 x_1} & L_{x_1 x_2} \\ g_{x_2} & L_{x_2 x_1} & L_{x_2 x_2} \end{bmatrix}}_H \begin{bmatrix} \frac{\partial \lambda^*}{\partial \alpha_j} \\ \frac{\partial x_1^*}{\partial \alpha_j} \\ \frac{\partial x_2^*}{\partial \alpha_j} \end{bmatrix} = - \begin{bmatrix} g_{\alpha_j} \\ L_{x_1 \alpha_j} \\ L_{x_2 \alpha_j} \end{bmatrix}.$$

这里的矩阵 H 就是课件中的 bordered Hessian。

6.6.4 显式比较静态公式

若

$$\det(H) \neq 0,$$

则

$$\frac{\partial \lambda^*}{\partial \alpha_j} = \frac{\det(H_1(\alpha_j))}{\det(H)},$$

$$\frac{\partial x_1^*}{\partial \alpha_j} = \frac{\det(H_2(\alpha_j))}{\det(H)},$$

$$\frac{\partial x_2^*}{\partial \alpha_j} = \frac{\det(H_3(\alpha_j))}{\det(H)},$$

其中 $H_i(\alpha_j)$ 表示把 H 的第 i 列替换为

$$\begin{bmatrix} -g_{\alpha_j} \\ -L_{x_1\alpha_j} \\ -L_{x_2\alpha_j} \end{bmatrix}$$

所得的新矩阵。

这组公式是等式约束优化的比较静态基础, 后面的 Slutsky 方程和包络定理应用都直接建立在它上面。

Sec 6.7

应用: Slutsky 方程 (Slutsky Equation)

6.7.1 效用最大化问题

考虑消费者问题

$$\max_{x_1, x_2} u(x_1, x_2) \quad \text{s.t.} \quad p_1 x_1 + p_2 x_2 = m.$$

拉格朗日函数为

$$L(x_1, x_2, \lambda) = u(x_1, x_2) + \lambda(m - p_1 x_1 - p_2 x_2).$$

一阶条件为

$$u_1(x_1^*, x_2^*) - \lambda^* p_1 = 0,$$

$$u_2(x_1^*, x_2^*) - \lambda^* p_2 = 0,$$

$$m - p_1 x_1^* - p_2 x_2^* = 0.$$

它们隐式定义了 Marshallian demand (马歇尔需求)

$$x_1^*(p_1, p_2, m), \quad x_2^*(p_1, p_2, m).$$

6.7.2 关于价格的比较静态

对 p_1 求导可得

$$u_{11} \frac{\partial x_1^*}{\partial p_1} + u_{12} \frac{\partial x_2^*}{\partial p_1} - p_1 \frac{\partial \lambda^*}{\partial p_1} - \lambda^* = 0,$$

$$u_{21} \frac{\partial x_1^*}{\partial p_1} + u_{22} \frac{\partial x_2^*}{\partial p_1} - p_2 \frac{\partial \lambda^*}{\partial p_1} = 0,$$

$$-p_1 \frac{\partial x_1^*}{\partial p_1} - p_2 \frac{\partial x_2^*}{\partial p_1} = x_1^*.$$

6.7. 应用: SLUTSKY 方程 (SLUTSKY EQUATION)

写成矩阵形式:

$$\begin{bmatrix} 0 & -p_1 & -p_2 \\ -p_1 & u_{11} & u_{12} \\ -p_2 & u_{21} & u_{22} \end{bmatrix} \begin{bmatrix} \frac{\partial \lambda^*}{\partial p_1} \\ \frac{\partial x_1^*}{\partial p_1} \\ \frac{\partial x_2^*}{\partial p_1} \end{bmatrix} = \begin{bmatrix} x_1^* \\ \lambda^* \\ 0 \end{bmatrix}.$$

记

$$|D| = \det \begin{bmatrix} 0 & -p_1 & -p_2 \\ -p_1 & u_{11} & u_{12} \\ -p_2 & u_{21} & u_{22} \end{bmatrix}.$$

对最大化问题, 在常规二阶条件下有

$$|D| > 0.$$

应用 Cramer's rule 可得

$$\begin{aligned} \frac{\partial x_1^*}{\partial p_1} &= -\frac{\lambda^* p_2^2}{|D|} + \frac{x_1^* (p_1 u_{22} - p_2 u_{12})}{|D|}, \\ \frac{\partial x_2^*}{\partial p_1} &= \frac{\lambda^* p_1 p_2}{|D|} + \frac{x_1^* (p_2 u_{11} - p_1 u_{21})}{|D|}. \end{aligned}$$

同理可得关于收入的比较静态:

$$\begin{aligned} \frac{\partial x_1^*}{\partial m} &= -\frac{p_1 u_{22} - p_2 u_{12}}{|D|}, \\ \frac{\partial x_2^*}{\partial m} &= -\frac{p_2 u_{11} - p_1 u_{21}}{|D|}. \end{aligned}$$

6.7.3 Slutsky 方程

把上一组公式合并, 可得

$$\frac{\partial x_1^*}{\partial p_1} = -\frac{\lambda^* p_2^2}{|D|} - x_1^* \frac{\partial x_1^*}{\partial m}.$$

右边分为两部分:

- $$-\frac{\lambda^* p_2^2}{|D|}$$

是 substitution effect (替代效应);

- $$-x_1^* \frac{\partial x_1^*}{\partial m}$$

是 income effect (收入效应)。

在通常情形下:

- $\lambda^* > 0$, 因此 substitution effect 恒为负;
- income effect 的符号取决于商品是 normal 还是 inferior。

6.7.4 正常品、劣等品与 Giffen goods

根据收入效应的符号, 可以把商品分成:

- Normal good (正常品):

$$\frac{\partial x_i^*}{\partial m} > 0;$$

- Strictly inferior good (严格劣等品):

$$\frac{\partial x_i^*}{\partial m} < 0;$$

- Weakly inferior good (弱劣等品):

$$\frac{\partial x_i^*}{\partial m} = 0.$$

于是:

- 对正常品, 替代效应与收入效应都使需求下降, 所以

$$\frac{\partial x_i^*}{\partial p_i} < 0;$$

- 对劣等品, 二者方向相反;

- 若收入效应的绝对值大于替代效应, 就会出现 **Giffen good (吉芬品)**, 即

$$\frac{\partial x_i^*}{\partial p_i} > 0.$$

6.7.5 Cobb-Douglas 例子

设

$$u(x_1, x_2) = x_1^{1/2} x_2^{1/2}.$$

其最优需求为

$$x_1^* = \frac{m}{2p_1}, \quad x_2^* = \frac{m}{2p_2}.$$

因此

$$\frac{\partial x_1^*}{\partial p_1} = -\frac{m}{2p_1^2}, \quad \frac{\partial x_1^*}{\partial m} = \frac{1}{2p_1}.$$

于是收入效应部分为

$$-x_1^* \frac{\partial x_1^*}{\partial m} = -\frac{m}{2p_1} \cdot \frac{1}{2p_1} = -\frac{m}{4p_1^2}.$$

所以 substitution effect 必须为

$$-\frac{m}{2p_1^2} - \left(-\frac{m}{4p_1^2}\right) = -\frac{m}{4p_1^2}.$$

这个例子说明: 对 Cobb-Douglas 效用而言, 替代效应与收入效应都为负, 因此商品一定是 ordinary good (普通品), 不是 Giffen goods。

Sec 6.8

包络定理 (Envelope Theorem)

6.8.1 无约束优化情形

考虑问题

$$\max_x F(x; a),$$

并定义 value function (值函数)

$$V(a) := F(x^*(a); a).$$

Theorem 6.8.2.

无约束包络定理 若 $x^*(a)$ 是可微最优解, 则

$$\frac{dV(a)}{da} = \frac{\partial F}{\partial a}(x^*(a); a).$$

Proof. 由链式法则,

$$\frac{dV}{da} = \sum_{i=1}^n \frac{\partial F}{\partial x_i}(x^*(a); a) \frac{dx_i^*}{da} + \frac{\partial F}{\partial a}(x^*(a); a).$$

由于 $x^*(a)$ 是内部最优解, 一阶条件给出

$$\frac{\partial F}{\partial x_i}(x^*(a); a) = 0, \quad i = 1, \dots, n.$$

因此所有通过最优选择变化带来的间接项都消失, 只剩

$$\frac{dV}{da} = \frac{\partial F}{\partial a}(x^*(a); a).$$

这说明: 最优值对参数的边际变化, 等于把最优选择暂时固定住时的“直接偏导数”。

6.8.2 等式约束优化情形

考虑问题

$$\max_{x_1, x_2} f(x_1, x_2; \alpha) \quad \text{s.t.} \quad g(x_1, x_2; \alpha) = 0.$$

拉格朗日函数为

$$L(x_1, x_2, \lambda; \alpha) = f(x_1, x_2; \alpha) + \lambda g(x_1, x_2; \alpha).$$

设最优解与乘子写成

$$x_1^* = x_1^*(\alpha), \quad x_2^* = x_2^*(\alpha), \quad \lambda^* = \lambda^*(\alpha).$$

定义值函数

$$V(\alpha) = f(x_1^*(\alpha), x_2^*(\alpha); \alpha).$$

6.8.3 推导

先对拉格朗日函数沿最优轨道求导:

$$\begin{aligned}\frac{dL}{d\alpha} &= (f_{x_1} + \lambda g_{x_1}) \frac{dx_1^*}{d\alpha} + (f_{x_2} + \lambda g_{x_2}) \frac{dx_2^*}{d\alpha} \\ &\quad + g \frac{d\lambda^*}{d\alpha} + (f_\alpha + \lambda g_\alpha).\end{aligned}$$

在最优点, 一阶条件与约束条件给出

$$f_{x_1} + \lambda^* g_{x_1} = 0, \quad f_{x_2} + \lambda^* g_{x_2} = 0, \quad g = 0.$$

因此

$$\frac{dL}{d\alpha} = f_\alpha + \lambda^* g_\alpha = \frac{\partial L}{\partial \alpha}.$$

另一方面, 对值函数直接求导:

$$\frac{dV}{d\alpha} = f_{x_1} \frac{dx_1^*}{d\alpha} + f_{x_2} \frac{dx_2^*}{d\alpha} + f_\alpha.$$

再用

$$f_{x_i} = -\lambda^* g_{x_i}$$

代入:

$$\frac{dV}{d\alpha} = -\lambda^* \left(g_{x_1} \frac{dx_1^*}{d\alpha} + g_{x_2} \frac{dx_2^*}{d\alpha} \right) + f_\alpha.$$

而由约束

$$g(x_1^*(\alpha), x_2^*(\alpha); \alpha) = 0$$

求导, 得

$$g_{x_1} \frac{dx_1^*}{d\alpha} + g_{x_2} \frac{dx_2^*}{d\alpha} = -g_\alpha.$$

于是

$$\frac{dV}{d\alpha} = f_\alpha + \lambda^* g_\alpha = \frac{\partial L}{\partial \alpha}.$$

Theorem 6.8.3.

等式约束包络定理 在上述条件下,

$$\frac{dV}{d\alpha} = \frac{\partial L}{\partial \alpha} = f_\alpha + \lambda^* g_\alpha.$$

6.8.4 一般形式

若问题为

$$\max f(x_1, \dots, x_n; \alpha_1, \dots, \alpha_m)$$

满足 K 个等式约束

$$g^k(x_1, \dots, x_n; \alpha_1, \dots, \alpha_m) = 0, \quad k = 1, \dots, K,$$

对应拉格朗日函数

$$L = f + \sum_{k=1}^K \lambda_k g^k,$$

则对任意参数 α_j ,

$$\frac{\partial V}{\partial \alpha_j} = \frac{\partial L}{\partial \alpha_j} = f_{\alpha_j} + \sum_{k=1}^K \lambda_k^* g_{\alpha_j}^k.$$

6.8.5 拉格朗日乘子的经济学含义

若约束写成

$$g^k(x) + \alpha_k = 0, \quad k = 1, \dots, K,$$

则

$$\frac{\partial V}{\partial \alpha_k} = \lambda_k^*.$$

因此拉格朗日乘子可以解释为:

约束右端放松一单位时, 最优值提高多少。

这也是 shadow price (影子价格) 或 shadow value (影子价值) 的来源。

Sec 6.9 包络定理的经济学应用

6.9.1 长短期成本曲线

长期成本最小化问题为

$$\min_{L, K} C = wL + rK \quad \text{s.t.} \quad y = f(L, K).$$

由一阶条件可解出条件要素需求

$$L = L(w, r, y), \quad K = K(w, r, y),$$

从而得到长期成本函数

$$C(w, r, y) = wL(w, r, y) + rK(w, r, y).$$

短期中资本固定为 K_a , 于是问题变为

$$\min_L c = wL + F_a \quad \text{s.t.} \quad y = f(L, K_a),$$

其中

$$F_a = rK_a$$

是固定成本。设最优劳动投入为

$$L = \phi(y, K_a),$$

则短期成本函数为

$$c(y, K_a) = w\phi(y, K_a) + F_a.$$

对任意给定 y , 长期可以在所有 K_a 中选出成本最低者, 因此

$$C(y) = \min_K c(y, K).$$

于是对任意固定的 K_a 都有

$$C(y) \leq c(y, K_a),$$

而当 $K_a = K^*(y)$ 时取等号。也就是说, 长期成本曲线是短期成本曲线族的下包络 (envelope)。

由包络定理,

$$C'(y) = \left. \frac{\partial c(y, K)}{\partial y} \right|_{K=K^*(y)}.$$

因此在切点处, 长期成本曲线与相应的短期成本曲线斜率相同, 二者相切 (tangent)。




图 6.3: 长期成本曲线作为短期成本曲线族的下包络

6.9.2 数值例子

考虑

$$\max_{x \in \mathbb{R}} f(x, \theta) = -\frac{x^2}{2} + \theta x - \frac{\theta^2}{4}.$$

一阶条件为

$$-x + \theta = 0,$$

所以最优解

$$x(\theta) = \theta.$$

值函数为

$$v(\theta) = f(x(\theta), \theta) = -\frac{\theta^2}{2} + \theta^2 - \frac{\theta^2}{4} = \frac{\theta^2}{4}.$$

于是

$$v'(\theta) = \frac{\theta}{2}.$$

另一方面,

$$\frac{\partial f}{\partial \theta} = x - \frac{\theta}{2}.$$

在最优点 $x = \theta$ 处,

$$\left. \frac{\partial f}{\partial \theta} \right|_{x=\theta} = \theta - \frac{\theta}{2} = \frac{\theta}{2} = v'(\theta).$$

这正是包络定理。




图 6.4: 包络定理的图形直观: 值函数与参数化目标函数在最优点处相切

6.9.3 应用: shadow wage rate

考虑一个小型开放经济, 有两个部门, 生产函数为

$$x_i = a_i L_i^b, \quad a_i > 0, \quad 0 < b < 1, \quad i = 1, 2,$$

且总劳动供给固定为

$$L_1 + L_2 = L^0.$$

在世界价格 p_1, p_2 给定下, 中央计划者最大化国民产值:

$$\max_{L_1, L_2} Y = p_1 x_1 + p_2 x_2 \quad \text{s.t.} \quad L_1 + L_2 = L^0.$$

拉格朗日函数为

$$\mathcal{L} = p_1 a_1 L_1^b + p_2 a_2 L_2^b + \lambda(L^0 - L_1 - L_2).$$

一阶条件为

$$b p_i a_i L_i^{b-1} - \lambda^* = 0, \quad i = 1, 2.$$

于是可得到最优劳动配置

$$L_1^* = c_1(p_1, p_2) L^0, \quad L_2^* = c_2(p_1, p_2) L^0.$$

把它们代回目标函数，得到值函数

$$V(p_1, p_2, L^0).$$

由包络定理，

$$\frac{\partial V}{\partial L^0} = \lambda^*.$$

因此 λ^* 就是劳动约束的 shadow wage rate (影子工资率)：多一单位劳动供给能给经济带来多少额外产值。

同理，

$$\frac{\partial V}{\partial p_i} = x_i^*, \quad i = 1, 2,$$

因为价格上升一单位时，最优产值的边际增加恰好等于该商品的最优产量。

6.9.4 间接效用函数与 Roy's Identity

消费者效用最大化问题为

$$\max_{x_1, x_2} u(x_1, x_2) \quad \text{s.t.} \quad p_1 x_1 + p_2 x_2 = m.$$

把 Marshallian demand 代回效用函数，得到 indirect utility function (间接效用函数)

$$V(p_1, p_2, m) = u(x_1^*(p_1, p_2, m), x_2^*(p_1, p_2, m)).$$

对拉格朗日函数

$$L = u(x_1, x_2) + \lambda(m - p_1 x_1 - p_2 x_2)$$

应用包络定理，可得

$$\begin{aligned} \frac{\partial V}{\partial m} &= \lambda^*, \\ \frac{\partial V}{\partial p_i} &= -\lambda^* x_i^*(p_1, p_2, m), \quad i = 1, 2. \end{aligned}$$

因此

$$x_i^*(p_1, p_2, m) = -\frac{\partial V(p_1, p_2, m)/\partial p_i}{\partial V(p_1, p_2, m)/\partial m}, \quad i = 1, 2.$$

这就是 Roy's Identity (罗伊恒等式)。

6.9.5 支出函数与 Shephard's Lemma

给定目标效用 $\bar{u}$ ，消费者的支出最小化问题为

$$\min_{x_1, x_2} E = p_1 x_1 + p_2 x_2 \quad \text{s.t.} \quad u(x_1, x_2) = \bar{u}.$$

拉格朗日函数为

$$L = p_1 x_1 + p_2 x_2 + \mu(\bar{u} - u(x_1, x_2)).$$

最优解给出 Hicksian demand (希克斯需求)

$$h_1(p_1, p_2, \bar{u}), \quad h_2(p_1, p_2, \bar{u}),$$

并导出 expenditure function (支出函数)

$$E(p_1, p_2, \bar{u}) = p_1 h_1(p_1, p_2, \bar{u}) + p_2 h_2(p_1, p_2, \bar{u}).$$

应用包络定理:

$$\frac{\partial E}{\partial \bar{u}} = \mu^*,$$

$$\frac{\partial E}{\partial p_i} = h_i(p_1, p_2, \bar{u}), \quad i = 1, 2.$$

最后一式就是 Shephard's Lemma (谢泼德引理)。

它的经济学含义非常直接: 若消费者在保持效用不变的前提下会购买 h_i 单位商品 i , 那么该商品价格每上涨 1 单位, 维持同一效用所需的最小支出就会上升 h_i 。

6.9.6 经验需求分析中的一个应用: AIDS

Almost Ideal Demand System (AIDS) 的一个经典思路是:

1. 先设定支出函数 $e(p, u)$;
2. 再利用 Shephard's Lemma 求 Hicksian demand;
3. 最后写成 budget share equation (预算份额方程)。

对应的经验方程常写成

$$w_i = \alpha_i + \sum_j \gamma_{ij} \log p_j + \beta_i \log(I/P),$$

其中:

- w_i 是商品 i 的支出份额;
- I 是总支出;
- P 是价格指数。

这说明: 包络定理与 Shephard's Lemma 并不只是理论工具, 它们还直接进入实证需求系统的构造。

Sec 6.10 本讲总结

第六章的逻辑可以概括为:

1. 比较静态研究的是外生参数变化如何影响内生均衡与最优解;
2. 在单方程情形中, 隐函数公式给出

$$\frac{dx^*}{d\alpha} = -\frac{f_\alpha}{f_x};$$

3. 在多变量系统中, Jacobian 与 Cramer's rule 给出显式比较静态公式;
4. 在无约束优化中, Hessian 的可逆性保证局部比较静态成立;
5. 在等式约束优化中, bordered Hessian 扮演同样角色;
6. Slutsky equation 把价格效应分解为 substitution effect 与 income effect;
7. Envelope Theorem 说明最优值对参数的边际影响只等于 Lagrangian 的直接偏导;
8. Roy's Identity 与 Shephard's Lemma 是包络定理在消费者理论中的两个核心应用。



Sec 7.1 总览

第七章从线性不等式约束出发, 引出 **Karush-Kuhn-Tucker conditions (KKT 条件)**, 并说明在何种条件下它既是必要条件, 也是充分条件。整章主线如下:

1. 从一个线性不等式约束出发, 用 feasible direction (可行方向) 推导必要条件;
2. 推广到多个线性不等式约束, 并引出 complementary slackness (互补松弛);
3. 再推广到同时含不等式与等式约束的情形;
4. 对非线性约束, 说明为什么需要 constraint qualification (约束资格条件);
5. 在 convex optimization (凸优化) 中, 证明 KKT 条件不仅必要, 而且充分。

Sec 7.2 单个线性不等式约束

7.2.1 问题设定

考虑二元问题

$$\min_{x_1, x_2} f(x_1, x_2) \quad \text{s.t.} \quad a_1 x_1 + a_2 x_2 \leq c,$$

其中 f 可微, a_1, a_2, c 为常数。

约束集合为

$$\Omega = \{x = (x_1, x_2) \mid a_1 x_1 + a_2 x_2 \leq c\}.$$

其边界是直线

$$a_1 x_1 + a_2 x_2 = c,$$

法向量为

$$a = \begin{bmatrix} a_1 \\ a_2 \end{bmatrix}.$$

7.2.2 内部解与边界解

若最优解 $x^* = (x_1^*, x_2^*)$ 满足

$$a_1 x_1^* + a_2 x_2^* < c,$$

则它是内部点 (interior point), 附近可以自由小幅移动, 因此必须满足

$$\nabla f(x^*) = 0.$$

若

$$a_1 x_1^* + a_2 x_2^* = c,$$

则约束是 **binding (紧的)** 或 **active (活跃的)**。这时并非所有方向都可行，需要研究可行方向。




图 7.1: 单个线性不等式约束的可行区域与可行方向

7.2.3 可行方向与必要条件

设从 x^* 沿方向 d 做小移动:

$$x = x^* + td, \quad t > 0 \text{ 很小.}$$

若 x 保持可行, 则必须有

$$\langle a, x^* + td \rangle \leq c.$$

由于 $\langle a, x^* \rangle = c$, 可行性等价于

$$t\langle a, d \rangle \leq 0 \iff \langle a, d \rangle \leq 0.$$

另一方面, 由于 x^* 是最优解, 沿任何可行方向都不能让目标函数下降, 因此

$$f(x^* + td) \geq f(x^*) \quad \text{for all small } t > 0.$$

两边相减并除以 t , 令 $t \downarrow 0$, 得到

$$0 \leq \lim_{t \downarrow 0} \frac{f(x^* + td) - f(x^*)}{t} = \langle \nabla f(x^*), d \rangle.$$

等价地,

$$\langle -\nabla f(x^*), d \rangle \leq 0.$$

这说明: 在最优点, 负梯度方向 $-\nabla f(x^*)$ 不可能指向任何可行下降方向。

7.2.4 正式结论

Proposition 7.2.1.

考虑问题

$$\min_x f(x) \quad s.t. \quad \langle a, x \rangle \leq c,$$

其中 f 可微, $a \neq 0$ 。若 x^* 是解, 则存在 $\lambda \geq 0$ 使

$$\nabla f(x^*) + \lambda a = 0.$$

Proof. 若约束不紧, 即

$$\langle a, x^* \rangle < c,$$

则 x^* 是内部点, 故

$$\nabla f(x^*) = 0.$$

取 $\lambda = 0$ 即可。

若约束紧, 即

$$\langle a, x^* \rangle = c,$$

则对任意满足 $\langle a, d \rangle \leq 0$ 的可行方向, 都有

$$\langle \nabla f(x^*), d \rangle \geq 0.$$

特别地, 若 d 满足

$$\langle a, d \rangle = 0,$$

则 d 与 $-d$ 都是可行方向, 于是

$$\langle \nabla f(x^*), d \rangle \geq 0, \quad \langle \nabla f(x^*), -d \rangle \geq 0.$$

两式合并得

$$\langle \nabla f(x^*), d \rangle = 0$$

对所有切向量 d 都成立。于是 $\nabla f(x^*)$ 与边界的切空间正交, 只能平行于法向量 a , 故存在实数 λ 使

$$\nabla f(x^*) = -\lambda a.$$

再取方向

$$d = -a.$$

因为

$$\langle a, d \rangle = -\|a\|^2 < 0,$$

所以 d 是可行方向。由必要条件,

$$\langle \nabla f(x^*), -a \rangle \geq 0.$$

代入 $\nabla f(x^*) = -\lambda a$ 得

$$\lambda \|a\|^2 \geq 0,$$

从而

$$\lambda \geq 0.$$

故命题得证。■

Sec 7.3 多个线性不等式约束

7.3.1 可行方向

现在考虑

$$\min_x f(x)$$

满足两个线性约束

$$\langle a_1, x \rangle \leq c_1, \quad \langle a_2, x \rangle \leq c_2.$$

记

$$g_i(x) = \langle a_i, x \rangle - c_i, \quad i = 1, 2.$$

Definition 7.3.1.

向量 d 称为点 x^* 处的 **feasible direction** (可行方向), 如果对充分小的 $t > 0$ 都有

$$x^* + td \in \Omega.$$

若 d 是可行方向, 且 x^* 是极小值点, 那么同样有

$$\langle \nabla f(x^*), d \rangle \geq 0 \iff \langle -\nabla f(x^*), d \rangle \leq 0.$$




图 7.2: 多个线性不等式约束的可行区域与可行方向

7.3.2 KKT 条件的线性约束版本

此时最优点处的负梯度必须位于活跃约束法向量张成的锥 (cone) 内。于是存在

$$\lambda_1, \lambda_2 \geq 0$$

使

$$-\nabla f(x^*) = \lambda_1 a_1 + \lambda_2 a_2.$$

等价地,

$$\nabla f(x^*) + \lambda_1 \nabla g_1(x^*) + \lambda_2 \nabla g_2(x^*) = 0.$$

Theorem 7.3.1.

线性不等式约束下的 KKT 条件 考虑问题

$$\min_x f(x) \quad s.t. \quad g_i(x) \leq 0, \quad i = 1, \dots, I,$$

其中每个 g_i 都是线性的, 且 f 可微。若 x^* 是解, 则存在乘子

$$\lambda_1, \dots, \lambda_I$$

使

$$\begin{aligned} \nabla f(x^*) + \sum_{i=1}^I \lambda_i \nabla g_i(x^*) &= 0, \\ \lambda_i &\geq 0, \quad g_i(x^*) \leq 0, \quad \lambda_i g_i(x^*) = 0 \quad (i = 1, \dots, I). \end{aligned}$$

其中最后一个条件

$$\lambda_i g_i(x^*) = 0$$

称为 complementary slackness (互补松弛)。它表示:

- 若约束不紧, 即 $g_i(x^*) < 0$, 则必须有 $\lambda_i = 0$;
- 若 $\lambda_i > 0$, 则约束必紧, 即 $g_i(x^*) = 0$ 。

7.3.3 拉格朗日解释

对不等式约束问题, 定义拉格朗日函数

$$L(x, \lambda) = f(x) + \sum_{i=1}^I \lambda_i g_i(x).$$

若把 λ 暂时当作常数, 则关于 x 的一阶条件为

$$\nabla_x L(x, \lambda) = \nabla f(x) + \sum_{i=1}^I \lambda_i \nabla g_i(x) = 0.$$

这就是 KKT 的第一组方程。它告诉我们: 不等式约束下的最优点, 仍然可以视为“某个拉格朗日函数的驻点 (stationary point)”, 只是多了非负性和互补松弛条件。

Sec 7.4 同时含等式与不等式约束

7.4.1 把等式约束改写成两条不等式

考虑问题

$$\min_x f(x)$$

7.4. 同时含等式与不等式约束

满足

$$\langle a, x \rangle \leq c, \quad \langle b, x \rangle = d.$$

等式约束可以写成两条不等式:

$$\langle b, x \rangle - d \leq 0, \quad \langle -b, x \rangle + d \leq 0.$$

因此原问题等价于只有不等式的 KKT 问题。

7.4.2 乘子符号为什么不同

设对应的三个不等式约束乘子分别为

$$\lambda_1, \lambda_2, \lambda_3 \geq 0.$$

一阶条件为

$$\nabla f(x^*) + \lambda_1 a + \lambda_2 b + \lambda_3 (-b) = 0.$$

令

$$\lambda := \lambda_1, \quad \mu := \lambda_2 - \lambda_3,$$

则

$$\nabla f(x^*) + \lambda a + \mu b = 0.$$

这里 $\lambda \geq 0$, 但 μ 可以为正、为负或为零。原因在于等式约束本身没有“只朝一个方向限制”的性质, 所以其乘子没有符号限制。

7.4.3 一般形式

Theorem 7.4.2.

同时含不等式与等式约束的 KKT 条件 考虑问题

$$\min_x f(x)$$

满足

$$g_i(x) \leq 0, \quad i = 1, \dots, I,$$

$$h_j(x) = 0, \quad j = 1, \dots, J.$$

若满足相应正则条件, 则存在乘子 λ_i, μ_j 使

$$\nabla f(x^*) + \sum_{i=1}^I \lambda_i \nabla g_i(x^*) + \sum_{j=1}^J \mu_j \nabla h_j(x^*) = 0,$$

$$\lambda_i \geq 0, \quad g_i(x^*) \leq 0, \quad \lambda_i g_i(x^*) = 0,$$

$$h_j(x^*) = 0.$$

Sec 7.5

非线性不等式约束与约束资格 (Constraint Qualification)

7

7.5.1 为什么线性情形不能直接照搬

考虑非线性问题

$$\min_x f(x) \quad \text{s.t.} \quad g_i(x) \leq 0, \quad i = 1, \dots, I.$$

在解 x^* 附近, 可对约束做一阶 Taylor 近似:

$$g_i(x) \approx g_i(x^*) + \langle \nabla g_i(x^*), x - x^* \rangle.$$

因此, 在局部上, 非线性约束看起来像由梯度给出的线性约束。KKT 条件正是由这种“局部线性化”思想得到的。

7.5.2 一般 KKT 定理

Theorem 7.5.3.

一般非线性不等式约束的 KKT 定理 设 $f, g_1, \dots, g_I$ 可微。若 x^* 是问题

$$\min_x f(x) \quad \text{s.t.} \quad g_i(x) \leq 0, \quad i = 1, \dots, I$$

的解, 并且在 x^* 处满足某个 *constraint qualification* (约束资格条件, CQ), 则存在乘子

$$\lambda_1, \dots, \lambda_I$$

使

$$\nabla f(x^*) + \sum_{i=1}^I \lambda_i \nabla g_i(x^*) = 0,$$

$$\lambda_i \geq 0, \quad g_i(x^*) \leq 0, \quad \lambda_i g_i(x^*) = 0.$$

与线性约束版本相比, 结论形式相同, 但前提更强: 必须额外要求某种 CQ。

7.5.3 一个说明 CQ 必要性的例子

考虑问题

$$\min_x x \quad \text{s.t.} \quad -x^3 \leq 0.$$

约束等价于

$$x \geq 0,$$

所以最优解为

$$x^* = 0.$$

7.5. 非线性不等式约束与约束资格 (CONSTRAINT QUALIFICATION)

如果机械地套用 KKT 条件, 则应有

$$f'(0) + \lambda g'(0) = 0.$$

这里

$$f'(x) = 1, \quad g'(x) = -3x^2,$$

故在 $x^* = 0$ 处变成

$$1 + \lambda \cdot 0 = 0,$$

显然不可能成立。

这说明: 即使问题有解, 如果活跃约束的梯度退化得太厉害, KKT 条件也可能失效。因此必须加入 CQ 来排除这种病态情形。

7.5.4 活跃约束集与 NDCQ

Definition 7.5.2.

给定可行点 x^* , 其 active set (活跃约束集) 定义为

$$I(x^*) := \{i \mid g_i(x^*) = 0\}.$$

Definition 7.5.3.

NDCQ (Nondegenerate Constraint Qualification) 要求活跃约束的梯度集合

$$\{\nabla g_i(x^*) \mid i \in I(x^*)\}$$

线性无关。

在线性约束中, 这一条件往往自动满足; 而在非线性约束中, 就需要显式检查。很多优化教材把这种“活跃约束梯度线性无关”的条件称为 LICQ (Linear Independence Constraint Qualification)。本章课件中的 LICQ 例子, 本质上就是在说明 NDCQ 的几何含义。

7.5.5 Slater 条件

Definition 7.5.4.

若所有 g_i 都是 convex (凸) 函数, 并且存在一点 x^0 使得

$$g_i(x^0) < 0, \quad \forall i,$$

则称满足 Slater condition (Slater 条件)。

Slater 条件是凸优化里最常用的 CQ。它要求存在一个 strict feasible point (严格可行点), 也就是“离边界有余量”的可行点。

7.5.6 线性无关的例子

若

$$g_1(x) = x_1 + x_2 - 1 \leq 0, \quad g_2(x) = x_1 - x_2 - 1 \leq 0,$$

则

$$\nabla g_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \nabla g_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

这两个梯度线性无关。

若

$$g_1(x) = x_1 + x_2 - 1 \leq 0, \quad g_2(x) = 2x_1 + 2x_2 - 4 \leq 0,$$

则

$$\nabla g_2 = 2\nabla g_1,$$

因此梯度线性相关。

7.5.7 几何解释: box constraints

对于盒状约束 (box constraints)

$$g_1(x) = x_1 - a \leq 0, \quad g_2(x) = x_2 - b \leq 0,$$

有

$$\nabla g_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \nabla g_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

它们显然线性无关, 因此这类约束通常是“最规则”的情形。

7.5.8 非线性 LICQ 成立与失败的例子

先看 LICQ 成立的例子:

$$g_1(x_1, x_2) = x_2 - x_1^2 \leq 0, \quad g_2(x_1, x_2) = x_1 - 2x_2^3 \leq 0.$$

在点

$$x^* = (0, 0)$$

处,

$$g_1(0, 0) = 0, \quad g_2(0, 0) = 0,$$

两条约束都活跃。其梯度为

$$\nabla g_1(0, 0) = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad \nabla g_2(0, 0) = \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

二者线性无关, 因此 LICQ 成立。

再看 LICQ 失败的例子:

$$g_1(x_1, x_2) = x_2 - x_1^2 \leq 0, \quad g_2(x_1, x_2) = 2x_2 - 5x_1^2 \leq 0.$$

同样在

$$x^* = (0, 0)$$

处, 两条约束都活跃, 但

$$\nabla g_1(0, 0) = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad \nabla g_2(0, 0) = \begin{bmatrix} 0 \\ 2 \end{bmatrix} = 2\nabla g_1(0, 0).$$

因此二者线性相关, LICQ 失败。

Sec 7.6 凸优化中的 KKT 条件

7.6.1 定理陈述

Theorem 7.6.4.

凸优化中的 KKT 条件 考虑问题

$$\min_x f(x) \quad \text{s.t.} \quad g_i(x) \leq 0, \quad i = 1, \dots, I,$$

其中 f 与每个 g_i 都可微且凸。

1. 若 x^* 是解, 且满足 Slater 条件, 则存在乘子使 KKT 条件成立;
2. 反过来, 若存在点 x^* 与乘子 λ_i 满足 KKT 条件, 则 x^* 就是全局最优解。

第一部分是“必要性 (necessity)”, 第二部分是“充分性 (sufficiency)”。凸优化的强大之处就在于: 局部一阶条件在这里直接升级为全局最优判别条件。

7.6.2 充分性的证明

Proof. 设存在可行点 x^* 与乘子 $\lambda_i \geq 0$ 满足 KKT 条件。定义拉格朗日函数

$$L(x, \lambda) = f(x) + \sum_{i=1}^I \lambda_i g_i(x).$$

由于 f 与每个 g_i 都凸, 且 $\lambda_i \geq 0$, 所以 $L(x, \lambda)$ 对 x 仍是凸函数。

KKT 的一阶条件给出

$$\nabla_x L(x^*, \lambda) = \nabla f(x^*) + \sum_{i=1}^I \lambda_i \nabla g_i(x^*) = 0.$$

对凸函数而言, 梯度为零意味着全局最小, 因此

$$L(x^*, \lambda) \leq L(x, \lambda) \quad \forall x.$$

现在任取任意可行点 x 。由互补松弛,

$$\lambda_i g_i(x^*) = 0 \quad \forall i.$$

所以

$$f(x^*) = f(x^*) + \sum_{i=1}^I \lambda_i g_i(x^*) = L(x^*, \lambda).$$

又由 x^* 使 L 最小,

$$L(x^*, \lambda) \leq L(x, \lambda) = f(x) + \sum_{i=1}^I \lambda_i g_i(x).$$

但由于 x 可行,

$$g_i(x) \leq 0$$

且 $\lambda_i \geq 0$, 故

$$\sum_{i=1}^I \lambda_i g_i(x) \leq 0.$$

于是

$$L(x, \lambda) \leq f(x).$$

综合起来得到

$$f(x^*) \leq f(x) \quad \forall \text{ feasible } x.$$

因此 x^* 是全局最优解。 ■

7.6.3 怎样实际使用这一定理

在凸优化中, 求解步骤通常是:

1. 检查 f 和 g_i 是否凸且可微;
2. 检查 Slater 条件是否成立;
3. 写出拉格朗日函数;
4. 联立 stationarity、primal feasibility、dual feasibility 和 complementary slackness;
5. 解出 x^* 与 λ^* 。

Sec 7.7 例子与应用

7.7.1 例子: 最小化 $1/x_1 + 1/x_2$

考虑问题

$$\min_{x_1, x_2} \frac{1}{x_1} + \frac{1}{x_2} \quad \text{s.t.} \quad x_1 + x_2 \leq 2,$$

并隐含要求

$$x_1 > 0, \quad x_2 > 0.$$

注意函数

$$f(x_1, x_2) = \frac{1}{x_1} + \frac{1}{x_2}$$

在正正交域上是凸函数, 因为

$$f_{x_1 x_1} = \frac{2}{x_1^3} > 0, \quad f_{x_2 x_2} = \frac{2}{x_2^3} > 0, \quad f_{x_1 x_2} = 0.$$

并且存在严格可行点, 例如

$$\left(\frac{1}{2}, \frac{1}{2}\right)$$

满足

$$\frac{1}{2} + \frac{1}{2} < 2.$$

所以 Slater 条件成立, KKT 条件既必要又充分。

写拉格朗日函数

$$L(x_1, x_2, \lambda) = \frac{1}{x_1} + \frac{1}{x_2} + \lambda(x_1 + x_2 - 2).$$

KKT 条件为

$$-\frac{1}{x_1^2} + \lambda = 0,$$

$$-\frac{1}{x_2^2} + \lambda = 0,$$

$$\lambda \geq 0, \quad x_1 + x_2 - 2 \leq 0, \quad \lambda(x_1 + x_2 - 2) = 0.$$

由前两式得

$$\frac{1}{x_1^2} = \frac{1}{x_2^2} \implies x_1 = x_2$$

(因为 $x_1, x_2 > 0$)。再由目标函数在坐标上单调递减可知, 约束必紧, 所以

$$x_1 + x_2 = 2.$$

于是

$$x_1^* = x_2^* = 1.$$

再代回得

$$\lambda^* = 1.$$

由于这是凸问题, 故该解是唯一全局最优解。

7.7.2 最大化问题的等价改写

若原问题是

$$\max_x f(x) \quad \text{s.t.} \quad g_i(x) \geq 0, \quad i = 1, \dots, I,$$

则可等价改写为

$$\min_x -f(x) \quad \text{s.t.} \quad -g_i(x) \leq 0, \quad i = 1, \dots, I.$$

因此 KKT 条件既可用于最小化, 也可用于最大化, 只是要先统一符号约定。

7.7.3 Cobb-Douglas 效用最大化

考虑消费者问题

$$\max_{x_1, x_2} \alpha \log x_1 + (1 - \alpha) \log x_2$$

满足

$$x_1 \geq 0, \quad x_2 \geq 0, \quad p_1 x_1 + p_2 x_2 \leq w, \quad 0 < \alpha < 1.$$

因为效用函数对 x_1, x_2 严格递增, 所以在最优点预算约束一定紧:

$$p_1 x_1^* + p_2 x_2^* = w.$$

同时最优点一定是内部解 $x_1^* > 0, x_2^* > 0$, 因此非负性约束的乘子都为零。

于是问题退化为熟悉的拉格朗日系统:

$$\begin{aligned} \frac{\alpha}{x_1^*} - \lambda^* p_1 &= 0, \\ \frac{1 - \alpha}{x_2^*} - \lambda^* p_2 &= 0, \\ w - p_1 x_1^* - p_2 x_2^* &= 0. \end{aligned}$$

求解得

$$x_1^* = \frac{\alpha w}{p_1}, \quad x_2^* = \frac{(1 - \alpha)w}{p_2}.$$

这个例子说明: 在有不等式约束的优化中, KKT 条件把“哪些约束真正起作用、哪些约束在最优点处是松的”统一编码在乘子的符号与互补松弛条件之中。

Sec 7.8 本讲总结

第七章的核心逻辑是:

1. 对不等式约束问题, 最优点不能沿任何 feasible direction 改善目标函数;
2. 由此得到 KKT 条件:

$$\nabla f(x^*) + \sum_i \lambda_i \nabla g_i(x^*) = 0, \quad \lambda_i \geq 0, \quad \lambda_i g_i(x^*) = 0;$$

3. 对等式约束, 其乘子不受符号限制;
4. 在非线性约束下, 需要 CQ 才能保证 KKT 必要性;
5. NDCQ/LICQ 与 Slater 条件是最重要的两类 CQ;
6. 在凸优化中, KKT 条件不仅必要, 而且充分, 因此成为求解凸约束优化的标准工具;
7. 互补松弛提供了清晰的经济解释: 只有真正“卡住”最优解的约束才会拥有正的影子价格。



应用一般均衡理论

Part

Sec 8.1 总览

第八章讨论 **Applied General Equilibrium Theory (应用一般均衡理论)**。前面几章的优化理论主要研究单个主体在给定约束下如何选择；一般均衡理论则把许多消费者、许多商品和许多市场同时放在一个模型中，研究价格与配置如何共同决定。

本章主线分为三部分：

1. Arrow-Debreu model (Arrow-Debreu 模型)：用抽象的多商品、多主体模型描述整个经济；
2. Walras Law (Walras 法则)：说明各市场的超额需求之间存在一个预算恒等关系；
3. Quasi-linear model (准线性模型)：在特殊效用结构下，把均衡问题转化为一个社会规划问题。

Sec 8.2 Arrow-Debreu 模型

8.2.1 什么是一般均衡？

一般均衡 (general equilibrium, GE) 与局部均衡 (partial equilibrium, PE) 相对。中级微观经济学中常见的供给曲线和需求曲线分析，通常只聚焦一个市场，例如只研究苹果市场或汽油市场的价格和数量。

现实经济中，各市场并不是彼此孤立的。一个消费者能购买多少商品，取决于收入；收入又可能来自劳动市场、资本市场或资产收益。油价上升会降低大排量汽车的需求，同时可能提高电动车的需求。一般均衡模型的目标，就是把整个经济作为一个相互联系的系统来分析，使价格、收入、需求和资源约束同时成立。

8.2.2 商品的广义含义

在一般均衡模型中，商品 (commodities) 要作广义理解。商品不仅由物理属性区分，例如苹果和香蕉不同；还可以由以下维度区分：

- **时间 (time)**：今天可得的咖啡豆和六个月后可得的咖啡豆，是两种不同商品；
- **地点 (location)**：新疆的水和浙江的水，在运输成本存在时应看作不同商品；
- **状态 (state)**：生病时的医疗服务和健康时的医疗服务，也是不同状态下的不同商品。

因此，一般均衡理论虽然抽象，但它可以通过强调不同商品维度，生成许多经济学分支的模型：

	Time	Location	Uncertainty
Time	Dynamic models	International macro	Stochastic dynamic models
Location	Trade / spatial models	International finance	
Uncertainty	Risk, beliefs, finance		

这个抽象框架的主要作用不是立即逼真地描写所有细节，而是训练我们用模型把不同市场之间的逻辑关系讲清楚。

8.2.3 基本记号

考虑 Arrow-Debreu 传统下的纯交换经济。经济中有 I 个主体，记为

$$\mathcal{I} = \{1, 2, \dots, I\}.$$

一般主体用 $i \in \mathcal{I}$ 表示。

经济中有 L 种商品，记为

$$\mathcal{L} = \{1, 2, \dots, L\}.$$

一般商品用 $l \in \mathcal{L}$ 表示。

若 $x = (x_1, \dots, x_L) \in \mathbb{R}^L$ ，约定：

- $x \succeq 0$ 表示 $x_l \geq 0$ 对所有 l 成立；所有这类向量构成非负正交域 $\mathbb{R}_+^L$ ；
- $x \gg 0$ 表示 $x_l > 0$ 对所有 l 成立；所有这类向量构成严格正正交域 $\mathbb{R}_{++}^L$ ；
- $x \succeq y$ 表示 $x_l \geq y_l$ 对所有 l 成立；
- $x \gg y$ 表示 $x_l > y_l$ 对所有 l 成立；
- $x > y$ 表示 $x \succeq y$ 且 $x \neq y$ 。

类似地可以定义 $\preceq, \prec, \ll$ 等符号。这里的大小关系都是逐分量 (componentwise) 比较，而不是用欧氏范数比较。

8.2.4 消费束与效用函数

一个一般消费束写作

$$x = (x_1, \dots, x_L) \in \mathbb{R}_+^L.$$

主体 i 的消费束写作

$$x_i = (x_{i1}, \dots, x_{iL}) \in \mathbb{R}_+^L.$$

双下标 x_{il} 中，第一个下标 i 表示主体，第二个下标 l 表示商品。例如， x_{12} 是主体 1 对商品 2 的消费量， x_{21} 是主体 2 对商品 1 的消费量。

假设主体 i 的偏好可以由效用函数

$$u_i : \mathbb{R}_+^L \rightarrow \mathbb{R}$$

表示。若

$$u_i(x) > u_i(y),$$

则主体 i 严格偏好 x 于 y 。

效用函数表示偏好的方式本质上是序数的 (ordinal)。若 $f: \mathbb{R} \rightarrow \mathbb{R}$ 严格递增, 则

$$u_i(x) > u_i(y) \iff f(u_i(x)) > f(u_i(y)).$$

因此

$$v_i = f \circ u_i$$

表示的偏好顺序与 u_i 完全相同。被严格递增变换保留下来的性质称为 **ordinal properties** (序数性质); 依赖效用数值大小本身的性质称为 **cardinal properties** (基数性质)。一般均衡中的消费选择主要依赖序数性质。

8.2.5 常见效用函数

在两商品情形中, 常见效用函数包括 Cobb-Douglas 效用:

$$u(x_1, x_2) = \alpha_1 \log x_1 + \alpha_2 \log x_2.$$

因为指数函数严格递增, 也可以使用

$$v(x) = \exp(u(x)) = x_1^{\alpha_1} x_2^{\alpha_2}$$

表示同一偏好。

另一类是 **Constant Elasticity of Substitution (CES, 常替代弹性)** 效用。对 $0 < \sigma \neq 1$, 可写为

$$u(x_1, x_2) = (\alpha_1 x_1^{1-\sigma} + \alpha_2 x_2^{1-\sigma})^{\frac{1}{1-\sigma}}.$$

由于

$$f(t) = \frac{t^{1-\sigma}}{1-\sigma}$$

在 $t > 0$ 上满足

$$f'(t) = t^{-\sigma} > 0,$$

也可以用严格递增变换后的形式

$$v(x) = \frac{1}{1-\sigma} (\alpha_1 x_1^{1-\sigma} + \alpha_2 x_2^{1-\sigma})$$

表示同一偏好。

8.2.6 Arrow-Debreu 经济的定义

Definition 8.2.1.

一个 Arrow-Debreu economy (Arrow-Debreu 经济)

$$\mathcal{E} = \{\mathcal{I}, (e_i)_{i \in \mathcal{I}}, (u_i)_{i \in \mathcal{I}}\}$$

由以下对象构成：

- 主体集合 $\mathcal{I} = \{1, 2, \dots, I\}$;
- 每个主体 i 的初始禀赋 (endowment)

$$e_i = (e_{i1}, \dots, e_{iL}) \in \mathbb{R}_+^L;$$

- 每个主体 i 的效用函数

$$u_i : \mathbb{R}_+^L \rightarrow \mathbb{R}.$$

本章只讨论 pure exchange economy (纯交换经济)，即每个主体拥有初始禀赋并通过市场交换达到最终消费。加入生产部门可以让模型更现实，但在抽象层面不会改变本章要强调的核心逻辑。

8.2.7 市场、价格与预算约束

先假设所有商品都可以交易，即市场是 complete market (完全市场)。这显然是强抽象：未来劳动收入未必能提前出售，因为劳动者未来可能不履约；某个特定天气和日期下的雨伞需求也未必有足够交易量形成市场。不过，完全市场假设能让我们先看清均衡的基本数学结构。

商品 l 的价格记为

$$p_l \in \mathbb{R},$$

价格向量为

$$p = (p_1, \dots, p_L) \in \mathbb{R}^L.$$

通常 $p_l > 0$ ，但模型也允许：

- $p_l = 0$ ：免费商品，例如空气或海滩游泳；
- $p_l < 0$ ：坏品 (bads)，例如垃圾、报废车或核废料。负价格表示别人愿意付钱让你接收它。

若主体 i 出售全部禀赋 e_i ，其财富为

$$w_i := \sum_{l=1}^L p_l e_{il} = p \cdot e_i.$$

若他想消费 $x = (x_1, \dots, x_L)$ ，所需支出为

$$\sum_{l=1}^L p_l x_l = p \cdot x.$$

因此预算约束为

$$p \cdot x \leq p \cdot e_i,$$

等价地，

$$p \cdot (x - e_i) \leq 0.$$

不等式而不是等式, 是因为消费者在形式上不一定被强制花光所有财富。

Definition 8.2.2.

给定价格 p , 主体 i 的 **budget set (预算集)** 为

$$B_i(p) := \{x \in \mathbb{R}_+^L \mid p \cdot (x - e_i) \leq 0\}.$$

$$B_i(p) := \{x \in \mathbb{R}_+^L \mid p \cdot (x - e_i) \leq 0\}$$




图 8.1: 两商品情形下的预算集: 初始禀赋 e_i 决定预算线位置, 价格向量 p 垂直于预算线

8.2.8 货币中性与价格标准化

若 $t > 0$, 则

$$B_i(tp) = \{x \in \mathbb{R}_+^L \mid (tp) \cdot (x - e_i) \leq 0\}.$$

由于 $t > 0$, 上式等价于

$$B_i(tp) = \{x \in \mathbb{R}_+^L \mid p \cdot (x - e_i) \leq 0\} = B_i(p).$$

也就是说, 把所有价格同时乘以同一个正数, 并不会改变任何人的预算集。

这就是一般均衡中的 **neutrality of money (货币中性)**: 价格的绝对单位不重要, 真正重要的是相对价格。因此求解均衡时可以选择一个标准化条件, 例如

$$\sum_{l=1}^L p_l = 1 \quad \text{or} \quad p_1 = 1.$$

8.2.9 主体目标与竞争均衡

给定价格 p , 主体 i 的目标是解效用最大化问题 (utility maximization problem, UMP):

$$\max_x u_i(x) \quad \text{s.t.} \quad x \in B_i(p).$$

若 x_i 是该问题的解, 则对任何严格递增函数 f , x_i 也解

$$\max_x f(u_i(x)) \quad \text{s.t.} \quad x \in B_i(p).$$

因此最优消费束本身是序数性质, 而最大效用数值 $u_i(x_i)$ 是基数性质。

Definition 8.2.3.

一个 **competitive equilibrium (竞争均衡)**, 也称 **Walrasian equilibrium (Walras 均衡)**, 由价格向量 $p \in \mathbb{R}^L$ 与配置

$$(x_i)_{i=1}^I, \quad x_i \in \mathbb{R}_+^L$$

构成, 并满足:

1. **主体最优化 (agent optimization)**: 对每个 i , x_i 解主体 i 的 UMP, 即

$$x_i \in B_i(p),$$

且对任意 $x \in B_i(p)$,

$$u_i(x_i) \geq u_i(x).$$

2. **市场出清 (market clearing)**: 总需求不超过总供给, 即

$$\sum_{i=1}^I x_i \preceq \sum_{i=1}^I e_i.$$

这里市场出清写成“不超过”而不是“等于”, 是为了允许 free disposal (免费处置): 某些商品即使没有被消费, 也可以被丢弃或闲置, 例如空气。

竞争均衡包含两个核心思想。第一, 主体是 price takers (价格接受者), 他们在给定价格下只关心自己的财富和偏好。第二, 均衡不是说每个主体的愿望都被满足, 而是说所有主体在这些价格下的最优选择, 与整个经济的资源约束相容。

8.2.10 例子: Edgeworth box 经济

考虑两个主体、两种商品的纯交换经济。设

$$e_1 = e_2 = \begin{bmatrix} 3 \\ 3 \end{bmatrix},$$

效用函数为

$$u_1(x_1, x_2) = \frac{2}{3} \log x_1 + \frac{1}{3} \log x_2,$$

$$u_2(x_1, x_2) = \frac{1}{3} \log x_1 + \frac{2}{3} \log x_2.$$

令价格为 $p = (p_1, p_2)$ 。两人的初始财富相同:

$$w_1 = w_2 = 3p_1 + 3p_2.$$

Cobb-Douglas 需求把收入按参数比例分配到各商品上, 所以

$$x_{11} = \frac{2}{3} \frac{w_1}{p_1}, \quad x_{12} = \frac{1}{3} \frac{w_1}{p_2},$$

$$x_{21} = \frac{1}{3} \frac{w_2}{p_1}, \quad x_{22} = \frac{2}{3} \frac{w_2}{p_2}.$$

总供给为 (6, 6)。商品 1 的市场出清条件为

$$x_{11} + x_{21} = 6.$$

代入 $w_1 = w_2 = 3p_1 + 3p_2$ 得

$$\frac{3p_1 + 3p_2}{p_1} = 6,$$

从而

$$p_2 = p_1.$$

因此均衡相对价格为

$$p_1 : p_2 = 1 : 1.$$

若取标准化 $p = (1, 1)$, 则 $w_1 = w_2 = 6$, 均衡配置为

$$x_1 = (4, 2), \quad x_2 = (2, 4).$$

两种商品的总需求分别为 6 和 6, 正好等于总供给。

8.2.11 例子：利率作为跨期相对价格

一般均衡模型也可以解释跨期选择。考虑一个主体、两个时期 $t = 1, 2$ 、一种物理商品 (苹果)。由于商品按可得时间区分, 今天的苹果和明天的苹果在模型中就是两种商品。

设禀赋为

$$e = (e_1, e_2),$$

效用函数为

$$u(x_1, x_2) = \log x_1 + \beta \log x_2,$$

价格为

$$p = (p_1, p_2).$$

这里 p_1 是现货价格, p_2 是未来交割苹果的价格。

主体问题为

$$\max_{x_1, x_2} \log x_1 + \beta \log x_2 \quad \text{s.t.} \quad p_1 x_1 + p_2 x_2 = p_1 e_1 + p_2 e_2.$$

Cobb-Douglas 需求给出

$$x_1 = \frac{p_1 e_1 + p_2 e_2}{(1 + \beta)p_1}, \quad x_2 = \frac{\beta(p_1 e_1 + p_2 e_2)}{(1 + \beta)p_2}.$$

代表性主体均衡要求 $x_1 = e_1, x_2 = e_2$, 于是

$$\frac{p_2}{p_1} = \frac{\beta e_1}{e_2}.$$

若把今天的苹果价格标准化为 $p_1 = 1$ ，则未来商品价格为 $p_2 = \beta e_1 / e_2$ 。若用 $R = p_1 / p_2$ 表示从今天商品到明天商品的相对回报，则

$$R = \frac{e_2}{\beta e_1}.$$

因此，跨期均衡中的利率本质上也是一个相对价格。

Sec 8.3 Walras 法则

8.3.1 三种单调性概念

Walras 法则需要一个很弱的偏好假设。先从较强的单调性开始。

Definition 8.3.4.

效用函数 $u : \mathbb{R}_+^L \rightarrow \mathbb{R}$ 称为 **strongly monotonic (强单调)**，如果

$$x < y \implies u(x) < u(y).$$

强单调表示：只要某些商品不减少且至少一种商品增加，消费者就严格更喜欢新的消费束。

Definition 8.3.5.

效用函数 u 称为 **weakly monotonic (弱单调)**，如果

$$x \preceq y \implies u(x) \leq u(y),$$

并且

$$x \ll y \implies u(x) < u(y).$$

弱单调允许某一种商品增加时效用不变，但要求所有商品都严格增加时效用严格提高。

Definition 8.3.6.

效用函数 u 称为 **locally nonsatiated (局部不饱和, LNS)**，如果对任意 $x \in \mathbb{R}_+^L$ 与任意 $\varepsilon > 0$ ，都存在 $y \in \mathbb{R}_+^L$ 使得

$$\|y - x\| < \varepsilon$$

且

$$u(y) > u(x).$$

局部不饱和的直观含义是：无论当前消费束是什么，在它任意小的邻域内，总能找到一个更好的消费束。它不要求“每种商品越多越好”，因此比弱单调更弱，也允许存在坏品。

三者之间的关系为

$$\text{strong monotonicity} \implies \text{weak monotonicity} \implies \text{local nonsatiation}.$$

Cobb-Douglas 和 CES 效用通常是强单调的; Leontief 效用

$$u(x_1, x_2) = \min\{x_1, x_2\}$$

是弱单调的, 但不是强单调的。

8.3.2 局部不饱意味着花光收入

Proposition 8.3.1.

设 $u: \mathbb{R}_+^L \rightarrow \mathbb{R}$ 是 *locally nonsatiated* 效用函数, 且 $x(p, w)$ 解效用最大化问题

$$\max_x u(x) \quad \text{s.t.} \quad p \cdot x \leq w, \quad x \in \mathbb{R}_+^L.$$

则

$$p \cdot x(p, w) = w.$$

Proof. 设 $x = x(p, w)$ 。反证法。若

$$p \cdot x < w,$$

则由于函数 $y \mapsto p \cdot y$ 连续, 存在 $\varepsilon > 0$, 使得只要

$$\|y - x\| < \varepsilon,$$

就仍有

$$p \cdot y < w.$$

也就是说, x 附近有一个小球完全落在预算约束的内部。

由局部不饱和性, 可以在这个小球内找到 y , 使得

$$u(y) > u(x).$$

这个 y 仍然可负担, 却比 x 更好, 矛盾于 x 是效用最大化问题的解。因此预算约束必须紧:

$$p \cdot x = w.$$

8.3.3 Walras Law

定义主体 i 在价格 p 下的需求为

$$x_i(p, p \cdot e_i).$$

总超额需求 (aggregate excess demand) 为

$$z(p) := \sum_{i=1}^I (x_i(p, p \cdot e_i) - e_i).$$

其中第 l 个分量为

$$z_l(p) = \sum_{i=1}^I (x_{il} - e_{il}).$$

Theorem 8.3.1.

Walras Law (Walras 法则) 若每个主体的效用函数都 *locally nonsatiated*, 则

$$p \cdot z(p) = 0.$$

Proof. 令

$$x_i = x_i(p, p \cdot e_i).$$

由上一命题, 每个主体都会花光收入:

$$p \cdot x_i = p \cdot e_i.$$

因此

$$p \cdot (x_i - e_i) = 0.$$

对所有主体求和, 得到

$$p \cdot z(p) = p \cdot \sum_{i=1}^I (x_i - e_i) = \sum_{i=1}^I p \cdot (x_i - e_i) = 0.$$

展开写, Walras 法则为

$$0 = p \cdot z(p) = \sum_{l=1}^L p_l z_l(p).$$

若所有价格都严格为正, 并且除了一个市场以外, 其余市场都已经出清, 那么最后一个市场也必然出清。例如, 若

$$z_l(p) = 0, \quad l = 1, \dots, L-1,$$

则

$$p_L z_L(p) = 0.$$

只要 $p_L > 0$, 就有

$$z_L(p) = 0.$$

这说明在求均衡时通常只需要检查 $L-1$ 个市场出清条件。

8.3.4 均衡中超额供给商品必须免费

Proposition 8.3.2.

设

$$\mathcal{E} = \{\mathcal{I}, (e_i), (u_i)\}$$

是一个所有效用函数均 *locally nonsatiated* 的经济。若 $\{p, (x_i)\}$ 是 Walrasian equilibrium, 且 $p \succeq 0$, 则对每种商品 l ,

$$p_l \sum_{i=1}^I (x_{il} - e_{il}) = 0.$$

特别地, 若商品 l 存在严格超额供给:

$$\sum_{i=1}^I (x_{il} - e_{il}) < 0,$$

则

$$p_l = 0.$$

Proof. 由市场出清,

$$\sum_{i=1}^I (x_{il} - e_{il}) \leq 0 \quad \forall l.$$

又因 $p_l \geq 0$, 故

$$p_l \sum_{i=1}^I (x_{il} - e_{il}) \leq 0 \quad \forall l.$$

对 l 求和得到

$$\sum_{l=1}^L p_l \sum_{i=1}^I (x_{il} - e_{il}) \leq 0.$$

但左边正是

$$p \cdot z(p),$$

由 Walras 法则等于 0。由于每一项都不大于 0, 总和却等于 0, 所以每一项都必须等于 0:

$$p_l \sum_{i=1}^I (x_{il} - e_{il}) = 0.$$

如果某商品严格超额供给, 则括号中的数为负, 只能有 $p_l = 0$ 。 ■

经济学含义很直接: 如果某种商品供给超过需求, 而且可以免费处置, 那么它在均衡中不能有正价格。空气就是典型例子。

8.3.5 强单调性下可以忽略一个市场

Theorem 8.3.2.

强单调偏好下的市场出清判别 设经济 $\mathcal{E} = \{\mathcal{I}, (e_i), (u_i)\}$ 中所有效用函数都 *locally non-satiated*, 且至少一个主体具有 *strongly monotonic preference*。令 x_i 为主体 i 在价格 p 下的需求。则 $\{p, (x_i)\}$ 是均衡, 当且仅当

$$p \gg 0$$

且

$$\sum_{i=1}^I (x_{il} - e_{il}) = 0, \quad l = 1, \dots, L-1.$$

Proof. 先说明必要性。若某个商品 l 满足 $p_l = 0$, 则对具有强单调偏好的主体而言, 增加该商品的消费不会增加支出, 却会严格提高效用。因此在预算集内不存在最优消费束。这与均衡要求每个主体最优化矛盾。所以均衡中必须有

$$p_l > 0, \quad l = 1, \dots, L.$$

在均衡中, 由上一命题有

$$p_l \sum_{i=1}^I (x_{il} - e_{il}) = 0.$$

由于 $p_l > 0$, 可得

$$\sum_{i=1}^I (x_{il} - e_{il}) = 0 \quad \forall l.$$

特别地, 前 $L - 1$ 个市场必然出清。

反过来, 若 $p \gg 0$, 且

$$\sum_{i=1}^I (x_{il} - e_{il}) = 0, \quad l = 1, \dots, L - 1,$$

则 Walras 法则给出

$$0 = p \cdot z(p) = p_L z_L(p).$$

因为 $p_L > 0$, 所以

$$z_L(p) = 0.$$

故第 L 个市场也出清。结合每个 x_i 已经是给定价格下的需求, 得到 Walrasian equilibrium。 ■

8.3.6 求解一般均衡的基本算法

上面的定理给出计算均衡的一般步骤:

1. 检查所有效用函数是否 LNS, 并确认至少一个主体的偏好强单调;
2. 对每个 $p \gg 0$, 解每个主体的效用最大化问题

$$\max_x u_i(x) \quad \text{s.t.} \quad p \cdot x \leq p \cdot e_i;$$

3. 利用价格标准化, 例如令 $p_L = 1$;
4. 解前 $L - 1$ 个市场出清方程

$$\sum_{i=1}^I (x_{il}(p, p \cdot e_i) - e_{il}) = 0, \quad l = 1, \dots, L - 1;$$

5. 得到价格向量 p 后, 再代回求出每个主体的需求

$$x_i = x_i(p, p \cdot e_i).$$

8.3.7 Cobb-Douglas Edgeworth box 的一般形式

考虑两个主体、两种商品。主体 1 的禀赋为

$$a = (a_1, a_2),$$

效用函数为

$$u_1(x_1, x_2) = \alpha \log x_1 + (1 - \alpha) \log x_2.$$

主体 2 的禀赋为

$$b = (b_1, b_2),$$

效用函数为

$$u_2(x_1, x_2) = \beta \log x_1 + (1 - \beta) \log x_2.$$

令 $p_2 = 1$ 作价格标准化。两人的财富为

$$w_1 = p_1 a_1 + a_2, \quad w_2 = p_1 b_1 + b_2.$$

Cobb-Douglas 需求为

$$x_{11} = \alpha \frac{w_1}{p_1}, \quad x_{21} = \beta \frac{w_2}{p_1}.$$

商品 1 的总供给为

$$a_1 + b_1.$$

市场出清要求

$$\alpha(p_1 a_1 + a_2) + \beta(p_1 b_1 + b_2) = p_1(a_1 + b_1).$$

整理得

$$p_1 [(1 - \alpha)a_1 + (1 - \beta)b_1] = \alpha a_2 + \beta b_2.$$

因此

$$p_1^* = \frac{\alpha a_2 + \beta b_2}{(1 - \alpha)a_1 + (1 - \beta)b_1}, \quad p_2^* = 1.$$

只要分母为正, 就得到正的均衡相对价格。前面的具体例子中, $a = b = (3, 3)$, $\alpha = 2/3, \beta = 1/3$, 所以 $p_1^* = 1$ 。

8.3.8 一般 Cobb-Douglas 经济

更一般地, 考虑 I 个主体、 L 种商品。主体 i 的效用为

$$u_i(x) = \sum_{l=1}^L \alpha_{il} \log x_l,$$

其中

$$\sum_{l=1}^L \alpha_{il} = 1, \quad \alpha_{il} \geq 0.$$

主体 i 的 Cobb-Douglas 需求为

$$x_{il} = \alpha_{il} \frac{p \cdot e_i}{p_l}.$$

令第 l 种商品的总禀赋为

$$e_l := \sum_{i=1}^I e_{il}.$$

市场出清条件为

$$e_l = \sum_{i=1}^I x_{il} = \sum_{i=1}^I \alpha_{il} \frac{p \cdot e_i}{p_l}.$$

两边乘以 p_l , 得到

$$p_l e_l = \sum_{i=1}^I \alpha_{il} (p \cdot e_i).$$

右边还可以写作

$$p \cdot \left(\sum_{i=1}^I \alpha_{il} e_i \right).$$

因此市场出清等价于

$$p \cdot \left(\sum_{i=1}^I \alpha_{il} e_i \right) = p_l e_l, \quad l = 1, \dots, L.$$

在选择一个价格标准化条件后, 这就是关于相对价格的线性方程组。课件中略去存在唯一正价格向量的证明; 直观上, Cobb-Douglas 需求连续、强单调, 并且每个主体都按固定支出份额购买各商品, 使得均衡相对价格可以由线性市场出清条件确定。

Sec 8.4 准线性模型

8.4.1 为什么引入准线性模型?

一般均衡的完整求解通常包含两层困难:

1. 给定价格 p , 先为每个主体解效用最大化问题, 得到需求 $x_i(p)$;
2. 再联立市场出清条件

$$\sum_{i=1}^I x_i(p) = \sum_{i=1}^I e_i$$

求均衡价格。

准线性 (quasi-linear) 模型通过引入一个特殊的计价商品, 把部分一般均衡问题化简。它不仅让均衡更容易计算, 还会带来一个清晰的福利结论: 在准线性经济中, 竞争均衡的非计价商品配置等价于最大化所有主体非线性效用部分之和。

8.4.2 准线性效用

Definition 8.4.7.

定义在 $\mathbb{R} \times \mathbb{R}_+^L$ 上的效用函数 u 称为 **quasi-linear (准线性)**, 如果它可以写成

$$u(x_0, x_1, \dots, x_L) = x_0 + \varphi(x_1, \dots, x_L),$$

其中

$$\varphi : \mathbb{R}_+^L \rightarrow \mathbb{R}.$$

这里 x_0 是特殊商品, 称为 **numeraire (计价物)**, 可以正消费也可以负消费。可以把它理解为货币或黄金。其余商品记为

$$x = (x_1, \dots, x_L).$$

准线性的意思是: 计价物部分以线性方式进入效用, 而其余商品通过非线性函数 φ 进入效用。

8.4.3 准线性效用下的需求

令计价物价格标准化为

$$p_0 = 1.$$

非计价商品价格向量为

$$p = (p_1, \dots, p_L).$$

给定收入 w , 消费者问题为

$$\max_{x_0, x} x_0 + \varphi(x)$$

满足

$$x_0 + p \cdot x \leq w, \quad x \in \mathbb{R}_+^L.$$

由于效用对 x_0 严格递增, 局部不饱和成立, 预算约束必然紧:

$$x_0 + p \cdot x = w.$$

于是

$$x_0 = w - p \cdot x.$$

代回目标函数, 得到

$$x_0 + \varphi(x) = w - p \cdot x + \varphi(x) = w + [\varphi(x) - p \cdot x].$$

由于 w 只是加性常数, 最优 x 由

$$\max_{x \in \mathbb{R}_+^L} [\varphi(x) - p \cdot x]$$

决定。

Proposition 8.4.3.

准线性消费者问题

$$\max_{x_0, x} x_0 + \varphi(x) \quad s.t. \quad x_0 + p \cdot x \leq w$$

的解可写为

$$(x_0, x) = (w - p \cdot x(p), x(p)),$$

其中 $x(p)$ 解

$$\max_{x \in \mathbb{R}_+^L} [\varphi(x) - p \cdot x].$$

因此非计价商品需求 $x(p)$ 只依赖价格 p , 不依赖收入 w 。

这就是准线性模型最重要的简化：非计价商品没有 income effect（收入效应）。收入变化只会改变计价物消费 x_0 , 不改变 $x_1, \dots, x_L$ 的需求。

8.4.4 可加分离的非线性部分

若

$$\varphi(x) = \varphi_1(x_1) + \dots + \varphi_L(x_L),$$

则

$$\varphi(x) - p \cdot x = \sum_{l=1}^L [\varphi_l(x_l) - p_l x_l].$$

因此最大化整个表达式等价于分别最大化每个一维问题

$$\max_{x_l \geq 0} \varphi_l(x_l) - p_l x_l.$$

若内点最优存在，一阶条件为

$$\varphi'_l(x_l) - p_l = 0.$$

于是

$$x_l(p) = (\varphi'_l)^{-1}(p_l).$$

这说明商品 l 的需求只依赖自身价格 p_l 。这为中级微观经济学中“单个市场需求曲线”的局部均衡分析提供了一个一般均衡基础。

8.4.5 准线性模型的局限

准线性效用在微观经济学中很常用，因为它能让研究者集中分析一个市场，并把其他商品折叠进计价物。但是它也明显不现实：非计价商品需求完全不依赖收入，而现实中大多数商品都有收入效应。因此准线性模型适合用于突出某些机制，而不是作为所有消费问题的通用描述。

8.4.6 均衡配置最大化效用和

现在考虑一个准线性纯交换经济

$$\mathcal{E} = \{\mathcal{I}, (e_{i0}, e_i), (u_i)\},$$

其中

$$u_i(x_0, x) = x_0 + \varphi_i(x).$$

这里 e_{i0} 是主体 i 的计价物禀赋, $e_i \in \mathbb{R}_+^L$ 是非计价商品禀赋。假设每个 φ_i 连续、可微、凹, 并且

$$\frac{\partial \varphi_i}{\partial x_l}(x) \rightarrow +\infty \quad \text{as } x_l \downarrow 0.$$

最后一个条件保证最优的非计价商品消费通常位于内部。

Theorem 8.4.3.

准线性均衡的社会规划表示 若 $\{(1, p), (x_{i0}, x_i)_{i=1}^I\}$ 是准线性经济的 *Walrasian equilibrium*, 则非计价商品配置 $(x_i)_{i=1}^I$ 解社会规划问题

$$\max_{(y_i)} \sum_{i=1}^I \varphi_i(y_i)$$

满足

$$\sum_{i=1}^I (y_{il} - e_{il}) \leq 0, \quad l = 1, \dots, L.$$

在该规划问题中, 均衡价格 p_l 可以解释为第 l 个资源约束的 *Lagrange multiplier* (拉格朗日乘子)。

Proof. 在均衡价格 p 下, 主体 i 的非计价商品需求 x_i 解

$$\max_{y_i \in \mathbb{R}_+^L} [\varphi_i(y_i) - p \cdot y_i].$$

因此对任意 y_i ,

$$\varphi_i(x_i) - p \cdot x_i \geq \varphi_i(y_i) - p \cdot y_i.$$

对所有主体求和:

$$\sum_{i=1}^I \varphi_i(x_i) \geq \sum_{i=1}^I \varphi_i(y_i) + p \cdot \sum_{i=1}^I (x_i - y_i).$$

若 (y_i) 是社会规划问题的任意可行配置, 则

$$\sum_{i=1}^I y_i \leq \sum_{i=1}^I e_i.$$

均衡中由 Walras 法则与市场出清可得

$$p \cdot \sum_{i=1}^I (x_i - e_i) = 0, \quad p \succeq 0.$$

所以

$$p \cdot \sum_{i=1}^I (x_i - y_i) = p \cdot \sum_{i=1}^I (x_i - e_i) + p \cdot \sum_{i=1}^I (e_i - y_i) \geq 0.$$

代回上式得到

$$\sum_{i=1}^I \varphi_i(x_i) \geq \sum_{i=1}^I \varphi_i(y_i).$$

因此 (x_i) 最大化非计价商品效用和。

8.4.7 最大化效用和也能生成均衡

Theorem 8.4.4.

社会规划配置生成准线性均衡 在上述准线性经济中, 若 $(x_i)_{i=1}^I$ 解

$$\max_{(y_i)} \sum_{i=1}^I \varphi_i(y_i)$$

满足

$$\sum_{i=1}^I (y_{il} - e_{il}) \leq 0, \quad l = 1, \dots, L,$$

并令 p_l 为对应资源约束的乘子, 则

$$\{(1, p), (x_{i0}, x_i)_{i=1}^I\}$$

是 *Walrasian equilibrium*, 其中

$$p = (p_1, \dots, p_L), \quad x_{i0} = e_{i0} + p \cdot (e_i - x_i).$$

Proof. 把资源约束写成

$$\sum_{i=1}^I e_{il} - \sum_{i=1}^I y_{il} \geq 0.$$

规划问题的拉格朗日函数为

$$\mathcal{L}((y_i), p) = \sum_{i=1}^I \varphi_i(y_i) + \sum_{l=1}^L p_l \left(\sum_{i=1}^I e_{il} - \sum_{i=1}^I y_{il} \right),$$

其中

$$p_l \geq 0.$$

一阶条件给出

$$\frac{\partial \varphi_i}{\partial x_l}(x_i) = p_l, \quad i = 1, \dots, I, \quad l = 1, \dots, L.$$

由于 φ_i 凹, 这说明 x_i 最大化

$$\varphi_i(y_i) - p \cdot y_i.$$

于是, 给定财富

$$w_i = e_{i0} + p \cdot e_i,$$

消费

$$x_{i0} = e_{i0} + p \cdot (e_i - x_i)$$

使预算约束紧:

$$x_{i0} + p \cdot x_i = e_{i0} + p \cdot e_i = w_i.$$

同时 x_i 是非计价商品的最优选择, 因此 (x_{i0}, x_i) 是主体 i 在价格 $(1, p)$ 下的最优消费。

规划问题的可行性给出非计价商品市场出清:

$$\sum_{i=1}^I x_i \preceq \sum_{i=1}^I e_i.$$

互补松弛给出

$$p_l \left(\sum_{i=1}^I e_{il} - \sum_{i=1}^I x_{il} \right) = 0 \quad \forall l.$$

因此

$$\sum_{i=1}^I x_{i0} = \sum_{i=1}^I e_{i0} + p \cdot \sum_{i=1}^I (e_i - x_i) = \sum_{i=1}^I e_{i0}.$$

计价物市场也出清。所以给定价格 $(1, p)$ 与配置 (x_{i0}, x_i) 构成 Walrasian equilibrium。 ■

8.4.8 福利含义

上面两个定理合起来说明, 在准线性经济中:

1. 竞争均衡的非计价商品配置最大化

$$\sum_{i=1}^I \varphi_i(x_i);$$

2. 反过来, 最大化该效用和的配置可以通过适当价格支持为竞争均衡。

这给出一种特殊意义下的福利性质: 均衡配置实现了非计价商品效用部分的总和最大化。它可以看作 Bentham “最大多数人的最大幸福” 思想的一个数学版本。不过, 这个结论强烈依赖准线性结构; 在一般效用下, 效用数值不能直接相加, 收入效应也不能被忽略。

8.4.9 例子: 一维准线性经济

考虑 I 个主体、一个非计价商品的准线性经济。主体 i 的效用为

$$u_i(x_0, x) = x_0 + \beta_i \log x, \quad \beta_i > 0.$$

非线性部分为

$$\varphi_i(x) = \beta_i \log x.$$

令非计价商品总禀赋为

$$e := \sum_{i=1}^I e_i.$$

根据准线性福利定理，求均衡配置可以转化为解

$$\max_{x_1, \dots, x_I} \sum_{i=1}^I \beta_i \log x_i$$

满足

$$\sum_{i=1}^I (x_i - e_i) \leq 0.$$

等价地，

$$\sum_{i=1}^I x_i \leq e.$$

写拉格朗日函数

$$\mathcal{L} = \sum_{i=1}^I \beta_i \log x_i + p \left(e - \sum_{i=1}^I x_i \right).$$

对 x_i 的一阶条件为

$$\frac{\beta_i}{x_i} - p = 0.$$

因此

$$x_i = \frac{\beta_i}{p}.$$

由于 $\log x$ 严格递增，总资源约束必紧：

$$\sum_{i=1}^I x_i = e.$$

代入得到

$$\sum_{i=1}^I \frac{\beta_i}{p} = e,$$

所以

$$p = \frac{\sum_{i=1}^I \beta_i}{e}.$$

最终

$$x_i^* = e \frac{\beta_i}{\sum_{j=1}^I \beta_j}.$$

也就是说，非计价商品按偏好强度参数 β_i 成比例分配。若需要写出计价物消费，则

$$x_{i0}^* = e_{i0} + p(e_i - x_i^*).$$

Sec 8.5

本讲总结

第八章的核心逻辑可以概括为：

1. 一般均衡把多个主体、多个商品和多个市场放在同一个系统中分析；
2. Arrow-Debreu 经济由主体、禀赋和效用函数构成，竞争均衡要求个体最优化与市场出清同时成立；

3. 由于价格只通过预算集中的相对比例起作用, 所有价格可以同乘一个正数而不改变需求, 因此需要价格标准化;
4. 局部不饱和偏好保证消费者花光收入, 从而推出 Walras Law:

$$p \cdot z(p) = 0;$$

5. Walras Law 说明只要价格严格为正, 检查 $L - 1$ 个市场即可推出最后一个市场出清;
6. 在 Cobb-Douglas 经济中, 固定支出份额使需求和市场出清方程具有清晰结构;
7. 在 quasi-linear economy 中, 非计价商品需求不依赖收入, 均衡配置可由最大化

$$\sum_i \varphi_i(x_i)$$

的社会规划问题刻画;

8. 准线性福利结论很有用, 但依赖无收入效应这一特殊假设, 不能直接推广到一般偏好。

Sec 9.1 总览

第九章讨论 **Convex Sets and Convex Functions (凸集与凸函数)**。前面几章已经多次使用 convexity (凸性) 来判断优化问题是否有良好性质; 本章把这些概念系统整理起来, 并说明它们为什么能支撑福利经济学中的基本定理。

本章主线如下:

1. 定义 convex sets (凸集)、convex hull (凸包) 与 convex combination (凸组合);
2. 用 hyperplanes (超平面) 与 half spaces (半空间) 描述几何分割;
3. 证明 convex sets 的 separation theorem (分离定理);
4. 回顾 convex functions (凸函数) 与 quasi-convex functions (拟凸函数) 的刻画;
5. 把凸分析应用到均衡的福利性质, 特别是 Pareto 有效性 (Pareto efficiency)。

Sec 9.2 凸集

9.2.1 凸集的定义

Definition 9.2.1.

集合 $C \subset \mathbb{R}^N$ 称为 **convex set (凸集)**, 如果对任意

$$x, y \in C$$

和任意

$$\alpha \in [0, 1],$$

都有

$$(1 - \alpha)x + \alpha y \in C.$$

点

$$(1 - \alpha)x + \alpha y$$

是 x 与 y 连线上的点。当 $\alpha = 0$ 时它等于 x ; 当 $\alpha = 1$ 时它等于 y ; 当 $0 < \alpha < 1$ 时, 它位于两点之间。因此, 凸集的几何含义是: 集合内任意两点之间的整条线段都仍留在集合内。

例如, 矩形、圆、椭圆、三角形和正多边形都是凸集; 星形区域或带凹陷的区域通常不是凸集。需要注意的是, “凸” 这个汉字本身对应的形状并不是凸集, 因为可以找到两个内部点, 使得连接它们的线段有一部分落在形状外部。




图 9.1: 凸集与非凸集的例子: 任意两点之间的线段若可能离开集合, 则该集合不是凸集

9.2.2 凸包

Definition 9.2.2.

给定任意集合 $A \subset \mathbb{R}^N$, 包含 A 的最小凸集称为 A 的 **convex hull (凸包)**, 记作

$$\text{co}(A).$$

这里“最小”是按集合包含关系理解的: $\text{co}(A)$ 是所有包含 A 的凸集的交集。直观上, 它是把 A 用最少的凸区域“包起来”。




图 9.2: 凸包: 把原集合 A 填补成包含它的最小凸集

9.2.3 凸组合与凸包的存在

Definition 9.2.3.

给定有限个点

$$\{x_k\}_{k=1}^K \subset \mathbb{R}^N,$$

若

$$x = \sum_{k=1}^K \alpha_k x_k,$$

其中

$$\alpha_k \geq 0, \quad \sum_{k=1}^K \alpha_k = 1,$$

则称 x 是这些点的一个 **convex combination** (凸组合)。

两个点的凸组合就是线段上的点；多个点的凸组合则是这些点所张成的凸区域中的点。

Proposition 9.2.1.

设 $A \subset \mathbb{R}^N$ 为任意集合，则

$$\text{co}(A)$$

恰好由 A 中有限多个点的所有凸组合构成。

Proof. 令

$$S := \left\{ \sum_{k=1}^K \alpha_k x_k \mid K \in \mathbb{N}, x_k \in A, \alpha_k \geq 0, \sum_{k=1}^K \alpha_k = 1 \right\}.$$

显然 $A \subset S$ ，因为任意 $a \in A$ 都可以写成 $1 \cdot a$ 。

先说明 S 是凸集。任取

$$x = \sum_{k=1}^K \alpha_k x_k \in S, \quad y = \sum_{m=1}^M \beta_m y_m \in S,$$

其中 $x_k, y_m \in A$ ，权重非负且各自加总为 1。对任意 $\theta \in [0, 1]$,

$$(1 - \theta)x + \theta y = \sum_{k=1}^K (1 - \theta)\alpha_k x_k + \sum_{m=1}^M \theta\beta_m y_m.$$

这些新权重仍非负，并且加总为

$$(1 - \theta) \sum_{k=1}^K \alpha_k + \theta \sum_{m=1}^M \beta_m = 1 - \theta + \theta = 1.$$

因此 $(1 - \theta)x + \theta y \in S$ ，即 S 是凸集。

由于 S 是包含 A 的凸集，根据凸包的最小性，

$$\text{co}(A) \subset S.$$

另一方面，任何包含 A 的凸集都必须包含 A 中任意有限点的凸组合，所以

$$S \subset \text{co}(A).$$

两边合并得到

$$S = \text{co}(A).$$



Sec 9.3

超平面与半空间

9.3.1 从直线和平面到超平面

在 $\mathbb{R}^2$ 中, 直线可以写成

$$a_1x_1 + a_2x_2 = c,$$

其中 a_1, a_2, c 为实数, 且 $(a_1, a_2) \neq 0$ 。在 $\mathbb{R}^3$ 中, 平面可以写成

$$a_1x_1 + a_2x_2 + a_3x_3 = c.$$

这些都是更高维 hyperplane (超平面) 的特殊情形。

对

$$a = (a_1, \dots, a_N), \quad x = (x_1, \dots, x_N),$$

记内积为

$$\langle a, x \rangle = a_1x_1 + \dots + a_Nx_N.$$

若 $a \neq 0$, 集合

$$H := \{x \in \mathbb{R}^N \mid \langle a, x \rangle = c\}$$

称为 $\mathbb{R}^N$ 中的一个 **hyperplane (超平面)**。

向量 a 与超平面正交, 是该超平面的 normal vector (法向量)。在二维中, 超平面是直线; 在三维中, 超平面是平面; 在一般 N 维中, 它是一个维度为 $N - 1$ 的仿射集合。

9.3.2 半空间

由同一个超平面可以定义两个 half spaces (半空间):

$$H^+ := \{x \in \mathbb{R}^N \mid \langle a, x \rangle \geq c\},$$

$$H^- := \{x \in \mathbb{R}^N \mid \langle a, x \rangle \leq c\}.$$

其中 H^+ 是沿法向量 a 方向的一侧, H^- 是沿 $-a$ 方向的一侧。

Proposition 9.3.2.

超平面 H 与半空间 H^+, H^- 都是凸集。

Proof. 先看超平面。若 $x, y \in H$, 则

$$\langle a, x \rangle = c, \quad \langle a, y \rangle = c.$$

对任意 $\alpha \in [0, 1]$,

$$\langle a, (1 - \alpha)x + \alpha y \rangle = (1 - \alpha)\langle a, x \rangle + \alpha\langle a, y \rangle = (1 - \alpha)c + \alpha c = c.$$

所以 $(1 - \alpha)x + \alpha y \in H$, H 是凸集。

半空间同理。若 $x, y \in H^-$, 则

$$\langle a, x \rangle \leq c, \quad \langle a, y \rangle \leq c.$$

于是

$$\langle a, (1 - \alpha)x + \alpha y \rangle \leq (1 - \alpha)c + \alpha c = c.$$

故 $(1 - \alpha)x + \alpha y \in H^-$ 。 H^+ 的证明完全类似。

Sec 9.4 凸集的分离

9.4.1 分离超平面

给定两个集合 $A, B \subset \mathbb{R}^N$, 若存在 $a \neq 0$ 与 $c \in \mathbb{R}$, 使得

$$\langle a, x \rangle \leq c \quad \forall x \in A,$$

并且

$$\langle a, y \rangle \geq c \quad \forall y \in B,$$

则称超平面

$$\langle a, z \rangle = c$$

separates (分离) A 与 B 。也可以把不等号方向全部反过来, 这相当于把法向量 a 换成 $-a$ 。




图 9.3: 分离超平面: 法向量 a 决定两侧半空间 H^- 与 H^+

9.4.2 可分离性的等价写法

集合 A 与 B 可由方向 a 分离, 当且仅当

$$\sup_{x \in A} \langle a, x \rangle \leq \inf_{y \in B} \langle a, y \rangle.$$

只要上式成立, 就可以选择任意

$$c \in \left[\sup_{x \in A} \langle a, x \rangle, \inf_{y \in B} \langle a, y \rangle \right],$$

从而得到分离超平面。

若不等式严格成立：

$$\sup_{x \in A} \langle a, x \rangle < \inf_{y \in B} \langle a, y \rangle,$$

则称 A 与 B 可以被 **strictly separated** (严格分离)。

9.4.3 分离超平面定理

Theorem 9.4.1.

Separating Hyperplane Theorem (分离超平面定理) 设 $C, D \subset \mathbb{R}^N$ 非空且凸。

1. 若

$$C \cap D = \emptyset,$$

则存在一个超平面分离 C 与 D 。

2. 若 C, D 都闭, 且其中一个紧, 则它们可以被严格分离。

这个定理是凸分析中的基础工具。直观上, 两个不相交的凸集之间总能放入一张“平面刀片”; 如果两个集合足够规整, 并且至少一个集合紧, 那么这张刀片还能与两边都留出正距离。

9.4.4 投影引理

分离定理的证明依赖一个几何事实: 对凸集外的点, 可以找到唯一的最近点。

Theorem 9.4.2.

Projection Lemma (投影引理) 设 $C \subset \mathbb{R}^N$ 非空且凸。对任意 $x \in \mathbb{R}^N$, 存在唯一点

$$P_C(x) \in \text{cl } C$$

使得

$$\|x - P_C(x)\| = \inf_{y \in C} \|x - y\|.$$

并且对任意 $z \in C$,

$$\langle x - P_C(x), z - P_C(x) \rangle \leq 0.$$

Proof. 记

$$\delta := \inf\{\|x - y\| \mid y \in C\} \geq 0.$$

取一系列 $\{y_k\} \subset C$, 使得

$$\|x - y_k\| \rightarrow \delta.$$

对任意 k, l , 利用平行四边形恒等式, 有

$$\|y_k - y_l\|^2 = 2\|x - y_k\|^2 + 2\|x - y_l\|^2 - 4\left\|x - \frac{y_k + y_l}{2}\right\|^2.$$

Projection Lemma

Let C be nonempty and convex. Then:

- Any $x \in \mathbb{R}^N$ has a unique closest point $P_C(x) \in \text{cl}C$ (the projection of x on $\text{cl}C$)
- For any $z \in C$: $\langle x - P_C(x), z - P_C(x) \rangle \leq 0$




图 9.4: 投影引理的几何含义: 从外点到凸集的最近点处, 连线与所有可行方向形成钝角

由于 C 是凸集,

$$\frac{y_k + y_l}{2} \in C,$$

所以

$$\left\| x - \frac{y_k + y_l}{2} \right\| \geq \delta.$$

于是

$$\|y_k - y_l\|^2 \leq 2\|x - y_k\|^2 + 2\|x - y_l\|^2 - 4\delta^2 \rightarrow 2\delta^2 + 2\delta^2 - 4\delta^2 = 0.$$

故 $\{y_k\}$ 是 Cauchy sequence (Cauchy 序列), 从而在 $\mathbb{R}^N$ 中收敛。设

$$y_k \rightarrow y.$$

由于每个 $y_k \in C$, 极限 y 属于闭包 $\text{cl}C$ 。由三角不等式,

$$\|x - y\| \leq \|x - y_k\| + \|y_k - y\| \rightarrow \delta.$$

而 δ 是下确界, 所以

$$\|x - y\| = \delta.$$

这说明 y 是最近点。

接着证明唯一性。若 $y_1, y_2 \in \text{cl}C$ 都是最近点, 则由同样的平行四边形恒等式,

$$\|y_1 - y_2\|^2 \leq 2\|x - y_1\|^2 + 2\|x - y_2\|^2 - 4\delta^2 = 0.$$

因此

$$y_1 = y_2.$$

唯一最近点记为 $P_C(x)$ 。

最后证明内积不等式。令

$$y = P_C(x).$$

取任意 $z \in C$, 以及上面构造中满足 $y_k \rightarrow y$ 的序列。由凸性, 对任意 $0 < \alpha \leq 1$,

$$(1 - \alpha)y_k + \alpha z \in C.$$

于是

$$\delta^2 = \|x - y\|^2 \leq \|x - (1 - \alpha)y_k - \alpha z\|^2.$$

令 $k \rightarrow \infty$, 得到

$$\|x - y\|^2 \leq \|x - y - \alpha(z - y)\|^2.$$

展开右边:

$$\|x - y - \alpha(z - y)\|^2 = \|x - y\|^2 - 2\alpha\langle x - y, z - y \rangle + \alpha^2\|z - y\|^2.$$

消去 $\|x - y\|^2$, 再除以 $\alpha > 0$:

$$0 \leq -2\langle x - y, z - y \rangle + \alpha\|z - y\|^2.$$

令 $\alpha \downarrow 0$, 得到

$$\langle x - y, z - y \rangle \leq 0.$$

9.4.5 点与凸集的分离

Proposition 9.4.3.

设 $C \subset \mathbb{R}^N$ 非空且凸, 且

$$\bar{x} \notin \text{int } C.$$

则存在超平面

$$\langle a, x \rangle = c$$

分离 $\bar{x}$ 与 C , 即

$$\langle a, \bar{x} \rangle \geq c \geq \langle a, z \rangle \quad \forall z \in C.$$

若进一步有

$$\bar{x} \notin \text{cl } C,$$

则可以严格分离:

$$\langle a, \bar{x} \rangle > c > \langle a, z \rangle \quad \forall z \in C.$$

Proof. 先看 $\bar{x} \notin \text{cl } C$ 的情形. 令

$$y = P_C(\bar{x})$$

为 $\bar{x}$ 到 $\text{cl } C$ 的投影. 定义

$$a = \bar{x} - y \neq 0, \quad c = \langle a, y \rangle + \frac{1}{2}\|a\|^2.$$

对任意 $z \in C$, 投影引理给出

$$\langle \bar{x} - y, z - y \rangle \leq 0.$$

也就是

$$\langle a, z \rangle \leq \langle a, y \rangle < \langle a, y \rangle + \frac{1}{2}\|a\|^2 = c.$$

另一方面,

$$\langle a, \bar{x} \rangle - c = \langle \bar{x} - y, \bar{x} \rangle - \left(\langle a, y \rangle + \frac{1}{2}\|a\|^2 \right) = \|a\|^2 - \frac{1}{2}\|a\|^2 = \frac{1}{2}\|a\|^2 > 0.$$

因此

$$\langle a, \bar{x} \rangle > c > \langle a, z \rangle,$$

严格分离成立。

再看

$$\bar{x} \in \text{cl } C \quad \text{但} \quad \bar{x} \notin \text{int } C$$

的情形。取一列

$$x_k \notin \text{cl } C, \quad x_k \rightarrow \bar{x}.$$

对每个 x_k , 由刚才的严格分离结论, 存在 $a_k \neq 0$ 与 c_k 使

$$\langle a_k, x_k \rangle \geq c_k \geq \langle a_k, z \rangle \quad \forall z \in C.$$

不妨把 a_k 标准化为

$$\|a_k\| = 1.$$

单位球紧, 因此存在收敛子列

$$a_{k_l} \rightarrow a.$$

同时, 由于 $x_k \rightarrow \bar{x}$ 且 $\|a_k\| = 1$, 对应的 c_{k_l} 可以取收敛子列

$$c_{k_l} \rightarrow c.$$

对不等式

$$\langle a_{k_l}, x_{k_l} \rangle \geq c_{k_l} \geq \langle a_{k_l}, z \rangle$$

令 $l \rightarrow \infty$, 得到

$$\langle a, \bar{x} \rangle \geq c \geq \langle a, z \rangle \quad \forall z \in C.$$

这给出非严格分离。■

9.4.6 分离超平面定理的证明

Proof. 定义 Minkowski 差集

$$E := C - D := \{x - y \mid x \in C, y \in D\}.$$

由于 C, D 非空且凸, E 也是非空凸集。若

$$C \cap D = \emptyset,$$

则

$$0 \notin E.$$

由点与凸集的分离命题, 存在 $a \neq 0$ 使得

$$\langle a, 0 \rangle = 0 \geq \langle a, z \rangle \quad \forall z \in E.$$

对任意 $x \in C$ 与 $y \in D$, 有 $x - y \in E$, 所以

$$\langle a, x - y \rangle \leq 0.$$

等价地,

$$\langle a, x \rangle \leq \langle a, y \rangle.$$

因此

$$\sup_{x \in C} \langle a, x \rangle \leq \inf_{y \in D} \langle a, y \rangle.$$

选择两者之间的任意 c , 超平面

$$\langle a, z \rangle = c$$

就分离 C 与 D 。

若 C, D 闭且其中一个紧, 不妨设 D 紧。此时

$$E = C - D$$

是闭集。由于 $0 \notin E$, 再次使用点与闭凸集的严格分离结论, 存在 $a \neq 0$ 使

$$0 = \langle a, 0 \rangle > \langle a, z \rangle \quad \forall z \in E.$$

即对任意 $x \in C, y \in D$,

$$\langle a, x \rangle < \langle a, y \rangle.$$

所以可以选择 c 使得

$$\sup_{x \in C} \langle a, x \rangle < c < \inf_{y \in D} \langle a, y \rangle.$$

这就是严格分离。

Sec 9.5

凸函数与拟凸函数

9.5.1

凸函数与凹函数

Definition 9.5.4.

函数 f 称为 **convex function (凸函数)**, 如果对任意 x_1, x_2 与任意 $\alpha \in [0, 1]$,

$$f((1 - \alpha)x_1 + \alpha x_2) \leq (1 - \alpha)f(x_1) + \alpha f(x_2).$$

若反向不等式成立, 则称 f 为 **concave function (凹函数)**。等价地, f 凹当且仅当 $-f$ 凸。

凸函数的几何含义是: 函数图像位于任意两点弦线的下方。凹函数则相反, 图像位于弦线的上方。

9.5.2 一阶刻画

Proposition 9.5.4.

设 f 可微。则 f 是 *convex function*, 当且仅当对任意 x, y ,

$$f(y) - f(x) \geq \langle \nabla f(x), y - x \rangle.$$

若对任意 $x \neq y$ 上式严格成立, 则 f 严格凸。

Proof. 先设 f 凸。对 $t \in (0, 1)$, 由凸性,

$$f((1-t)x + ty) \leq (1-t)f(x) + tf(y).$$

整理得

$$\frac{f(x + t(y-x)) - f(x)}{t} \leq f(y) - f(x).$$

令 $t \downarrow 0$, 左边收敛到方向导数

$$\langle \nabla f(x), y - x \rangle.$$

于是

$$\langle \nabla f(x), y - x \rangle \leq f(y) - f(x).$$

反过来, 若上述一阶不等式对任意 x, y 成立。令

$$z = (1-\alpha)x + \alpha y.$$

分别把一阶不等式应用到 (z, x) 与 (z, y) :

$$f(x) \geq f(z) + \langle \nabla f(z), x - z \rangle,$$

$$f(y) \geq f(z) + \langle \nabla f(z), y - z \rangle.$$

第一式乘以 $1-\alpha$, 第二式乘以 α , 相加得到

$$(1-\alpha)f(x) + \alpha f(y) \geq f(z) + \langle \nabla f(z), (1-\alpha)(x-z) + \alpha(y-z) \rangle.$$

由于

$$(1-\alpha)(x-z) + \alpha(y-z) = 0,$$

所以

$$(1-\alpha)f(x) + \alpha f(y) \geq f(z),$$

即 f 凸。 ■

9.5.3 Hessian 刻画

Proposition 9.5.5.

设 $U \subset \mathbb{R}^N$ 是开凸集, $f: U \rightarrow \mathbb{R}$ 为 C^2 函数。则 f 在 U 上凸, 当且仅当 Hessian 矩阵

$$\nabla^2 f(x) = \left[\frac{\partial^2 f(x)}{\partial x_m \partial x_n} \right]_{m,n=1}^N$$

对每个 $x \in U$ 都 positive semidefinite (半正定)。

直观地说, Hessian 半正定意味着函数沿任意方向的二阶弯曲都非负。若 d 是任意方向, 则

$$d^\top \nabla^2 f(x) d \geq 0$$

表示沿直线 $x + td$ 观察, 函数不会向下弯。

9.5.4 上图集、下图集与凸性

Definition 9.5.5.

函数 f 的 epigraph (上图集) 定义为

$$\text{epi}(f) := \{(x, t) \mid t \geq f(x)\}.$$

函数 f 的 hypograph (下图集) 定义为

$$\text{hypo}(f) := \{(x, t) \mid t \leq f(x)\}.$$

Proposition 9.5.6.

函数 f 凸, 当且仅当

$$\text{epi}(f)$$

是凸集。函数 f 凹, 当且仅当

$$\text{hypo}(f)$$

是凸集。

这个刻画把函数凸性转化为集合凸性。凸函数图像上方的区域是凸的; 凹函数图像下方的区域是凸的。

9.5.5 拟凸函数

Definition 9.5.6.

函数 $f: \mathbb{R}^N \rightarrow \mathbb{R}$ 称为 **quasi-convex (拟凸)**, 如果它的所有 lower contour sets (下等值集)

$$L_f(\bar{y}) := \{x \mid f(x) \leq \bar{y}\}$$

都是凸集。

等价地, f 拟凸当且仅当对任意 x_1, x_2 和任意 $\alpha \in [0, 1]$,

$$f((1 - \alpha)x_1 + \alpha x_2) \leq \max\{f(x_1), f(x_2)\}.$$

这说明在连接两个点的线段上, 函数值不会高过两端点中较大的那个值。

凸函数一定是拟凸函数, 但拟凸函数不一定凸。拟凸性比凸性更弱, 也更适合表达“偏好或选择集合形状良好”的序数性质。

9.5.6 单调变换下的关系

若 f 拟凸, 且 $g: \mathbb{R} \rightarrow \mathbb{R}$ 严格递增, 则

$$g \circ f$$

仍然拟凸。原因是

$$g(f(x)) \leq \bar{y}$$

等价于

$$f(x) \leq g^{-1}(\bar{y}),$$

所以 $g \circ f$ 的下等值集只是 f 的某个下等值集。

但是, convexity (凸性) 和 concavity (凹性) 一般不被严格递增变换保留。例如

$$u(x) = \sqrt{x}$$

是凹函数, 而

$$f(t) = t^4$$

是凸且严格递增的函数。在 $x \geq 0$ 上,

$$(f \circ u)(x) = (\sqrt{x})^4 = x^2,$$

变成了凸函数。

这对效用函数很重要: 效用函数只在严格递增变换下代表同一偏好。因此, quasi-concavity (拟凹性) 是偏好的序数性质, 而 concavity (凹性) 不是纯粹的序数性质。

9.5.7 拟凸函数的一阶刻画

Proposition 9.5.7.

设 f 可微。则 f 拟凸，当且仅当对任意 x, y ，只要

$$f(y) \leq f(x),$$

就有

$$\langle \nabla f(x), y - x \rangle \leq 0.$$

直观上，如果 y 的函数值不高于 x ，那么从 x 指向 y 的方向不能是函数在 x 处的一阶上升方向。

9.5.8 偏好理论中的拟凹性

效用函数 u 称为 **quasi-concave (拟凹)**，如果所有 upper contour sets (上等值集)

$$U(\bar{u}) := \{x \in \mathbb{R}_+^N \mid u(x) \geq \bar{u}\}$$

都是凸集。

等价地，若

$$u(x) \geq \bar{u}, \quad u(y) \geq \bar{u},$$

则对任意 $\alpha \in [0, 1]$,

$$u((1 - \alpha)x + \alpha y) \geq \bar{u}.$$

经济学含义是 convex preferences (凸偏好)：如果两个消费束都至少和某个参考水平一样好，那么它们的混合也至少一样好。配合凸预算集，拟凹偏好通常会带来较好的需求性质。

9.5.9 间接效用与支出函数

消费者的 **indirect utility function (间接效用函数)** 定义为

$$v(p, m) = \max_{x \geq 0} \{u(x) \mid p \cdot x \leq m\}.$$

给定价格 p 与收入 m ，它回答“可达到的最高效用是多少”。

对应的 **expenditure function (支出函数)** 定义为

$$e(p, \bar{u}) = \min_{x \geq 0} \{p \cdot x \mid u(x) \geq \bar{u}\}.$$

给定价格 p 与目标效用 $\bar{u}$ ，它回答“达到 $\bar{u}$ 至少需要多少钱”。

二者满足基本对偶关系：

$$v(p, m) \geq \bar{u} \iff m \geq e(p, \bar{u}).$$

也就是说，收入足够支付达到 $\bar{u}$ 的最低成本，当且仅当预算集内可以达到至少 $\bar{u}$ 的效用。

9.5.10 支出函数关于价格凹

固定目标效用 $\bar{u}$, 定义

$$X(\bar{u}) := \{x \geq 0 \mid u(x) \geq \bar{u}\}.$$

则

$$e(p, \bar{u}) = \min_{x \in X(\bar{u})} p \cdot x.$$

对每个固定消费束 x , 函数

$$p \mapsto p \cdot x$$

是价格 p 的线性函数。支出函数是这一族线性函数的下包络 (lower envelope), 因此关于价格 p 是凹的。

形式化地, 对任意 p^1, p^2 与 $\alpha \in [0, 1]$,

$$e(\alpha p^1 + (1 - \alpha)p^2, \bar{u}) = \min_{x \in X(\bar{u})} [\alpha p^1 \cdot x + (1 - \alpha)p^2 \cdot x].$$

由于对任意 x ,

$$p^1 \cdot x \geq e(p^1, \bar{u}), \quad p^2 \cdot x \geq e(p^2, \bar{u}),$$

所以

$$e(\alpha p^1 + (1 - \alpha)p^2, \bar{u}) \geq \alpha e(p^1, \bar{u}) + (1 - \alpha)e(p^2, \bar{u}).$$

故 $e(p, \bar{u})$ 关于 p 凹。

9.5.11 间接效用关于价格和收入拟凸

考虑间接效用函数的下等值集:

$$L_v(\bar{u}) := \{(p, m) \mid v(p, m) \leq \bar{u}\}.$$

由消费者对偶关系, 在标准单调性假设下可以写成

$$v(p, m) \leq \bar{u} \iff m \leq e(p, \bar{u}).$$

因此

$$L_v(\bar{u}) = \{(p, m) \mid m \leq e(p, \bar{u})\}.$$

右边正是支出函数关于 p 的 hypograph (下图集)。由于 $e(p, \bar{u})$ 关于 p 凹, 它的 hypograph 是凸集。所以 $L_v(\bar{u})$ 是凸集, 从而

$$v(p, m)$$

关于 (p, m) 是 quasi-convex (拟凸) 的。

9.5.12 拟凸问题中 KKT 的充分性

考虑优化问题

$$\min_x f(x) \quad \text{s.t.} \quad g_i(x) \leq 0, \quad i = 1, \dots, I,$$

其中 f 与 g_i 都可微且 quasi-convex。

Theorem 9.5.3.

拟凸约束问题中 KKT 的充分性 若存在严格可行点 x^0 使得

$$g_i(x^0) < 0 \quad \forall i$$

即 Slater condition (Slater 条件) 成立, 并且存在乘子 $\lambda_1, \dots, \lambda_I$ 使得某点 x^* 满足 KKT 条件。若

$$\nabla f(x^*) \neq 0,$$

则 x^* 是该问题的解。

Proof. 反证。若 x^* 不是最优解, 则存在可行点 y 使

$$f(y) < f(x^*).$$

由拟凸函数的一阶刻画, 并利用 $\nabla f(x^*) \neq 0$, 可得

$$\langle \nabla f(x^*), y - x^* \rangle < 0.$$

另一方面, 对任意活跃约束 i , 有

$$g_i(x^*) = 0, \quad g_i(y) \leq 0,$$

所以

$$g_i(y) \leq g_i(x^*).$$

由 g_i 的拟凸一阶刻画,

$$\langle \nabla g_i(x^*), y - x^* \rangle \leq 0.$$

若约束不活跃, 则互补松弛给出 $\lambda_i = 0$ 。

因此

$$\left\langle \nabla f(x^*) + \sum_{i=1}^I \lambda_i \nabla g_i(x^*), y - x^* \right\rangle < 0.$$

但 KKT 的 stationarity 条件给出

$$\nabla f(x^*) + \sum_{i=1}^I \lambda_i \nabla g_i(x^*) = 0,$$

于是左边应等于 0, 矛盾。因此不存在这样的 y , x^* 是解。 ■

Sec 9.6 应用：均衡的福利性质**9.6.1 均衡是否“理想”？**

上一章在准线性效用下说明：竞争均衡配置可以最大化效用和。因此, 在某种意义上, 均衡是 desirable (理想的)。更一般地, 福利经济学有两个核心结论：

1. **First Welfare Theorem (第一福利定理)**：竞争均衡配置是 efficient (有效) 的；

2. **Second Welfare Theorem (第二福利定理)**: 在合适条件下, 任何有效配置都可以通过适当的直接税或补贴实现为竞争均衡。

本章课件不完整证明这两个福利定理, 而是先建立 Pareto efficiency 与加权福利最大化之间的凸分析联系。

9.6.2 一致同意原则

考虑一个有 I 个主体、 L 种商品的经济。主体 i 的效用函数为

$$u_i : \mathbb{R}_+^L \rightarrow \mathbb{R}.$$

设

$$x = (x_i)_{i=1}^I, \quad y = (y_i)_{i=1}^I$$

是两个配置。

一个自然问题是：什么时候能说配置 y 比配置 x 更好？困难在于，不同主体可能有不同意见。有人偏好较少政府干预，有人偏好较多再分配；有人重视效率，有人重视公平。因此，Pareto 方法放弃对任意两个配置做完整社会排序，只排序那些所有人都一致同意的改进：

若所有主体都认为 y 不差于 x ，且至少一人更好，则 y 社会优于 x 。

9.6.3 Pareto 有效性

设经济中有 I 个消费者，效用函数

$$u_i : \mathbb{R}_+^N \rightarrow \mathbb{R}$$

连续。主体 i 的消费向量为

$$x_i \in \mathbb{R}_+^N.$$

总禀赋为

$$e \in \mathbb{R}_+^N.$$

Definition 9.6.7.

配置 $\{x_i\}_{i=1}^I$ 称为 **feasible allocation (可行配置)**，如果

$$\sum_{i=1}^I x_i \leq e.$$

Definition 9.6.8.

若配置 $\{y_i\}_{i=1}^I$ 满足

$$u_i(y_i) \geq u_i(x_i) \quad \forall i,$$

并且存在某个主体 j 使得

$$u_j(y_j) > u_j(x_j),$$

则称 $\{y_i\}$ **Pareto dominates (Pareto 支配)** $\{x_i\}$ 。

Definition 9.6.9.

可行配置 $\{x_i\}$ 称为 **Pareto efficient (Pareto 有效)**, 如果不存在另一个可行配置 $\{y_i\}$ Pareto 支配它。若存在这样的 $\{y_i\}$, 则称 $\{x_i\}$ Pareto inefficient (Pareto 无效), 而 $\{y_i\}$ 称为相对于 $\{x_i\}$ 的 Pareto improvement (Pareto 改进)。

换言之, Pareto 无效表示: 可以让至少一个人变好, 同时不让任何人变差。Pareto 有效则表示: 任何进一步改进都必须以某些人的损失为代价。

9.6.4 蛋糕例子

假设只有一种商品: 蛋糕。所有人都喜欢蛋糕。考虑三种配置:

- A: 我拿走全部蛋糕, 你没有蛋糕;
- B: 我们平分蛋糕;
- C: 我拿一半, 另一半被丢掉。

A 和 B 都是 Pareto efficient。因为要让某个人获得更多蛋糕, 就必须从另一个人那里拿走蛋糕, 使另一个人变差。

C 则是 Pareto inefficient。因为被丢掉的一半蛋糕可以送给某个人, 使他变好, 同时不让任何人变差。

这个例子说明 Pareto efficiency 是一个很弱的评价标准。它只要求 unanimous agreement (一致同意), 不关心分配公平。因此, 极端不平等的配置也可能是 Pareto 有效的。

9.6.5 福利最大化推出 Pareto 有效

Proposition 9.6.8.

设

$$\lambda \in \mathbb{R}_{++}^I,$$

并定义社会福利函数

$$W(x_1, \dots, x_I) = \sum_{i=1}^I \lambda_i u_i(x_i).$$

则:

1. W 在所有可行配置上达到最大值;
2. 任意最大化 W 的配置都是 Pareto efficient。

Proof. 可行配置集合为

$$F = \left\{ (x_1, \dots, x_I) \in (\mathbb{R}_+^N)^I \mid \sum_{i=1}^I x_i \preceq e \right\}.$$

该集合非空，例如 $x_i = 0$ 对所有 i 可行。它也是闭且有界的，因此紧。由于每个 u_i 连续， W 连续。由 Weierstrass 极值定理， W 在 F 上达到最大值。

接着证明最大点 Pareto 有效。设 $\{x_i\}$ 最大化 W 。若它不是 Pareto efficient，则存在可行配置 $\{y_i\}$ Pareto 支配它，即

$$u_i(y_i) \geq u_i(x_i) \quad \forall i,$$

且对某个 j ,

$$u_j(y_j) > u_j(x_j).$$

由于

$$\lambda_i > 0 \quad \forall i,$$

可得

$$\sum_{i=1}^I \lambda_i u_i(y_i) > \sum_{i=1}^I \lambda_i u_i(x_i).$$

即

$$W(y_1, \dots, y_I) > W(x_1, \dots, x_I),$$

这与 $\{x_i\}$ 最大化 W 矛盾。因此 $\{x_i\}$ 必为 Pareto efficient。■

9.6.6 Pareto 权重的构造

上一命题说明：正权重加权福利最大化给出 Pareto efficient allocation。反方向也成立，不过需要效用函数的凹性。

Proposition 9.6.9.

假设每个 u_i 都是 concave (凹) 的，并且可行配置

$$\{\bar{x}_i\}_{i=1}^I$$

是 Pareto efficient。则存在

$$\lambda \in \mathbb{R}_+^I$$

使得 $\{\bar{x}_i\}$ 最大化

$$W(x_1, \dots, x_I) = \sum_{i=1}^I \lambda_i u_i(x_i)$$

于所有可行配置之上。

Proof. 定义效用可达下方集合

$$V := \{v = (v_1, \dots, v_I) \in \mathbb{R}^I \mid \exists \{x_i\} \in F, \forall i, v_i \leq u_i(x_i)\}.$$




图 9.5: Pareto 权重的构造：用分离超平面把可达效用集合 V 与严格改进集合 D 分开

它表示：存在某个可行配置，其效用向量至少达到 v 。

集合 V 非空，因为 $\{\bar{x}_i\}$ 可行。它也是凸集。原因是，若 $v, w \in V$ ，则存在可行配置 $\{x_i\}$ 与 $\{y_i\}$ 使

$$v_i \leq u_i(x_i), \quad w_i \leq u_i(y_i).$$

对任意 $\alpha \in [0, 1]$ ，由于可行集合 F 凸，

$$z_i = (1 - \alpha)x_i + \alpha y_i$$

给出可行配置。又因 u_i 凹，

$$u_i(z_i) \geq (1 - \alpha)u_i(x_i) + \alpha u_i(y_i) \geq (1 - \alpha)v_i + \alpha w_i.$$

所以 $(1 - \alpha)v + \alpha w \in V$ 。

记

$$\bar{u} := (u_1(\bar{x}_1), \dots, u_I(\bar{x}_I)).$$

定义严格改进集合

$$D := \bar{u} + \mathbb{R}_{++}^I.$$

集合 D 是所有严格高于 $\bar{u}$ 的效用向量，显然非空且凸。

由于 $\{\bar{x}_i\}$ Pareto efficient，不存在可行配置使所有人不差且至少一人更好，特别不存在效用向量严格高于 $\bar{u}$ 。因此

$$V \cap D = \emptyset.$$

由 separating hyperplane theorem，存在

$$0 \neq \lambda \in \mathbb{R}^I$$

使得对任意 $v \in V$ 与任意 $d \in \mathbb{R}_{++}^I$ ，

$$\langle \lambda, v \rangle \leq \langle \lambda, \bar{u} + d \rangle.$$

先说明 $\lambda_i \geq 0$ 。若某个 $\lambda_i < 0$ ，让 $d_i \rightarrow +\infty$ 而其他分量固定，则右边

$$\langle \lambda, \bar{u} + d \rangle$$

会趋向 $-\infty$ ，无法对所有 $v \in V$ 成立。因此

$$\lambda \in \mathbb{R}_+^I.$$

再令 $d \downarrow 0$ ，得到

$$\langle \lambda, v \rangle \leq \langle \lambda, \bar{u} \rangle \quad \forall v \in V.$$

对任意可行配置 $\{x_i\}$ ，其效用向量

$$(u_1(x_1), \dots, u_I(x_I))$$

属于 V 。因此

$$\sum_{i=1}^I \lambda_i u_i(x_i) \leq \sum_{i=1}^I \lambda_i u_i(\bar{x}_i).$$

这正说明 $\{\bar{x}_i\}$ 最大化加权福利函数。 ■

这两个命题合起来说明：在凹效用和凸可行集下，Pareto 有效配置可以用加权福利最大化 (weighted welfare maximization) 刻画。权重 λ_i 可理解为社会福利函数中赋予主体 i 的福利权重 (welfare weight)。

Sec 9.7 本讲总结

第九章的核心逻辑可以概括为：

1. 凸集要求任意两点之间的线段都留在集合内，凸包是包含给定集合的最小凸集；
2. 超平面与半空间是刻画凸集几何结构的基本工具，二者本身都是凸集；
3. 分离超平面定理说明，不相交凸集可以被某个超平面分开；闭性和紧性可以进一步保证严格分离；
4. 投影引理给出分离定理的几何基础：凸集外点到闭包有唯一最近点，最近点方向与所有可行方向形成钝角；
5. 函数凸性可以通过一阶不等式、Hessian 半正定、epigraph 凸性等方式刻画；
6. 拟凸性只要求 lower contour sets 凸，因此比凸性弱，并且在严格递增变换下保持；
7. 在偏好理论中，更自然的序数性质是 quasi-concavity，它对应 convex preferences；
8. 支出函数是线性函数族的下包络，因此关于价格凹；间接效用函数关于价格和收入拟凸；
9. Pareto efficiency 是一个弱但重要的福利标准；在凹效用条件下，Pareto 有效配置可以由加权福利最大化刻画。

动态优化与 RAMSEY 模型

Part

Sec 10.1 总览

本章进入 **dynamic optimization (动态优化)**。前面章节主要研究静态优化：决策者一次性选择一个向量 x ，使目标函数达到最大或最小。许多经济问题却不是一次性决策，而是跨期决策：

1. 家庭在今天消费和为未来储蓄之间权衡；
2. 企业在当前利润和未来资本、进入、退出或研发之间权衡；
3. 政府的财政政策和货币政策会影响未来资源约束；
4. 经济增长模型研究资本如何随时间积累。

动态优化的核心问题是：决策者如何选择一整条随时间变化的行动路径 (sequence of actions)。

10.1.1 跨期权衡

动态问题的基本权衡可以写成

today's output = today's consumption + investment for tomorrow.

当前消费越多，当前效用越高；当前投资越多，未来资本越高，从而扩大未来的消费可能性。动态优化研究的正是这种 present versus future (现在与未来) 之间的取舍。

静态优化通常写成

$$\max_x f(x).$$

动态优化则常写成

$$\max_{\{x_t\}_{t=0}^T} \sum_{t=0}^T \beta^t F(x_t, x_{t+1}),$$

其中 $\beta \in (0, 1)$ 是 discount factor (贴现因子)。这里的选择变量不是单个 x ，而是一整条路径 $\{x_t\}_{t=0}^T$ 。当前 x_t 既影响当前收益，也影响下一期约束，所以动态优化本质上是“路径优化”。

10.1.2 离散时间与连续时间

动态模型必须为变量标注时间。常见时间设定有两类。

Definition 10.1.1.

Discrete time (离散时间) 指时间取

$$t = 0, 1, 2, \dots$$

变量写作 y_t 。典型演化方程为

$$k_{t+1} = G(k_t, c_t).$$

离散时间适合描述按月、按季、按年记录的数据，例如月度 CPI 或年度 GDP。

Definition 10.1.2.

Continuous time (连续时间) 指时间取 $t \in \mathbb{R}_+$ ，变量写作 $y(t)$ 。典型演化方程为

$$\dot{k}(t) = G(k(t), c(t)),$$

其中 $\dot{k}(t) = dk(t)/dt$ 。连续时间适合描述可以近似连续变动的对象，例如金融资产价格或汇率。

选择离散时间还是连续时间，取决于研究对象、数据频率和模型便利性。本章主要使用离散时间。

10.1.3 差分方程与微分方程**Definition 10.1.3.**

Difference equation (差分方程) 描述离散时间下相邻两期变量的变化。若变量为 y_t ，则一阶差分为

$$\Delta y_t = y_{t+1} - y_t.$$

差分方程说明 Δy_t 由哪些变量决定。

例如，若价格指数满足

$$p_{t+1} - p_t = \theta p_t, \quad 0 < \theta < 1,$$

则价格指数每一期增加当前水平的比例 θ 。又如，货币供给满足

$$m_{t+1} - m_t = b + \alpha m_t, \quad b > 0, \alpha > 0,$$

表示货币供给每期增加常数项 b ，并额外增加上一期货币供给的一定比例。

Definition 10.1.4.

Differential equation (微分方程) 描述连续时间下变量的瞬时变化率。若变量为 $y(t)$ ，则

$$\frac{dy}{dt} = \lim_{h \rightarrow 0} \frac{y(t+h) - y(t)}{h}.$$

常用记号是 $\dot{y} = dy/dt$ 。

资本积累的连续时间形式常写为

$$\dot{K}(t) = I(t) - \delta K(t), \quad 0 < \delta < 1,$$

即资本存量的变化等于新投资减去折旧。差分方程与微分方程的区别只是时间建模方式不同：前者在 $t = 0, 1, 2, \dots$ 上变化，后者在连续时间上变化。

Sec 10.2 离散时间 Ramsey 模型

10.2.1 规划者问题

离散时间 Ramsey model (Ramsey 模型) 是动态优化中最经典的增长模型之一。社会规划者选择每一期消费 c_t 和下一期资本 k_{t+1} ，以最大化贴现效用和：

$$\max_{\{c_t, k_{t+1}\}_{t=0}^T} \sum_{t=0}^T \beta^t u(c_t), \quad \beta \in (0, 1).$$

这里 $u(c_t)$ 是第 t 期消费效用， β 衡量耐心程度。 β 越高，未来效用的权重越大。

规划者面对资源约束

$$c_t + k_{t+1} \leq f(k_t), \quad t = 0, 1, \dots, T,$$

其中

1. c_t 是第 t 期消费；
2. k_{t+1} 是带到下一期的资本；
3. $f(k_t)$ 是由当前资本 k_t 生产出来的产出；
4. 初始资本 $k_0 > 0$ 给定。

这个约束体现了本章最重要的跨期权衡：当前产出既可以消费，也可以储蓄为下一期资本。

10.2.2 基本假设

本章采用以下标准假设：

1. $u(c)$ strictly increasing (严格递增)、differentiable (可微) 且 concave (凹)；
2. $f(k)$ strictly increasing (严格递增)、differentiable (可微) 且 concave (凹)；
3. $f(0) = 0$ ；
4. 效用函数满足 Inada condition (稻田条件)：

$$\lim_{c \rightarrow 0} u'(c) = +\infty.$$

稻田条件的含义是：当消费接近零时，边际效用趋于无穷大，所以零消费极其不可取。这个条件帮助排除最优解中的零消费角点。

由于 u 严格递增，资源约束在最优解处必定取等号。如果某一期有

$$c_t + k_{t+1} < f(k_t),$$

则可以增加 c_t 而不影响可行性，并使效用上升，矛盾。因此

$$c_t + k_{t+1} = f(k_t),$$

从而

$$c_t = f(k_t) - k_{t+1}.$$

于是有限期 Ramsey 问题可改写为仅以资本路径为选择变量的问题：

$$\max_{\{k_{t+1}\}_{t=0}^T} \sum_{t=0}^T \beta^t u(f(k_t) - k_{t+1}).$$

10.2.3 内点性与终端条件

正消费要求

$$k_{t+1} < f(k_t).$$

在终端日以前，最优解通常是 interior solution（内点解）：

$$0 < k_{t+1} < f(k_t), \quad t = 0, \dots, T-1.$$

直观地说， $k_{t+1} = 0$ 意味着下一期没有资本； $k_{t+1} = f(k_t)$ 意味着当前消费为零。稻田条件使这两种极端选择都不能在终端日以前最优。

Proposition 10.2.1.

若 $t < T$ 且 $k_t > 0$ ，则最优资本选择满足

$$0 < k_{t+1} < f(k_t).$$

Proof. 先说明 $k_{t+1} > 0$ 。反设某一期 $t < T$ 有 $k_{t+1} = 0$ 。把 $x = k_{t+1}$ 看成局部选择变量，与 x 直接相关的效用项至少包括

$$\beta^t u(f(k_t) - x) + \beta^{t+1} u(f(x) - k_{t+2}).$$

若从 $x = 0$ 略微增加资本，当前消费减少，带来边际损失

$$-\beta^t u'(f(k_t) - x),$$

但下一期可用资源增加，带来边际收益

$$\beta^{t+1} u'(f(x) - k_{t+2}) f'(x).$$

在 $x = 0$ 附近, 下一期消费接近零; 由 Inada condition, 下一期消费的边际效用趋于无穷大。因此从 0 增加一点 x 会提高目标函数, 矛盾。

再说明 $k_{t+1} < f(k_t)$ 。若

$$k_{t+1} = f(k_t),$$

则 $c_t = 0$ 。考虑略微减少 k_{t+1} , 这会增加当前消费。目标函数对 $x = k_{t+1}$ 的边际变化为

$$-\beta^t u'(f(k_t) - x) + \beta^{t+1} u'(f(x) - k_{t+2}) f'(x).$$

当 $x = f(k_t)$ 时, 第一项为 $-\infty$, 因为当前消费为零。于是减少 x 会提高效用, 和最优性矛盾。因此 $k_{t+1} < f(k_t)$ 。■

终端期有一个特殊条件。模型在 T 期结束, $T+1$ 期以后没有生产和消费, 因此终端以后留下的资本没有价值。

Proposition 10.2.2.

在有限期 Ramsey 问题中, 终端资本满足

$$k_{T+1}^* = 0.$$

Proof. 反设最优解中 $k_{T+1}^* > 0$ 。保持 $0, \dots, T-1$ 期的选择不变, 在第 T 期把原本留作 k_{T+1}^* 的资源转为消费, 即把消费从 c_T^* 增加到

$$c_T^* + k_{T+1}^*.$$

由于第 T 期以后没有未来时期, 减少 k_{T+1} 不会造成任何未来损失; 同时 u 严格递增, 所以第 T 期效用上升。这与原路径最优矛盾。■

因此, 有限期 Ramsey 问题可以规范地写为

$$\max_{\{c_t, k_{t+1}\}_{t=0}^T} U = \sum_{t=0}^T \beta^t u(c_t)$$

subject to

$$c_t + k_{t+1} = f(k_t), \quad t = 0, 1, \dots, T,$$

with

$$k_0 > 0 \text{ given}, \quad k_{T+1} = 0.$$

10.2.4 拉格朗日法与 Euler 方程

构造 Lagrangian (拉格朗日函数):

$$\mathcal{L} = \sum_{t=0}^T [\beta^t u(c_t) + \lambda_t (f(k_t) - k_{t+1} - c_t)].$$

对 c_t 的一阶条件为

$$\frac{\partial \mathcal{L}}{\partial c_t} = \beta^t u'(c_t) - \lambda_t = 0,$$

即

$$\beta^t u'(c_t) = \lambda_t.$$

对 k_{t+1} 的一阶条件要注意: k_{t+1} 既出现在第 t 期约束中, 也作为下一期生产函数的状态变量出现在第 $t+1$ 期约束中。因此对 $t = 0, \dots, T-1$,

$$\frac{\partial \mathcal{L}}{\partial k_{t+1}} = -\lambda_t + \lambda_{t+1} f'(k_{t+1}) = 0,$$

从而

$$\lambda_t = \lambda_{t+1} f'(k_{t+1}).$$

代入 $\lambda_t = \beta^t u'(c_t)$ 与

$$\lambda_{t+1} = \beta^{t+1} u'(c_{t+1}),$$

得到

$$\beta^t u'(c_t) = \beta^{t+1} u'(c_{t+1}) f'(k_{t+1}).$$

两边除以 β^t , 得到 Euler equation (Euler 方程):

$$u'(c_t) = \beta u'(c_{t+1}) f'(k_{t+1}), \quad t = 0, \dots, T-1.$$

这个方程的经济含义非常清楚:

1. 左边 $u'(c_t)$ 是今天多消费一单位的边际效用;
2. 右边 $\beta u'(c_{t+1}) f'(k_{t+1})$ 是今天少消费一单位、把它存成资本后, 明天通过边际产出转化为消费所带来的贴现边际效用。

最优路径要求二者相等。

Euler 方程与资源约束

$$c_t + k_{t+1} = f(k_t)$$

共同决定最优动态路径

$$\{c_t, k_{t+1}\}_{t=0}^T.$$

若把消费消去, Euler 方程会变成关于资本的 second-order difference equation (二阶差分方程): 它同时涉及 k_t, k_{t+1}, k_{t+2} 。边界条件为

$$k_0 > 0 \text{ given}, \quad k_{T+1} = 0.$$

10.2.5 凹性与充分性

在凹优化问题中, 一阶条件不仅必要, 而且充分。这里需要验证目标函数

$$\sum_{t=0}^T \beta^t u(f(k_t) - k_{t+1})$$

关于资本路径是凹的。

记

$$c_t = f(k_t) - k_{t+1}, \quad H(k_t, k_{t+1}) = u(c_t).$$

一阶偏导为

$$\frac{\partial H}{\partial k_t} = u'(c_t)f'(k_t), \quad \frac{\partial H}{\partial k_{t+1}} = -u'(c_t).$$

二阶偏导为

$$\frac{\partial^2 H}{\partial k_t^2} = u''(c_t)(f'(k_t))^2 + u'(c_t)f''(k_t) \leq 0,$$

$$\frac{\partial^2 H}{\partial k_{t+1}^2} = u''(c_t) \leq 0,$$

$$\frac{\partial^2 H}{\partial k_t \partial k_{t+1}} = -u''(c_t)f'(k_t).$$

二维 Hessian 为 negative semidefinite (负半定) 的充分检查是: 两个对角二阶项非正, 且行列式非负。行列式为

$$\left[u''(c_t)(f'(k_t))^2 + u'(c_t)f''(k_t) \right] u''(c_t) - [-u''(c_t)f'(k_t)]^2.$$

化简得

$$u'(c_t)f''(k_t)u''(c_t) \geq 0,$$

因为 $u'(c_t) > 0$, $f''(k_t) \leq 0$, $u''(c_t) \leq 0$ 。因此每一期的 H 都是凹函数, 贴现加总仍然是凹函数。一阶条件由此足以刻画全局最优。

10.2.6 例: 对数效用与线性技术

Example 10.2.1.

设

$$u(c) = \log c, \quad f(k) = Rk.$$

则

$$u'(c) = \frac{1}{c}, \quad f'(k) = R.$$

Euler 方程变为

$$\frac{1}{c_t} = \beta R \frac{1}{c_{t+1}}.$$

因此

$$c_{t+1} = \beta R c_t,$$

从而

$$\frac{c_{t+1}}{c_t} = \beta R.$$

耐心程度 β 越高, 或者储蓄回报 R 越高, 未来消费相对于当前消费就越高。

10.2.7 例: 十期数值问题

考虑十期问题

$$\max_{\{c_t, k_{t+1}\}_{t=0}^{10}} \sum_{t=0}^{10} \beta^t \log(c_t)$$

subject to

$$c_t + k_{t+1} \leq k_t^\alpha + (1 - \delta)k_t, \quad t = 0, 1, \dots, 10,$$

with k_0 given. 由于对数效用严格递增, 资源约束在最优解处绑定:

$$c_t = k_t^\alpha + (1 - \delta)k_t - k_{t+1}.$$

Euler 方程为

$$\frac{1}{k_t^\alpha + (1 - \delta)k_t - k_{t+1}} = \beta \frac{\alpha k_{t+1}^{\alpha-1} + 1 - \delta}{k_{t+1}^\alpha + (1 - \delta)k_{t+1} - k_{t+2}},$$

其中 $t = 0, 1, \dots, 9$, 终端条件是

$$k_{11} = 0.$$

课件中的参数取值为

$$\delta = 0.1, \quad \alpha = \frac{1}{3}, \quad \beta = 0.9, \quad k_0 = 2.$$




图 10.1: 十期 Ramsey 数值解: 终端条件使资本在最后一期被消耗, 消费在后期上升

图 10.1 展示了 finite horizon (有限期) 模型的典型终端效应。由于 $k_{11} = 0$, 资本在最后阶段被逐步转化为消费; 消费路径在后期上升, 资本路径向零下降。这也是引入 infinite horizon (无限期) 模型的一个动机: 有限期终端条件有时会制造人为的末期效应。

Sec 10.3 无限期与横截条件

10.3.1 无限期 Ramsey 问题

许多动态经济问题没有自然终点。家庭储蓄、经济增长和企业长期投资都可能持续很久。有限期模型中的

$$k_{T+1} = 0$$

会产生人为终端效应; 无限期模型通过令时间延伸到无穷远来消除这种末期扭曲。

无限期 Ramsey 问题为

$$\max_{\{c_t, k_{t+1}\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t u(c_t)$$

subject to

$$c_t + k_{t+1} = f(k_t), \quad c_t \geq 0, \quad k_{t+1} \geq 0,$$

with

$$k_0 > 0 \text{ given.}$$

目标函数现在是 infinite discounted sum (无限贴现和)。

贴现因子 $\beta \in (0, 1)$ 至关重要。若消费恒定为

$$c_t = \bar{c}, \quad \forall t,$$

则 lifetime utility (终身效用) 为

$$\sum_{t=0}^{\infty} \beta^t u(\bar{c}) = u(\bar{c}) \sum_{t=0}^{\infty} \beta^t = \frac{u(\bar{c})}{1 - \beta}.$$

贴现保证未来效用的权重递减, 并使许多无限期目标函数有良好定义。

10.3.2 Euler 方程与横截条件

无限期问题中的 Euler 方程仍然是

$$u'(c_t) = \beta u'(c_{t+1}) f'(k_{t+1}), \quad t = 0, 1, 2, \dots$$

它仍然比较“今天消费一单位”与“储蓄一单位并在明天消费”的边际价值。

但是, 在无限期问题中, Euler 方程本身不够。有限期问题有终端条件 $k_{T+1} = 0$; 无限期问题没有最后一期, 因此需要一个条件排除在无穷远处留下有价值资本的浪费路径。

Definition 10.3.5.

无限期 Ramsey 问题的 transversality condition (横截条件) 是

$$\lim_{t \rightarrow \infty} \beta^t u'(c_t) k_{t+1} = 0.$$

其中 $\beta^t u'(c_t)$ 是第 t 期消费的贴现边际效用, 所以

$$\beta^t u'(c_t) k_{t+1}$$

可以理解为第 $t+1$ 期资本在无穷远处的贴现边际价值。横截条件要求这个价值在极限中为零。若极限严格为正, 说明规划者永远留下有价值资源而不消费, 这不可能最优。

Proposition 10.3.3.

在凹性假设下, 若一条可行路径 $\{c_t^*, k_{t+1}^*\}_{t=0}^{\infty}$ 满足 Euler 方程

$$u'(c_t^*) = \beta u'(c_{t+1}^*) f'(k_{t+1}^*)$$

和横截条件

$$\lim_{t \rightarrow \infty} \beta^t u'(c_t^*) k_{t+1}^* = 0,$$

则该路径是无限期 Ramsey 问题的最优路径。

Proof. 记

$$H(k_t, k_{t+1}) = u(f(k_t) - k_{t+1}).$$

前面已经说明, 在 u 与 f 的标准凹性假设下, H 关于 (k_t, k_{t+1}) 是凹函数。因此对任意可行路径 $\{c_t, k_{t+1}\}$ 和候选最优路径 $\{c_t^*, k_{t+1}^*\}$, 有一阶凹性不等式

$$H(k_t, k_{t+1}) - H(k_t^*, k_{t+1}^*) \leq u'(c_t^*)f'(k_t^*)(k_t - k_t^*) - u'(c_t^*)(k_{t+1} - k_{t+1}^*).$$

两边乘以 β^t 并从 $t = 0$ 加到 T :

$$\sum_{t=0}^T \beta^t [u(c_t) - u(c_t^*)] \leq \sum_{t=0}^T \beta^t u'(c_t^*)f'(k_t^*)(k_t - k_t^*) - \sum_{t=0}^T \beta^t u'(c_t^*)(k_{t+1} - k_{t+1}^*).$$

由于初始资本相同, $k_0 = k_0^*$ 。同时 Euler 方程给出

$$\beta^t u'(c_t^*)f'(k_t^*) = \beta^{t-1} u'(c_{t-1}^*), \quad t \geq 1.$$

因此中间项逐期抵消, 只剩下末端项:

$$\sum_{t=0}^T \beta^t u(c_t) \leq \sum_{t=0}^T \beta^t u(c_t^*) - \beta^T u'(c_T^*)(k_{T+1} - k_{T+1}^*).$$

又因任意可行路径满足 $k_{T+1} \geq 0$, 所以

$$-\beta^T u'(c_T^*)(k_{T+1} - k_{T+1}^*) \leq \beta^T u'(c_T^*)k_{T+1}^*.$$

从而

$$\sum_{t=0}^T \beta^t u(c_t) \leq \sum_{t=0}^T \beta^t u(c_t^*) + \beta^T u'(c_T^*)k_{T+1}^*.$$

令 $T \rightarrow \infty$, 由横截条件, 最后一项趋于零。于是

$$\sum_{t=0}^{\infty} \beta^t u(c_t) \leq \sum_{t=0}^{\infty} \beta^t u(c_t^*).$$

任意可行路径的效用都不超过候选路径, 所以候选路径最优。 ■

10.3.3 例: 对数效用与 Cobb-Douglas 生产

考虑

$$V^*(k_0) = \sup_{\{k_{t+1}\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t \log(Ak_t^\alpha - k_{t+1})$$

subject to

$$0 \leq k_{t+1} \leq Ak_t^\alpha, \quad k_0 > 0, \quad \alpha, \beta \in (0, 1).$$

我们验证策略

$$k_{t+1} = \alpha\beta Ak_t^\alpha.$$

在该策略下,

$$c_t = Ak_t^\alpha - k_{t+1} = (1 - \alpha\beta)Ak_t^\alpha.$$

对数效用满足 $u'(c) = 1/c$, Cobb-Douglas 生产函数满足

$$f'(k) = \alpha A k^{\alpha-1}.$$

Euler 方程右边为

$$\beta \frac{1}{c_{t+1}} \alpha A k_{t+1}^{\alpha-1} = \beta \frac{\alpha A k_{t+1}^{\alpha-1}}{(1-\alpha\beta) A k_{t+1}^{\alpha}} = \frac{\alpha\beta}{(1-\alpha\beta) k_{t+1}}.$$

再代入

$$k_{t+1} = \alpha\beta A k_t^{\alpha},$$

得到

$$\frac{\alpha\beta}{(1-\alpha\beta) k_{t+1}} = \frac{1}{(1-\alpha\beta) A k_t^{\alpha}} = \frac{1}{c_t}.$$

这正是 Euler 方程左边。因此该策略满足 Euler 方程。

在该策略下, 稳态 k^* 满足

$$k^* = \alpha\beta A (k^*)^{\alpha},$$

所以

$$k^* = (A\alpha\beta)^{\frac{1}{1-\alpha}}.$$

消费收敛到

$$c^* = (1-\alpha\beta) A (k^*)^{\alpha}.$$

由于 k_t 与 c_t 收敛到有限正数,

$$\frac{k_{t+1}}{c_t}$$

有界, 而 $\beta^t \rightarrow 0$. 因此

$$\lim_{t \rightarrow \infty} \beta^t u'(c_t) k_{t+1} = \lim_{t \rightarrow \infty} \beta^t \frac{k_{t+1}}{c_t} = 0.$$

所以横截条件也成立。

Sec 10.4

稳态与转移动态

10.4.1 稳态

解出最优政策以后, 还要研究经济的 long-run behavior (长期行为): 资本是否收敛? 长期消费由什么决定? 耐心程度和生产率如何影响长期资本?

Definition 10.4.6.

若资本路径满足

$$k_{t+1} = k_t = k^*,$$

则称 k^* 为 steady state (稳态) 资本。

无折旧 Ramsey 模型的 Euler 方程为

$$u'(c_t) = \beta u'(c_{t+1}) f'(k_{t+1}).$$

在稳态中,

$$c_{t+1} = c_t = c^*, \quad k_{t+1} = k_t = k^*.$$

因此

$$u'(c^*) = \beta u'(c^*) f'(k^*).$$

由于 $u'(c^*) > 0$, 可约去, 得到

$$f'(k^*) = \frac{1}{\beta}.$$

若资源约束含折旧:

$$c_t + k_{t+1} = f(k_t) + (1 - \delta)k_t,$$

则 Euler 方程变为

$$u'(c_t) = \beta u'(c_{t+1}) [f'(k_{t+1}) + 1 - \delta].$$

在稳态中,

$$1 = \beta [f'(k^*) + 1 - \delta],$$

所以

$$f'(k^*) = \frac{1}{\beta} - 1 + \delta.$$

这个式子可以写成

$$f'(k^*) - \delta = \frac{1}{\beta} - 1.$$

左边是资本的净边际回报, 右边是由贴现因子刻画的 impatience (不耐烦程度)。稳态要求储蓄的净回报等于规划者的不耐烦程度。

10.4.2 稳态比较静态

由

$$f'(k^*) = \frac{1}{\beta} - 1 + \delta$$

可以得到两个基本 comparative statics (比较静态) 结论。

第一, β 上升会降低右边。由于 f 凹, f' 随 k 下降。若稳态边际产出要求更低, 就必须有更高的 k^* 。因此更有耐心的经济会积累更多长期资本。

第二, δ 上升会提高右边。为使边际产出更高, 稳态资本必须下降。因此折旧率越高, 长期资本越低。

10.4.3 例: Cobb-Douglas 生产

设

$$f(k) = Ak^\alpha, \quad 0 < \alpha < 1.$$

则

$$f'(k) = \alpha Ak^{\alpha-1}.$$

无折旧时, 稳态条件为

$$\alpha A(k^*)^{\alpha-1} = \frac{1}{\beta}.$$

解得

$$k^* = (\alpha A \beta)^{\frac{1}{1-\alpha}}.$$

若有折旧, 则

$$\alpha A (k^*)^{\alpha-1} = \frac{1}{\beta} - 1 + \delta,$$

因此

$$k^* = \left(\frac{\alpha A}{\frac{1}{\beta} - 1 + \delta} \right)^{\frac{1}{1-\alpha}}.$$

给定稳态资本, 稳态消费由资源约束决定。无折旧时,

$$c^* = f(k^*) - k^*.$$

有折旧时,

$$c^* = f(k^*) - \delta k^*.$$

资本是 state variable (状态变量), 而消费由可行性和最优政策共同钉住。

10.4.4 转移动态

若经济从稳态以外开始, 即

$$k_0 \neq k^*,$$

最优政策函数 (policy function) 决定 transition path (转移路径):

$$k_{t+1} = g(k_t).$$

序列

$$k_0, k_1, k_2, \dots$$

描述资本如何向稳态移动。对应消费路径由

$$c_t = f(k_t) - g(k_t)$$

给出。

在对数效用与 Cobb-Douglas 生产的例子中, 最优政策为

$$k_{t+1} = \alpha \beta A k_t^\alpha.$$

因此

$$g(k) = \alpha \beta A k^\alpha.$$

稳态满足

$$k^* = \alpha \beta A (k^*)^\alpha,$$

所以

$$k^* = (\alpha \beta A)^{\frac{1}{1-\alpha}}.$$

政策函数把当前资本映射到下一期资本。若 $k_t < k^*$, 则通常 $g(k_t) > k_t$, 经济积累资本; 若 $k_t > k^*$, 则通常 $g(k_t) < k_t$, 经济减少资本。于是资本沿着政策函数逐步收敛到稳态。




图 10.2: 政策函数图: $g(k)$ 与 45° 线的交点给出稳态, 反复迭代政策函数得到转移路径

图 10.2 给出了 policy function diagram (政策函数图) 的基本读法。 $g(k)$ 与 45° 线的交点满足

$$g(k^*) = k^*,$$

即稳态条件。从初始 k_0 出发, 先由政策函数读出 $k_1 = g(k_0)$, 再把 k_1 带回横轴继续迭代, 就得到资本的转移路径。

Sec 10.5 本讲总结

本章的核心逻辑可以概括为:

1. 动态优化研究一整条跨期选择路径, 而不是单个静态选择;
2. 离散时间模型用差分方程描述变量演化, 连续时间模型用微分方程描述变量演化;
3. 有限期 Ramsey 模型中, 资源约束在最优解处绑定, 终端资本满足 $k_{T+1} = 0$;
4. Euler 方程

$$u'(c_t) = \beta u'(c_{t+1}) f'(k_{t+1})$$

刻画了当前消费和未来消费之间的最优边际权衡;

5. 在凹性假设下, Euler 方程与边界条件足以刻画有限期最优路径;
6. 无限期模型没有终端日, 因此需要横截条件

$$\lim_{t \rightarrow \infty} \beta^t u'(c_t) k_{t+1} = 0$$

排除无穷远处留下有价值资本的浪费路径;

7. 稳态满足 $k_{t+1} = k_t = k^*$, 无折旧时有 $f'(k^*) = 1/\beta$;
8. 有折旧时稳态条件为

$$f'(k^*) = \frac{1}{\beta} - 1 + \delta,$$

它说明资本净回报等于不耐烦程度;

9. 在 log-Cobb-Douglas 模型中, 政策函数

$$k_{t+1} = \alpha \beta A k_t^\alpha$$

给出从任意初始资本向稳态收敛的转移动态。



动态规划与连续时间优化

Part

Sec 11.1 总览

本章介绍 dynamic programming (动态规划) 这一求解动态优化问题的递归方法。第十章已经用 Euler equation (Euler 方程) 刻画 Ramsey 模型的最优路径; 那种方法把整条路径

$$\{c_t, k_{t+1}\}_{t=0}^{\infty}$$

作为一个整体来选择。动态规划采用另一种表示: 在每一期只根据当前 state variable (状态变量) 选择下一期状态, 并把未来问题压缩进 value function (价值函数) 之中。

本章主线如下:

1. 建立动态规划的基本框架: state space、feasible correspondence 和 per-period return;
2. 把无限期 Ramsey 问题写成 Bellman equation (Bellman 方程);
3. 由 Bellman 方程推导 policy function (政策函数)、一阶条件和 envelope condition (包络条件);
4. 说明递归方法与 Euler 方程方法等价;
5. 用 log-Cobb-Douglas 增长模型演示 guess-and-verify (猜测试证法);
6. 介绍 value function iteration (价值函数迭代) 和 Bellman operator (Bellman 算子) 的收敛直觉。

Sec 11.2 动态规划与 Bellman 方程

11.2.1 动态规划的基本思想

动态规划提供了一种 recursive (递归) 的求解方式。Euler 方程方法一次性选择整条路径; 动态规划则把问题拆成一系列形式相同的一期问题。关键是: 只要当前状态变量已经给定, 所有与未来收益有关的过去信息都应当已经被状态变量概括。

在一般动态规划框架中, 有三个基本对象:

1. **State space (状态空间)** X : 状态变量 $x \in X$ 所能取的集合。状态变量概括所有与当前和未来决策相关的历史信息。
2. **Feasible correspondence (可行对应)** $\Gamma(x_t)$: 给定当前状态 x_t , 下一期状态 x_{t+1} 可以选择的集合。
3. **Per-period return (单期回报)** $F(x_t, x_{t+1})$: 从当前状态 x_t 选择下一期状态 x_{t+1} 所得到的当期收益或效用。

一般无限期动态问题可以写为

$$\sup_{\{x_{t+1}\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t F(x_t, x_{t+1})$$

subject to

$$x_{t+1} \in \Gamma(x_t), \quad t = 0, 1, 2, \dots,$$

with

$$x_0 \in X \text{ given.}$$

这里 x_t 是状态变量。若 x_t 已经包含所有 payoff-relevant information (与收益相关的信息), 则过去的完整历史不再需要单独进入决策问题。

Definition 11.2.1.

给定状态 x , **value function (价值函数)** 定义为从 $x_0 = x$ 出发所能达到的最大终身贴现回报:

$$V(x) = \sup_{\{x_{t+1}\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t F(x_t, x_{t+1})$$

subject to

$$x_{t+1} \in \Gamma(x_t), \quad x_0 = x.$$

它回答的问题是: 从状态 x 出发有多大价值。

11.2.2 Bellman 方程

价值函数的递归表示为

$$V(x) = \max_{x' \in \Gamma(x)} \{F(x, x') + \beta V(x')\}.$$

这就是 **Bellman equation (Bellman 方程)**。其中

1. $F(x, x')$ 是当前回报;
2. $V(x')$ 是从下一期状态 x' 开始的 continuation value (延续价值);
3. $\beta V(x')$ 是贴现后的未来价值。

Bellman 方程把原本的无限期路径选择问题分解为一个一期选择问题: 给定当前状态 x , 选择 x' 以最大化“当前回报加未来价值”。明天到达状态 x' 后, 同样的逻辑再次适用:

$$V(x') = \max_{x'' \in \Gamma(x')} \{F(x', x'') + \beta V(x'')\}.$$

这种自相似结构正是动态规划的核心。

11.2.3 Ramsey 模型的递归表示

第十章的无限期 Ramsey 问题可以写成 sequential form (序列形式):

$$V^*(k_0) = \sup_{\{k_{t+1}\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t u(f(k_t) - k_{t+1})$$

subject to

$$k_{t+1} \in [0, f(k_t)].$$

这里当前资本 k_t 是 state variable, 下一期资本 k_{t+1} 是 choice variable。给定 k_t , 当前消费由资源约束决定:

$$c_t = f(k_t) - k_{t+1}.$$

因此 Ramsey 模型的 Bellman 方程为

$$V(k) = \max_{k' \in [0, f(k)]} \{u(f(k) - k') + \beta V(k')\}.$$

在这个表达中:

1. k 是当前资本;
2. k' 是下一期资本;
3. $f(k) - k'$ 是当前消费;
4. $V(k')$ 是从明天资本 k' 开始的最大未来价值。

选择更高的 k' 会降低当前消费, 但提高未来生产能力; 这正是 Ramsey 模型的跨期权衡。

11.2.4 政策函数

Bellman 方程中使右边达到最大值的选择定义为 policy function (政策函数):

$$g(k) = \arg \max_{k' \in [0, f(k)]} \{u(f(k) - k') + \beta V(k')\}.$$

它告诉我们: 给定当前资本 k , 最优地带到下一期的资本是多少, 即

$$k' = g(k).$$

对应的 consumption policy (消费政策) 为

$$c(k) = f(k) - g(k).$$

因此, Bellman 方程不仅给出价值函数, 也同时刻画储蓄政策和消费政策。

11.2.5 一阶条件与包络条件

若最优解是内点, 则 Ramsey Bellman 方程可写为

$$V(k) = \max_{k'} \{u(f(k) - k') + \beta V(k')\}.$$

对 k' 求一阶条件:

$$-u'(f(k) - k') + \beta V'(k') = 0.$$

令

$$c_t = f(k_t) - k_{t+1},$$

则一阶条件变为

$$u'(c_t) = \beta V'(k_{t+1}).$$

左边是当前消费的边际效用, 右边是下一期资本的贴现边际价值。

另一方面, 由 envelope theorem (包络定理), 对当前状态 k 求导时, 只需要考虑目标函数中直接依赖于 k 的部分:

$$V'(k) = u'(f(k) - k')f'(k).$$

代入 $c_t = f(k_t) - k_{t+1}$, 得到

$$V'(k_t) = u'(c_t)f'(k_t).$$

这个式子的含义是:

1. $V'(k_t)$ 是资本的 marginal value (边际价值);
2. $u'(c_t)$ 是资源转化为消费时的边际效用;
3. $f'(k_t)$ 是一单位资本带来的额外产出。

因此, 明天同样有

$$V'(k_{t+1}) = u'(c_{t+1})f'(k_{t+1}).$$

把一阶条件

$$u'(c_t) = \beta V'(k_{t+1})$$

和包络条件

$$V'(k_{t+1}) = u'(c_{t+1})f'(k_{t+1})$$

合并, 得到

$$u'(c_t) = \beta u'(c_{t+1})f'(k_{t+1}).$$

这正是第十章得到的 Euler 方程。因此 dynamic programming approach (动态规划方法) 与 Euler equation approach (Euler 方程方法) 在最优性刻画上是一致的。

11.2.6 序列方法与递归方法的比较

序列方法把问题写为

$$\max_{\{c_t, k_{t+1}\}} \sum_{t=0}^{\infty} \beta^t u(c_t),$$

其特点是:

11.3. 猜测验证法与价值函数迭代

1. 直接选择整条消费和资本路径;
2. 使用 Lagrangian (拉格朗日函数);
3. 推导 Euler 方程和横截条件。

递归方法把同一问题写为

$$V(k) = \max_{k'} \{u(f(k) - k') + \beta V(k')\}.$$

其特点是:

1. 给定当前状态 k , 只选择下一期资本 k' ;
2. 用状态变量概括历史;
3. 直接刻画政策函数 $k' = g(k)$ 。

两种方法只是表示不同: 序列方法强调整条路径, 递归方法强调状态和政策函数; 在标准条件下, 它们给出同一个最优路径。

Sec 11.3

猜测验证法与价值函数迭代

11.3.1 猜测验证法

先考虑 log-Cobb-Douglas 最优增长问题:

$$\max_{\{c_t, k_{t+1}\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t \log(c_t)$$

subject to

$$k_{t+1} = Ak_t^\alpha - c_t, \quad k_0 > 0.$$

等价地,

$$c_t = Ak_t^\alpha - k_{t+1}.$$

其 Bellman 方程为

$$V(k) = \max_{0 < k' < Ak^\alpha} \{\log(Ak^\alpha - k') + \beta V(k')\}.$$

对数效用和 Cobb-Douglas 生产函数具有很强的函数形式相容性, 因此猜测价值函数具有 log-linear form (对数线性形式):

$$V(k) = E + F \log k.$$

这里 E 和 F 是待定常数。猜测验证法的步骤是: 先猜一个函数形式, 代入 Bellman 方程求出最优政策, 再匹配系数, 最后验证猜测形式确实封闭。

11.3.2 求解政策函数

将猜测

$$V(k') = E + F \log k'$$

代入 Bellman 方程, 得到

$$V(k) = \max_{0 < k' < Ak^\alpha} \{ \log(Ak^\alpha - k') + \beta(E + F \log k') \}.$$

对 k' 求一阶条件:

$$-\frac{1}{Ak^\alpha - k'} + \frac{\beta F}{k'} = 0.$$

移项得

$$\frac{\beta F}{k'} = \frac{1}{Ak^\alpha - k'}.$$

交叉相乘:

$$\beta F(Ak^\alpha - k') = k'.$$

因此

$$\beta F Ak^\alpha = (1 + \beta F)k',$$

从而

$$k' = \frac{\beta F}{1 + \beta F} Ak^\alpha.$$

11.3.3 匹配系数

把政策函数代回 Bellman 方程。先记

$$s := \frac{\beta F}{1 + \beta F}, \quad k' = sAk^\alpha.$$

则

$$Ak^\alpha - k' = (1 - s)Ak^\alpha.$$

Bellman 方程变为

$$E + F \log k = \log((1 - s)Ak^\alpha) + \beta[E + F \log(sAk^\alpha)].$$

展开右边:

$$E + F \log k = \log(1 - s) + \log A + \alpha \log k + \beta E + \beta F (\log s + \log A + \alpha \log k).$$

由于该等式必须对所有 k 成立, 比较 $\log k$ 的系数, 得到

$$F = \alpha + \alpha\beta F.$$

解得

$$F = \frac{\alpha}{1 - \alpha\beta}.$$

于是

$$\frac{\beta F}{1 + \beta F} = \frac{\frac{\alpha\beta}{1-\alpha\beta}}{1 + \frac{\alpha\beta}{1-\alpha\beta}} = \alpha\beta.$$

因此最优政策函数为

$$k' = \alpha\beta Ak^\alpha.$$

消费政策为

$$c = Ak^\alpha - k' = (1 - \alpha\beta)Ak^\alpha.$$

若继续匹配常数项，还可以求出

$$E = \frac{\log((1 - \alpha\beta)A) + \beta F \log(\alpha\beta A)}{1 - \beta}.$$

不过对政策函数而言，关键系数是 F ，因为它决定储蓄比例。

11.3.4 经济学解释

最优政策为

$$k' = \alpha\beta Ak^\alpha.$$

因此规划者储蓄产出的固定比例：

$$\frac{k'}{Ak^\alpha} = \alpha\beta.$$

这给出两个直观比较静态：

1. β 越高，规划者越有耐心，愿意储蓄更多；
2. α 越高，资本在生产中越重要，储蓄回报越高，因此最优储蓄比例更高。

这就是 log-Cobb-Douglas Ramsey 模型的 closed-form solution（闭式解）。

Sec 11.4 价值函数迭代

11.4.1 基本思想

猜测验证法依赖便利的函数形式；在更一般的问题中，价值函数未必能被简单猜中。此时可以使用 value function iteration（价值函数迭代）进行数值近似。

从初始猜测开始，例如

$$V_0(k) = 0.$$

然后反复使用 Bellman 方程更新：

$$V_{j+1}(k) = \max_{k' \in \Gamma(k)} \{u(f(k) - k') + \beta V_j(k')\}.$$

随着迭代次数增加，

$$V_0(k) \rightarrow V_1(k) \rightarrow V_2(k) \rightarrow \cdots \rightarrow V^*(k).$$

算法可以写为：

1. 选择初始猜测 $V_0(k)$;
2. 对每个状态 k , 计算

$$V_{j+1}(k) = \max_{k' \in \Gamma(k)} \{u(f(k) - k') + \beta V_j(k')\};$$

3. 检查收敛:

$$\max_k |V_{j+1}(k) - V_j(k)| < \varepsilon;$$

4. 若满足收敛条件则停止, 否则回到第二步。

在收敛时,

$$V_j(k) \approx V^*(k).$$




图 11.1: 价值函数迭代: 从初始猜测出发, 反复应用 Bellman 方程使价值函数逐步靠近固定点

图 11.1 展示了价值函数迭代的典型形态。不同迭代次数下的价值函数逐渐靠近极限曲线 V_∞ 。直观地说, 每次迭代都会把“多看一期未来”的信息纳入价值函数; 当迭代足够多时, 有限期近似逐渐接近无限期问题的价值函数。

11.4.2 Bellman 算子

定义 Bellman operator (Bellman 算子) T :

$$(TV)(k) = \max_{k' \in [0, f(k)]} \{u(f(k) - k') + \beta V(k')\}.$$

价值函数迭代可以简写为

$$V_{j+1} = TV_j.$$

真实价值函数是 Bellman 算子的 fixed point (固定点):

$$V^* = TV^*.$$

因此, 求解 Bellman 方程等价于寻找 Bellman 算子的固定点。

11.4.3 为什么价值函数迭代有效

Bellman 算子通常具有两个重要性质。

Proposition 11.4.1.

Bellman 算子 T 满足 *monotonicity* (单调性): 若对所有 k 都有

$$V_1(k) \geq V_2(k),$$

则

$$(TV_1)(k) \geq (TV_2)(k) \quad \forall k.$$

Proof. 对任意给定 k 和任意可行 k' , 若 $V_1(k') \geq V_2(k')$, 则

$$u(f(k) - k') + \beta V_1(k') \geq u(f(k) - k') + \beta V_2(k').$$

对左、右两边分别在可行集合上取最大值, 不等式保持成立, 所以

$$(TV_1)(k) \geq (TV_2)(k).$$

Proposition 11.4.2.

Bellman 算子 T 满足 *discounting* (贴现性): 对任意常数 a ,

$$T(V + a) = TV + \beta a.$$

Proof. 直接代入定义:

$$T(V + a)(k) = \max_{k'} \{u(f(k) - k') + \beta(V(k') + a)\}.$$

由于 βa 不依赖于选择变量 k' , 可以移到最大化号外:

$$T(V + a)(k) = \max_{k'} \{u(f(k) - k') + \beta V(k')\} \beta a = TV(k) + \beta a.$$

这两个性质是 Blackwell's conditions (Blackwell 条件) 的核心。它们意味着在标准有界性条件下, T 是 contraction (压缩映射)。用 sup norm (上确界范数)

$$\|V - W\|_\infty := \sup_k |V(k) - W(k)|$$

记

$$d = \|V - W\|_\infty.$$

则

$$W - d \leq V \leq W + d.$$

由单调性,

$$T(W - d) \leq TV \leq T(W + d).$$

再由贴现性,

$$TW - \beta d \leq TV \leq TW + \beta d.$$

因此

$$\|TV - TW\|_{\infty} \leq \beta \|V - W\|_{\infty}.$$

由于 $\beta \in (0, 1)$, 反复应用 T 会让价值函数之间的距离不断缩小。于是序列

$$V_0, TV_0, T^2V_0, \dots$$

收敛到唯一固定点

$$V^* = TV^*.$$

11.4.4 log-Cobb-Douglas 模型中的 VFI

在 log-Cobb-Douglas 模型中, 若第 j 次迭代时价值函数具有形式

$$V_j(k) = E_j + F_j \log k,$$

则应用 Bellman 算子后仍然得到同类形式:

$$TV_j(k) = E_{j+1} + F_{j+1} \log k.$$

由前面的猜测试验证推导, 给定 F_j 时, 一阶条件给出第 j 次迭代下的政策:

$$k' = \frac{\beta F_j}{1 + \beta F_j} A k^{\alpha}.$$

同时 $\log k$ 的系数满足递推式

$$F_{j+1} = \alpha + \alpha \beta F_j.$$

若从

$$F_0 = 0$$

开始, 则

$$F_1 = \alpha, \quad F_2 = \alpha + \alpha^2 \beta, \quad F_3 = \alpha + \alpha^2 \beta + \alpha^3 \beta^2,$$

一般地,

$$F_j = \alpha \sum_{m=0}^{j-1} (\alpha \beta)^m.$$

因为 $\alpha \beta \in (0, 1)$,

$$F_j \rightarrow F_{\infty} = \frac{\alpha}{1 - \alpha \beta}.$$

因此政策函数也收敛:

$$k' = \frac{\beta F_j}{1 + \beta F_j} A k^{\alpha} \rightarrow \alpha \beta A k^{\alpha}.$$

这说明 VFI 不仅收敛到价值函数, 也收敛到最优政策函数。

11.4.5 数值图示

考虑参数

$$\beta = 0.9, \quad \alpha = \frac{1}{3}, \quad \delta = 0.2.$$

价值函数迭代可以同时产出：

1. value function $V(k)$;
2. policy function $k' = g(k)$;
3. consumption policy $c(k) = f(k) - g(k)$ 。

政策函数告诉我们，在每一个当前资本水平下，最优的下一期资本是多少。




Figure: Policy Function




Figure: Value Function

图 11.2: 简单增长模型中的 VFI 结果：左图为政策函数，右图为价值函数

图 11.2 的左图展示政策函数 $g(k)$ 与 45° 线的关系。若政策函数位于 45° 线上方，则下一期资本大于当前资本，资本积累；若位于下方，则资本下降。右图展示价值函数 $V(k)$ ，它随着资本增加而上升，反映更高初始资本带来更高可达到的终身效用。

Sec 11.5 本讲总结

本章的核心逻辑可以概括为：

1. 动态规划把动态优化问题改写为递归问题，用当前状态概括所有与未来相关的历史信息；
2. Bellman 方程

$$V(x) = \max_{x' \in \Gamma(x)} \{F(x, x') + \beta V(x')\}$$

把无限期问题分解为“当前回报加贴现延续价值”的一期问题；

3. Ramsey 模型中，状态变量是当前资本 k ，选择变量是下一期资本 k' ；
4. 政策函数

$$g(k) = \arg \max_{k' \in [0, f(k)]} \{u(f(k) - k') + \beta V(k')\}$$

给出每个资本状态下的最优储蓄选择；

5. Bellman 方程的一阶条件和包络条件合起来可以恢复 Euler 方程

$$u'(c_t) = \beta u'(c_{t+1}) f'(k_{t+1});$$

6. 对 log-Cobb-Douglas 模型, 猜测

$$V(k) = E + F \log k$$

可以求得闭式政策

$$k' = \alpha \beta A k^\alpha, \quad c = (1 - \alpha \beta) A k^\alpha;$$

7. 价值函数迭代从初始猜测 V_0 出发, 反复应用 Bellman 算子 T , 即 $V_{j+1} = TV_j$;
 8. Bellman 算子的单调性与贴现性给出压缩映射直觉, 保证迭代收敛到唯一固定点 $V^* = TV^*$;
 9. 在 log-Cobb-Douglas 模型中, VFI 的系数递推

$$F_{j+1} = \alpha + \alpha \beta F_j$$

收敛到

$$F_\infty = \frac{\alpha}{1 - \alpha \beta},$$

因而政策函数也收敛到闭式最优政策。

封底信息.